

0.1 Bối cảnh bài toán

Trong môi trường bán lẻ, quá trình mua sắm của khách hàng thường diễn ra qua nhiều khu vực như cửa vào, khu trưng bày sản phẩm, khu tư vấn và quầy thanh toán. Trải nghiệm của khách hàng được hình thành qua nhiều lần tương tác theo thời gian, thay vì chỉ tại một thời điểm riêng lẻ [?]. Vì vậy, một kết quả nhận dạng biểu cảm tại một khu vực chưa thể hiện được diễn biến biểu cảm trong toàn bộ quá trình mua sắm.

Các hệ thống CRM thường lưu trữ hồ sơ khách hàng, đơn hàng và lịch sử mua hàng. Những dữ liệu này cho biết khách hàng là ai và đã mua sản phẩm nào, nhưng chưa phản ánh được biểu cảm và phản ứng quan sát được của khách hàng trong quá trình mua sắm. Phương pháp nhận dạng biểu cảm khuôn mặt có thể bổ sung thông tin này từ hình ảnh được ghi nhận tại từng khu vực. Tuy nhiên, nếu các kết quả chỉ được lưu thành những bản ghi riêng biệt, hệ thống không xác định được chúng thuộc khách hàng nào, được tạo ra trong phiên mua sắm nào và liên hệ với nhau theo thứ tự ra sao.

Halvorsrud, Kvale và Følstad cho rằng quá trình tương tác thực tế của khách hàng có thể được dựng lại từ các sự kiện quan sát được và được sắp xếp theo thời gian [?]. Vận dụng cách tiếp cận này, mỗi phiên mua sắm trong luận văn được biểu diễn thành một chuỗi lần ghi nhận tại những khu vực được xác định từ trước. Mỗi lần ghi nhận bao gồm mã khách hàng, mã phiên mua sắm, khu vực, thời gian và kết quả nhận dạng biểu cảm.

Việc liên kết các bản ghi cho phép theo dõi diễn biến biểu cảm của từng khách hàng trong một phiên mua sắm. Trên cơ sở đó, dữ liệu có thể được tổng hợp để xác định biểu cảm xuất hiện phổ biến tại từng khu vực, đồng thời ghi nhận trường hợp nhân biểu cảm được giữ nguyên hoặc thay đổi giữa hai khu vực liên tiếp. Khi kết hợp với thông tin đơn hàng và lịch sử mua hàng trong CRM, kết quả này cung cấp thêm dữ liệu để xem xét phản ứng của khách hàng trong từng giai đoạn của quá trình mua sắm.

Từ bối cảnh trên, luận văn giải quyết ba nội dung: nhận dạng biểu cảm khuôn mặt; liên kết kết quả theo khách hàng và phiên mua sắm; tích hợp dữ liệu phiên mua sắm vào CRM để tra cứu và thống kê. Qua đó, kết quả từ các ảnh riêng lẻ được sắp xếp để theo dõi diễn biến biểu cảm trong quá trình mua sắm.

0.2 Cơ sở lý thuyết về nhận dạng biểu cảm khuôn mặt

0.2.1 Cảm xúc, biểu cảm khuôn mặt và bài toán FER

Cảm xúc có thể được biểu hiện một phần qua những thay đổi trên khuôn mặt. Hoạt động của các vùng cơ làm thay đổi hình dạng và vị trí tương đối của mắt, lông mày, mũi, miệng và má. Khi khuôn mặt được ghi lại bằng ảnh, những thay đổi này tạo thành các mẫu thị giác thể hiện qua đường nét, hình dạng và sự phân bố điểm ảnh. Vì vậy, ảnh khuôn mặt có thể được sử dụng làm đầu vào để mô hình trích xuất đặc trưng và phân loại biểu cảm.

Năm 1971, Paul Ekman và Wallace V. Friesen công bố nghiên cứu *Constants Across Cultures in the Face and Emotion* nhằm kiểm tra khả năng nhận biết biểu cảm giữa các nền văn hóa. Nghiên cứu thu thập dữ liệu từ cộng đồng Fore tại New Guinea, là nhóm có mức độ tiếp xúc hạn chế với truyền thông phương Tây. Người tham gia nghe các tình huống mô tả cảm xúc và lựa chọn ảnh khuôn mặt phù hợp. Kết quả cho thấy nhiều mẫu biểu cảm được gán với các nhóm cảm xúc tương tự giữa cộng đồng này và những nhóm đã được khảo sát trước đó; tuy nhiên, sợ hãi và ngạc nhiên có mức độ nhầm lẫn cao hơn các nhóm còn lại [?]. Kết quả này cung cấp cơ sở thực nghiệm cho việc sử dụng sáu nhóm biểu cảm gồm tức giận, ghê tởm, sợ hãi, vui vẻ, buồn bã và ngạc nhiên trong các nghiên cứu nhận dạng biểu cảm khuôn mặt.

Nhận dạng biểu cảm khuôn mặt, viết tắt là FER, là bài toán xác định lớp biểu cảm từ ảnh hoặc chuỗi ảnh khuôn mặt. Shan Li và Weihong Deng trình bày một nghiên cứu tổng quan về FER dựa trên học sâu, bao gồm các bộ dữ liệu, phương pháp xử lý ảnh tĩnh, phương pháp xử lý chuỗi ảnh và những khó khăn thường gặp. Hai tác giả chỉ ra hai nhóm vấn đề chính là hiện tượng quá khớp (overfitting) do dữ liệu huấn luyện còn hạn chế và các biến thiên không liên quan trực tiếp đến biểu cảm như điều kiện chiếu sáng, tư thế đầu và đặc điểm nhận dạng của từng người [?].

Trong bài báo tổng quan *Deep Facial Expression Recognition: A Survey* [?] công bố năm 2022, Shan Li và Weihong Deng đã tổng hợp quy trình của một hệ thống FER. Theo quy trình được hai tác giả tổng hợp, một hệ thống FER thường gồm phát hiện khuôn mặt, căn chỉnh, tiền xử lý, trích xuất đặc trưng và phân loại. Với ảnh đầu vào I , bộ phát hiện xác định vùng khuôn mặt B . Vùng này được cắt và chuẩn hóa thành ảnh I_f . Mạng phân loại tiếp nhận I_f , trích xuất đặc trưng và tạo điểm số cho từng lớp biểu cảm. Các bước xử lý và một số nhóm mạng sâu được hai tác giả tổng hợp được minh họa ở Hình ??.

Đầu ra của mô hình được sử dụng trong hệ thống gồm bảy nhãn: *Angry, Disgust,*

Fear, Happy, Sad, Surprise và *Neutral*. Sáu nhãn đầu tương ứng với sáu nhóm biểu cảm cơ bản trong nghiên cứu của Ekman và Friesen. Nhãn *Neutral* được sử dụng theo cách phân chia bảy lớp của bộ dữ liệu FER-2013, do Pierre Luc Carrier và Aaron Courville xây dựng và được Goodfellow cùng cộng sự công bố. Nhãn này giúp mô hình xử lý những khuôn mặt không thể hiện rõ một trong sáu biểu cảm cơ bản, thay vì bắt buộc gán chúng vào một lớp biểu cảm không phù hợp [?]. Với mỗi ảnh khuôn mặt, mô hình trả về nhãn dự đoán và độ tin cậy tương ứng.



Hình 0.1: Bảy biểu cảm khuôn mặt

0.2.2 Quy trình FER tổng quát


Li và Deng mô tả quy trình nhận dạng biểu cảm khuôn mặt dựa trên học sâu gồm ba giai đoạn chính: tiền xử lý ảnh khuôn mặt, học đặc trưng và phân loại biểu cảm [?]. Đối với ảnh đầu vào, bước đầu tiên là phát hiện khuôn mặt để xác định vùng ảnh chứa khuôn mặt và loại bỏ phần lớn thông tin nền không liên quan. Đây là bước cần thiết vì mô hình nhận dạng biểu cảm chỉ có thể trích xuất đặc trưng phù hợp khi vùng khuôn mặt được xác định chính xác.

Sau khi khuôn mặt được phát hiện, ảnh được căn chỉnh và chuẩn hóa. Căn chỉnh khuôn mặt dựa trên các điểm đặc trưng đã xác định nhằm giảm sự khác biệt về kích thước, vị trí và góc xoay của khuôn mặt. Chuẩn hóa ảnh tiếp tục hạn chế ảnh hưởng của điều kiện chiếu sáng và tư thế đầu trước khi ảnh được đưa vào mạng học sâu. Trong giai đoạn huấn luyện, dữ liệu còn có thể được tăng cường bằng các phép biến đổi như xoay, dịch chuyển, thay đổi tỷ lệ, độ tương phản hoặc bổ sung nhiễu. Theo Li và Deng, việc tăng cường dữ liệu giúp mở rộng số lượng mẫu huấn luyện và hạn chế hiện tượng quá khớp khi dữ liệu biểu cảm khuôn mặt còn hạn chế [?].

Ảnh khuôn mặt sau khi tiền xử lý được đưa vào mạng học sâu để trích xuất đặc trưng. Khác với phương pháp truyền thống sử dụng các đặc trưng được thiết kế thủ

công, mạng học sâu hình thành biểu diễn đặc trưng thông qua nhiều lớp biến đổi phi tuyến. Đối với ảnh tĩnh, mạng nơ-ron tích chập thường được sử dụng để học các đặc trưng từ những vùng cục bộ đến biểu diễn tổng thể của khuôn mặt. Những đặc trưng thu được cần thể hiện được sự khác biệt giữa các mẫu biểu cảm, đồng thời hạn chế ảnh hưởng của các yếu tố không liên quan như đặc điểm riêng của từng người, điều kiện chiếu sáng và tư thế khuôn mặt [?].

Phân loại biểu cảm là bước cuối cùng của quy trình. Li và Deng cho biết trong các mô hình học sâu, bước trích xuất đặc trưng và phân loại có thể được huấn luyện đồng thời theo phương pháp đầu cuối. Lớp phân loại tiếp nhận đặc trưng đã học, tạo giá trị dự đoán cho từng lớp và xác định nhãn biểu cảm của ảnh đầu vào. Số lượng và tên các lớp đầu ra phụ thuộc vào bộ dữ liệu cũng như mô hình được sử dụng. Quy trình gồm phát hiện khuôn mặt, căn chỉnh và chuẩn hóa, trích xuất đặc trưng và phân loại biểu cảm được minh họa tại Hình ?? [?].



Hình 0.2: Quy trình tổng quát của hệ thống FER dựa trên học sâu (Nguồn: Li và Deng [?])

0.3 Các phương pháp phát hiện khuôn mặt

Phát hiện khuôn mặt là bài toán xác định trong ảnh có khuôn mặt hay không và định vị từng khuôn mặt bằng một khung bao. Qua ba công trình của Viola và Jones, Zhang và cộng sự, cùng Deng và cộng sự, quy trình phát hiện có thể được khái quát thành bốn thao tác: khảo sát ảnh tại nhiều vị trí và tỷ lệ; phân biệt vùng khuôn mặt với vùng nền; hiệu chỉnh vị trí khung bao; và loại bỏ các khung dự đoán trùng lặp [?, ?, ?]. Điểm tin cậy biểu thị mức độ mô hình cho rằng một khung dự đoán chứa khuôn mặt. Với các phương pháp có dự đoán điểm mốc, vị trí mắt, mũi và khóe miệng còn được xác định để hỗ trợ căn chỉnh khuôn mặt trước bước nhận dạng biểu cảm.


Ba công trình trên xây dựng các thao tác này theo những nguyên lý khác nhau. Viola và Jones khảo sát ảnh bằng cửa sổ trượt ở nhiều tỷ lệ, mô tả mỗi cửa sổ bằng

đặc trưng Haar, sử dụng AdaBoost để chọn đặc trưng phân biệt và tổ chức các bộ phân loại theo cấu trúc xếp tầng nhằm loại nhanh vùng nền [?]. Zhang và cộng sự đề xuất MTCNN gồm ba mạng tích chập nối tiếp; vùng ứng viên được sàng lọc và hiệu chỉnh dần từ P-Net đến R-Net và O-Net, đồng thời mô hình dự đoán năm điểm mốc khuôn mặt [?]. Deng và cộng sự đề xuất RetinaFace theo hướng phát hiện một giai đoạn: các khung khuôn mặt được dự đoán trực tiếp trên những mức đặc trưng có độ phân giải khác nhau, kết hợp nhiệm vụ phân loại khuôn mặt, hồi quy khung bao và xác định điểm mốc [?]. Các mục tiếp theo trình bày chi tiết cơ sở lý thuyết của từng phương pháp.

0.3.1 Haar Cascade theo Viola–Jones

Năm 2001, Paul Viola và Michael Jones công bố phương pháp phát hiện đối tượng nhanh dựa trên ba thành phần chính: ảnh tích phân để tính đặc trưng hình chữ nhật, AdaBoost để lựa chọn đặc trưng và bộ phân loại xếp tầng để giảm số phép tính khi quét ảnh. Phương pháp được hai tác giả xây dựng và kiểm chứng cho bài toán phát hiện khuôn mặt chính diện từ ảnh xám [?].

Ý tưởng chính của phương pháp là không dành cùng một lượng tính toán cho mọi vùng ảnh. Phần lớn cửa sổ khi quét toàn ảnh chỉ chứa nền và có thể bị loại bằng một số phép kiểm tra đơn giản. Chỉ những cửa sổ còn giống khuôn mặt mới được chuyển qua các bước kiểm tra phức tạp hơn. Luồng xử lý được luận văn tổng hợp tại Hình ??.



Hình 0.3: Quy trình phát hiện khuôn mặt theo Viola–Jones, luận văn tổng hợp từ [?]

Mỗi vùng ảnh cần kiểm tra được chuẩn hóa về cửa sổ cơ sở có kích thước 24×24 điểm ảnh. Thay vì so sánh trực tiếp từng điểm ảnh, Viola và Jones biểu diễn cửa sổ bằng các đặc trưng hình chữ nhật tương tự đặc trưng Haar. Đặc trưng hai vùng lấy chênh lệch tổng cường độ của hai hình chữ nhật kề nhau; đặc trưng ba vùng so sánh vùng trung tâm với hai vùng ngoài; đặc trưng bốn vùng so sánh hai cặp hình chữ nhật nằm trên hai đường chéo. Có thể hiểu mỗi đặc trưng là một phép kiểm tra quan hệ sáng–tối trong một phần khuôn mặt, chẳng hạn vùng mắt thường tối hơn vùng má. Với cửa sổ 24×24 , bài báo tạo ra hơn 180.000 đặc trưng ứng viên, vì vậy cần một cách tính nhanh và một cơ chế chỉ giữ lại các đặc trưng hữu ích.

Để tính nhanh tổng cường độ của một vùng chữ nhật, Viola và Jones sử dụng ảnh tích phân. Giá trị ảnh tích phân tại một vị trí được xác định bởi [?]:

$$ii(x, y) = \sum_{x'=0}^x \sum_{y'=0}^y i(x', y'). \quad (1)$$

Viola và Jones định nghĩa ảnh tích phân tại vị trí (x, y) là tổng giá trị của các điểm ảnh nằm phía trên và bên trái vị trí đó, bao gồm cả điểm ảnh tại (x, y) [?].

Trong Công thức ??, $i(x', y')$ là giá trị điểm ảnh của ảnh gốc tại vị trí (x', y') , còn $ii(x, y)$ là giá trị tương ứng trên ảnh tích phân. Hai biến x' và y' được dùng để duyệt các điểm ảnh thuộc miền tính tổng. Công thức này cần thiết vì tổng tích lũy chỉ phải tạo một lần cho toàn ảnh; các vùng chữ nhật sau đó không còn phải cộng lại từng điểm ảnh.

Giả sử vùng chữ nhật R có góc trên bên trái là (x_1, y_1) và góc dưới bên phải là (x_2, y_2) , tổng cường độ trong vùng được tính từ bốn giá trị của ảnh tích phân:

$$S(R) = ii(x_2, y_2) - ii(x_1 - 1, y_2) - ii(x_2, y_1 - 1) + ii(x_1 - 1, y_1 - 1). \quad (2)$$

Trong Công thức ??, $S(R)$ là tổng cường độ các điểm ảnh thuộc vùng R . Giá trị $ii(x_2, y_2)$ chứa vùng cần tính cùng phần ảnh nằm phía trên và bên trái. Hai số hạng tiếp theo loại hai phần thừa này; số hạng cuối được cộng lại vì vùng giao đã bị trừ hai lần. Công thức này là bước sử dụng ảnh tích phân: tổng của một hình chữ nhật chỉ cần bốn lần truy cập, không phụ thuộc vào diện tích vùng. Giá trị đặc trưng Haar được tạo bằng hiệu giữa tổng cường độ của các hình chữ nhật cấu thành đặc trưng.

Ảnh tích phân giải quyết tốc độ tính đặc trưng nhưng chưa giải quyết vấn đề có quá nhiều đặc trưng ứng viên. Vì vậy, phương pháp sử dụng AdaBoost, viết tắt của *Adaptive Boosting*, để lựa chọn đặc trưng và huấn luyện bộ phân loại. Tập huấn luyện gồm các cửa sổ chứa khuôn mặt và các cửa sổ không chứa khuôn mặt. Mỗi đặc trưng Haar cùng một ngưỡng tạo thành một bộ phân loại yếu theo Công thức ?? [?]:

$$h_j(X) = \begin{cases} 1, & \text{nếu } p_j f_j(X) < p_j \theta_j, \\ 0, & \text{ngược lại.} \end{cases} \quad (3)$$

Trong công thức trên, X là cửa sổ ảnh 24×24 cần phân loại; $f_j(X)$ là giá trị đặc trưng Haar thứ j ; θ_j là ngưỡng phân chia; $p_j \in \{-1, 1\}$ xác định chiều so sánh; còn $h_j(X)$ trả về 1 khi cửa sổ được xem là khuôn mặt và trả về 0 trong trường hợp còn lại. Hệ số p_j cần thiết vì có đặc trưng nhận biết khuôn mặt bằng giá trị nhỏ hơn ngưỡng, trong khi đặc trưng khác lại sử dụng giá trị lớn hơn ngưỡng. Một bộ phân loại yếu chỉ dựa trên một quan hệ sáng–tối nên chưa đủ tin cậy. Ở mỗi vòng huấn luyện, AdaBoost chọn bộ phân loại yếu có sai số có trọng số nhỏ nhất và tăng mức quan tâm đối với các mẫu đang bị phân loại sai.

Sau T vòng lặp, các quyết định đơn giản được kết hợp thành một bộ phân loại mạnh. Mục đích của Công thức ?? là thực hiện biểu quyết có trọng số thay vì coi mọi bộ phân loại yếu quan trọng như nhau:

$$H(X) = \begin{cases} 1, & \sum_{t=1}^T \alpha_t h_t(X) \geq \frac{1}{2} \sum_{t=1}^T \alpha_t, \\ 0, & \text{ngược lại,} \end{cases} \quad \alpha_t = \ln\left(\frac{1}{\beta_t}\right), \quad \beta_t = \frac{\varepsilon_t}{1 - \varepsilon_t}. \quad (4)$$

Trong Công thức ??, T là số bộ phân loại yếu được chọn; $h_t(X)$ là kết quả của bộ phân loại yếu thứ t ; ε_t là sai số có trọng số của bộ phân loại đó; β_t chuyển sai số thành hệ số trung gian; α_t là trọng số biểu quyết; và $H(X)$ là kết quả cuối cùng. Khi ε_t nhỏ, β_t nhỏ và α_t lớn, vì vậy bộ phân loại hoạt động tốt có ảnh hưởng nhiều hơn. Khi ε_t tiến gần 0,5, α_t tiến gần 0, nghĩa là một bộ phân loại gần với đoán ngẫu nhiên hầu như không đóng góp vào kết quả. Ngưỡng $\frac{1}{2} \sum_{t=1}^T \alpha_t$ thể hiện điều kiện đa số có trọng số: tổng mức ủng hộ lớp khuôn mặt phải đạt ít nhất một nửa tổng trọng số.

Bộ phân loại mạnh cho biết cách kết hợp các đặc trưng, nhưng nếu áp dụng toàn bộ cho mọi cửa sổ thì chi phí vẫn lớn. Viola và Jones giải quyết vấn đề này bằng cấu trúc xếp tầng. Các tầng đầu sử dụng ít đặc trưng để loại nhanh những vùng chắc chắn là nền; các tầng sau sử dụng nhiều đặc trưng hơn để kiểm tra những trường hợp khó. Cửa sổ bị từ chối tại bất kỳ tầng nào sẽ không được xử lý tiếp. Nhờ vậy, phần lớn vùng ảnh chỉ phải đi qua một hoặc hai tầng đầu, còn toàn bộ chuỗi chỉ được thực hiện trên số ít vùng có khả năng chứa khuôn mặt.


Khi xử lý ảnh hoàn chỉnh, cửa sổ dò được quét tại nhiều vị trí và nhiều tỷ lệ để tìm các khuôn mặt có kích thước khác nhau. Trong cấu hình thực nghiệm của bài báo, tỷ lệ giữa hai kích thước cửa sổ liên tiếp là 1,25. Mỗi cửa sổ còn được chuẩn hóa phương sai để giảm ảnh hưởng của chiếu sáng. Một khuôn mặt có thể tạo ra nhiều khung dự đoán gần nhau, do đó các khung chồng lấn được nhóm lại và tọa độ trung bình của nhóm được dùng làm kết quả cuối cùng [?].

Theo cách hiểu tổng quát, ảnh tích phân làm giảm chi phí tính đặc trưng; AdaBoost giảm số đặc trưng cần sử dụng; còn cấu trúc xếp tầng giảm số cửa sổ phải trải qua phép kiểm tra phức tạp. Ba thành phần cùng hướng tới mục tiêu phát hiện nhanh. Tuy nhiên, phương pháp gốc chủ yếu được huấn luyện cho khuôn mặt chính diện và sử dụng các đặc trưng hình chữ nhật theo một số hướng cố định. Khả năng xử lý khuôn mặt nhỏ, quay nghiêng, che khuất hoặc có chiếu sáng phức tạp vì vậy

cần được đánh giá bằng thực nghiệm trên dữ liệu phù hợp với bài toán.

0.3.2 MTCNN

MTCNN kết hợp phát hiện và căn chỉnh khuôn mặt bằng ba mạng tích chập nối tiếp gồm P-Net, R-Net và O-Net [?]. P-Net quét tháp ảnh đa tỷ lệ để sinh nhanh các vùng ứng viên. R-Net loại thêm vùng sai và hiệu chỉnh khung bao. O-Net thực hiện quyết định cuối, tiếp tục hiệu chỉnh khung bao và dự đoán năm điểm mốc khuôn mặt. Ở mỗi tầng, thuật toán loại bỏ không cực đại (NMS) loại các khung bao có mức chồng lấn cao.



Hình 0.4: Luồng xử lý ba tầng của MTCNN, tổng hợp từ [?]

Khác với bộ phân loại xếp tầng dùng đặc trưng Haar, các đặc trưng của MTCNN được học từ dữ liệu; ba nhiệm vụ phân loại khuôn mặt, hồi quy khung bao và định vị điểm mốc được tối ưu đồng thời. Cơ chế nhiều tầng giúp giảm dần số vùng cần xử lý, nhưng tháp ảnh và nhiều lượt suy luận nối tiếp có thể tạo độ trễ đáng kể.

0.3.3 RetinaFace

RetinaFace là bộ phát hiện một giai đoạn: thay vì dùng nhiều mạng nối tiếp như MTCNN, RetinaFace chỉ đưa ảnh qua một mạng duy nhất và nhận về kết quả ngay [?]. Mạng này tạo ra các bản đồ đặc trưng ở nhiều kích thước khác nhau; bản đồ lớn giúp phát hiện khuôn mặt nhỏ, bản đồ nhỏ giúp phát hiện khuôn mặt lớn. Tại mỗi vị trí trên các bản đồ đặc trưng, mô hình dự đoán đồng thời ba thông tin: khuôn mặt hay không, vị trí khung bao và năm điểm mốc. Việc dự đoán cả ba cùng lúc giúp các nhiệm vụ bổ trợ lẫn nhau: thông tin điểm mốc cung cấp ràng buộc hình học, giúp khung bao chính xác hơn. Sau khi dự đoán trên toàn ảnh, các khung bao có điểm tin cậy thấp bị loại bỏ và thuật toán loại bỏ không cực đại (NMS) giữ lại phát hiện tốt nhất cho mỗi khuôn mặt.

0.3.4 So sánh về nguyên lý

Bảng ?? tổng hợp sự khác biệt cần thiết cho bài toán. Bảng không xếp hạng phương pháp theo tài liệu, bởi kết quả công bố ở các nghiên cứu khác nhau có thể sử dụng dữ liệu, phần cứng và cấu hình không đồng nhất.

Bảng 1: So sánh nguyên lý của các phương pháp phát hiện khuôn mặt

Phương pháp	Cơ sở chính	Đầu ra	Đặc điểm cần kiểm chứng
Haar Cascade	Đặc trưng dạng Haar, ảnh tích phân, AdaBoost và bộ phân loại xếp tầng	Khung bao	Khả năng xử lý mặt nhỏ, mặt nghiêng, che khuất và nền phức tạp
MTCNN	Chuỗi CNN ba tầng và học đa nhiệm	Khung bao, năm điểm mốc	Chất lượng định vị và độ trễ của chuỗi ba mạng trên tháp ảnh
RetinaFace	Phát hiện một giai đoạn, đặc trưng đa mức và học đa nhiệm	Khung bao, năm điểm mốc	Hiệu quả phát hiện trên các mức độ khó so với chi phí suy luận

0.4 Các phương pháp phân loại biểu cảm

Sau khi khuôn mặt được phát hiện và chuẩn hóa, bài toán còn lại là học hàm phân loại từ ảnh khuôn mặt sang bảy lớp. Các hướng tiếp cận có thể chia thành phương pháp dựa trên đặc trưng thủ công và phương pháp học đặc trưng bằng mạng nơ-ron sâu. Các kiến trúc như VGG, ResNet hoặc EfficientNet đóng vai trò mạng nền trong nhóm học sâu, không phải những bước độc lập của quy trình. Tương tự, thư viện tích hợp nhiều mô hình chỉ là lớp phần mềm hỗ trợ suy luận, không phải một phương pháp phân loại.

0.4.1 Đặc trưng thủ công kết hợp bộ phân loại

Mẫu nhị phân cục bộ (LBP) mã hóa quan hệ cường độ giữa một điểm ảnh trung tâm và các điểm lân cận thành mẫu nhị phân; biểu đồ tần suất của các mẫu mô tả kết cấu cục bộ [?]. Biểu đồ hướng gradient (HOG) biểu diễn phân bố hướng biến thiên cường độ trong các ô cục bộ và chuẩn hóa theo từng khối [?]. Đối với FER, các đặc trưng này có thể mô tả nếp nhăn, biên môi, hướng lông mày và biến đổi cục bộ quanh mắt. Véc-tơ đặc trưng sau đó được đưa vào bộ phân loại như máy véc-tơ hỗ trợ (SVM).

Ưu điểm của hướng tiếp cận này là quy trình rõ ràng, mô hình nhỏ và chi phí huấn luyện thấp. Tuy nhiên, đặc trưng được thiết kế cố định nên khó thích nghi với đồng thời nhiều biến thiên về góc mặt, danh tính, che khuất và ánh sáng. Hiệu quả của LBP/HOG kết hợp bộ phân loại vì thế cần được kiểm chứng bằng thực nghiệm trên cùng dữ liệu và cùng tiêu chí đánh giá.

0.4.2 Mạng nơ-ron tích chập

Mạng nơ-ron tích chập (CNN) học các bộ lọc trực tiếp từ dữ liệu. Các tầng đầu thường phản ứng với cạnh và kết cấu đơn giản; các tầng sâu hơn kết hợp chúng thành cấu trúc có mức trừu tượng cao hơn [?]. Đối với FER, cơ chế này cho phép mô hình học đồng thời những thay đổi quanh mắt, lông mày, mũi và miệng thay

vì phụ thuộc vào một bộ mô tả cố định. Phép gộp hoặc phép giảm kích thước làm tăng vùng cảm thụ và giảm chi phí, trong khi đầu phân loại chuyển đặc trưng cuối thành các giá trị đầu ra z_k .

Xác suất của lớp k thường được tính bằng hàm softmax:

$$p_k = \frac{\exp(z_k)}{\sum_{j=1}^K \exp(z_j)}, \quad K = 7. \quad (5)$$

Trong huấn luyện phân loại một nhãn, hàm mất mát entropy chéo cho một mẫu có nhãn thật y là

$$\mathcal{L} = -\log p_y. \quad (6)$$

Các công thức trên mô tả đầu ra phân loại xác suất phổ biến của mạng sâu [?]. Trong dữ liệu FER tự nhiên, thách thức không chỉ nằm ở kiến trúc mà còn ở số lượng mẫu, mất cân bằng lớp, nhãn mơ hồ và các biến thiên không liên quan tới biểu cảm. Tổng quan của Li và Deng chỉ ra rằng thiếu dữ liệu huấn luyện và ảnh hưởng của tư thế, chiếu sáng, danh tính là những vấn đề chính của FER dựa trên học sâu [?]. Do đó, độ chính xác công bố của một mô hình trên một tập dữ liệu không được dùng trực tiếp để suy ra hiệu quả trong bối cảnh camera bán lẻ.

0.4.3 Học chuyển giao

Học chuyển giao sử dụng tri thức học được từ miền nguồn để hỗ trợ nhiệm vụ ở miền đích, đặc biệt khi dữ liệu gán nhãn của miền đích còn hạn chế [?]. Với FER, mạng nền có thể được khởi tạo từ mô hình đã học trên tập ảnh lớn hoặc tập khuôn mặt, sau đó thay đầu phân loại bằng đầu ra bảy lớp. Hai cách sử dụng phổ biến là cố định phần lớn mạng nền để trích xuất đặc trưng hoặc tinh chỉnh một phần hay toàn bộ mạng trên dữ liệu biểu cảm.

Hướng tiếp cận này giảm nhu cầu huấn luyện từ đầu. Tuy nhiên, lợi ích phụ thuộc độ gần giữa miền nguồn và miền đích. Ảnh biểu cảm được cắt sẵn trong bộ dữ liệu có thể khác đáng kể ảnh camera về khoảng cách, chất lượng, góc nhìn và phân bố người dùng; đây là hiện tượng dịch chuyển miền. Vì vậy, hiệu quả của kiến trúc và bộ trọng số dùng cho bước FER cần được kiểm chứng trên cùng tập kiểm thử, cùng bộ phát hiện và cùng quy trình tiền xử lý.

0.5 Cơ sở phân tích hành trình cảm xúc đa điểm chạm

0.5.1 Hành trình khách hàng và điểm chạm


Hành trình khách hàng mô tả chuỗi tương tác của khách hàng với doanh nghiệp qua nhiều giai đoạn, kênh và điểm chạm theo thời gian. Lemon và Verhoef nhấn mạnh rằng trải nghiệm khách hàng mang tính động và được hình thành qua nhiều điểm chạm, thay vì chỉ tại một giao dịch đơn lẻ [?]. Điểm chạm có thể là lần khách hàng tiếp xúc với không gian, nhân viên, sản phẩm hoặc hệ thống của doanh nghiệp. Trong bối cảnh bán lẻ của luận văn, camera tại từng khu vực cung cấp một nguồn quan sát biểu cảm tương ứng với điểm chạm, nhưng không tự mô tả toàn bộ trải nghiệm tại khu vực đó.

Halvorsrud, Kvale và Følstad đề xuất khung phân tích hành trình khách hàng, trong đó quá trình cung cấp dịch vụ từ góc nhìn khách hàng được biểu diễn bằng các điểm chạm có thứ tự. Cách biểu diễn này hỗ trợ so sánh hành trình dự kiến với hành trình thực tế [?]. Cơ sở trên phù hợp để đặt các kết quả FER theo trục thời gian. Việc xác định tên khu vực, định danh phiên và liên kết quan sát giữa camera là phần thiết kế của hệ thống, không phải nội dung được suy ra trực tiếp từ khung lý thuyết.

0.5.2 Quan sát tại điểm chạm đến chuỗi biểu cảm

Một kết quả FER tại một thời điểm được xem là một quan sát gồm điểm chạm, thời gian, nhãn biểu cảm và véc-tơ xác suất. Nếu tại một điểm chạm có nhiều khung hình liên tiếp, các dự đoán này chưa thể được xem ngay là nhiều trải nghiệm độc lập, bởi chúng có tương quan theo thời gian và có thể dao động do tư thế hoặc chất lượng ảnh. Cách chọn khung hình, lọc dự đoán độ tin cậy thấp và ổn định nhãn trong một khoảng thời gian phải được mô tả như phương pháp xử lý của luận văn ở chương triển khai.

Sau khi có một quan sát đại diện cho từng điểm chạm, hành trình có thể được tổ chức thành chuỗi theo thời gian như Hình ???. Hình chỉ minh họa cách đặt quan sát FER theo thứ tự; nhãn trong một hành trình thực tế phải do quy trình xử lý suy luận từ dữ liệu.



Hình 0.5: Minh họa chuỗi quan sát biểu cảm theo hành trình đa điểm chạm

Từ chuỗi này, ta có thể thống kê phân bố lớp biểu cảm tại từng điểm chạm, đếm chuyển đổi giữa hai điểm chạm liên tiếp, xác định vị trí thường bắt đầu xuất hiện

biểu cảm tiêu cực và phân tích các trường hợp thiếu quan sát. Cách tiếp cận theo chuỗi giữ lại thứ tự của sự kiện, trong khi một tỷ lệ tổng hợp trên toàn hành trình có thể che mất vị trí xảy ra thay đổi.