ĐẠI HỌC BÁCH KHOA HÀ NỘI

LUẬN VĂN THẠC SĨ

Nhận dạng và liên kết biểu cảm khuôn mặt theo hành trình đa điểm chạm, tích hợp vào hệ thống CRM

ĐOÀN ĐỨC CƯƠNG
cuong.dd232040M@sis.hust.edu.vn

Chương trình đào tạo: Công nghệ thông tin

Giảng viên hướng dẫn: TS. Phạm Ngọc Hưng

Khoa: Kỹ thuật máy tính

Trường: Công nghệ thông tin và Truyền thông

HÀ NỘI, 10/2026

LỜI CAM ĐOAN

Tôi xin cam đoan các nội dung trong luận văn với đề tài là "Nhận dạng và liên kết biểu cảm khuôn mặt theo hành trình đa điểm chạm, tích hợp vào hệ thống CRM" là công trình nghiên cứu của bản thân tôi dưới sự hướng dẫn của TS. Phạm Ngọc Hưng. Các kết quả nêu trong Luận văn là trung thực, là thành quả của riêng tôi, không sao chép theo bất kỳ công trình nào khác. Tất cả những tham khảo trong Luận văn – bao gồm hình ảnh, bảng biểu, số liệu, và các câu từ trích dẫn – đều được ghi rõ ràng và đầy đủ nguồn gốc trong danh mục tài liệu tham khảo. Tôi xin hoàn toàn chịu trách nhiệm với dù chỉ một sao chép vi phạm quy chế của nhà trường.

Hà Nội, ngày tháng năm

Học viên

Đoàn Đức Cương

LỜI CẢM ƠN

Trong suốt quá trình nghiên cứu và thực hiện luận văn, tôi đã nhận được rất nhiều sự quan tâm, hướng dẫn và giúp đỡ tận tình của thầy, cô giáo cùng các bạn học đồng trang lứa.

Lời đầu tiên tôi xin được gửi lời cảm ơn sâu sắc tới Ban giám hiệu Đại học Bách Khoa Hà Nội nói chung, Ban giám hiệu Trường Công nghệ Thông tin và Truyền thông nói riêng đã tạo cho tôi một môi trường học tập chuyên nghiệp, hiệu quả và thân thiện.

Đặc biệt, tôi xin được bày tỏ lòng biết ơn chân thành đến TS. Phạm Ngọc Hưng, Khoa Kỹ thuật máy tính, Trường Công nghệ Thông tin và Truyền thông, người đã trực tiếp hướng dẫn, giúp đỡ và đưa ra những lời khuyên, góp ý vô cùng hữu ích trong suốt quá trình thực hiện.

Tôi cũng xin bày tỏ lời cảm ơn sâu sắc đến gia đình, bạn bè, người thân và đồng nghiệp đã động viên, giúp đỡ tôi hoàn thành luận văn này.

Tôi xin trân trọng cảm ơn!

Tóm tắt nội dung luận văn

Trong hoạt động bán lẻ, việc nhận biết trải nghiệm của khách hàng tại nhiều điểm chạm có ý nghĩa đối với đánh giá chất lượng phục vụ. Các hình thức khảo sát trực tiếp hoặc sau giao dịch có thể làm gián đoạn quá trình mua sắm, có tỷ lệ phản hồi thấp và chịu ảnh hưởng của thiên lệch khảo sát. Nhận dạng biểu cảm khuôn mặt cho phép ghi nhận nhãn biểu cảm từ hình ảnh, nhưng một quan sát riêng lẻ chưa thể mô tả toàn bộ hành trình. Luận văn đề xuất quy trình liên kết kết quả xử lý ảnh với danh tính khách hàng, thời gian và điểm chạm để hình thành chuỗi trạng thái biểu cảm trong từng lần mua sắm. Các chuỗi được sử dụng để thống kê, nhận diện kiểu diễn biến và truy vết về dữ liệu CRM, không thay thế khảo sát trực tiếp hoặc dùng để đánh giá độ hài lòng khách hàng.

Đóng góp về mặt phương pháp là quy trình tổ chức và phân tích dữ liệu biểu cảm có bảo toàn thứ tự giữa các điểm chạm. Ảnh đầu vào được phát hiện khuôn mặt, phân loại biểu cảm, tạo đặc trưng nhận dạng và đối sánh với mẫu đã đăng ký để tạo bản ghi quan sát. Các bản ghi được liên kết theo khách hàng và lần mua sắm, xử lý dữ liệu thiếu, trùng hoặc xung đột thời gian, rồi lựa chọn nhãn đại diện tại mỗi đoạn điểm chạm để tạo chuỗi. Luận văn kết hợp thống kê phân bố và sự thay đổi biểu cảm với Optimal Matching để đo độ khác biệt giữa các chuỗi, PAM để phân cụm và Average Silhouette Width để lựa chọn số cụm. Kết quả gồm chuỗi medoid, quy mô, tỷ lệ, mức độ phù hợp của thành viên và liên kết truy vết về quan sát ban đầu.

Về mặt thực tiễn và kỹ thuật, luận văn xây dựng một hệ thống thử nghiệm tích hợp quản lý CRM, xử lý ảnh và phân tích chuỗi biểu cảm tại nhiều điểm chạm. Để kiểm nghiệm luồng xử lý, luận văn xây dựng một bộ dữ liệu camera thử nghiệm từ các ảnh thuộc tập KDEF, được phát lại theo lịch định trước và gắn với các điểm chạm tương ứng. Hệ thống được kiểm nghiệm từ các thành phần phát hiện khuôn mặt, nhận dạng khách hàng, phân loại biểu cảm và phân cụm chuỗi đến toàn bộ luồng xử lý đầu cuối. Kết quả cho thấy giải pháp có thể tiếp nhận dữ liệu ảnh, liên kết các quan sát theo từng lần mua sắm, hình thành chuỗi trạng thái và cung cấp kết quả phân tích có khả năng truy vết.

MỤC LỤC

DANH MỤC HÌNH VẼ ..... **v**

DANH MỤC BẢNG BIỂU ..... **vi**

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT ..... **vii**

CHƯƠNG 1. GIỚI THIỆU LUẬN VĂN **1**

1.1 Đặt vấn đề 1

1.2 Mục tiêu và định hướng giải pháp 2

1.3 Đóng góp của luận văn 2

1.4 Kết cấu của luận văn 3

CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT VÀ CÔNG NGHỆ **5**

2.1 Bối cảnh bài toán 5

2.2 Cơ sở lý thuyết về nhận dạng biểu cảm khuôn mặt 6

2.2.1 Cảm xúc, biểu cảm khuôn mặt và bài toán FER 6

2.2.2 Quy trình FER tổng quát 7

2.3 Các phương pháp phát hiện khuôn mặt 8

2.3.1 Haar Cascade theo Viola–Jones 9

2.3.2 MTCNN 10

2.3.3 RetinaFace 14

2.3.4 So sánh giữa các phương pháp 15

2.4 Các phương pháp phân loại biểu cảm 16

2.4.1 Phân loại biểu cảm bằng LBP kết hợp SVM 16

2.4.2 Phân loại biểu cảm bằng mạng nơ-ron tích chập 18

2.4.3 Học chuyển giao trong phân loại biểu cảm 19

2.5 Cơ sở phân tích quan sát biểu cảm theo hành trình đa điểm chạm 20

2.5.1 Hành trình khách hàng và điểm chạm 20

2.5.2 Quan sát tại điểm chạm đến chuỗi biểu cảm 21
CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT 26
3.1 Tổng quan phương pháp 26
3.2 Phương pháp hình thành bản ghi tại các điểm chạm 27
3.2.1 Xác định dữ liệu đầu vào và ngữ cảnh điểm chạm 27
3.2.2 Phát hiện và trích xuất vùng khuôn mặt 28
3.2.3 Xác định nhãn biểu cảm của quan sát 29
3.2.4 Xác định khách hàng bằng đối sánh khuôn mặt 29
3.2.5 Kết hợp kết quả thành bản ghi tại điểm chạm 30
3.3 Cơ chế liên kết chuỗi biểu cảm 31
3.3.1 Nguyên tắc phân tách bản ghi theo khách hàng và lần mua sắm 31
3.3.2 Xử lý quan sát thiếu hoặc xung đột 32
3.3.3 Gom quan sát thành các chuỗi dữ liệu tại điểm chạm 32
3.3.4 Tiêu chí lựa chọn nhãn biểu cảm đại diện 33
3.4 Phương pháp phân tích 33
3.4.1 Phân tích phân bố và thay đổi biểu cảm theo điểm chạm 34
3.4.2 Phân cụm chuỗi trạng thái và lựa chọn số cụm 35
CHƯƠNG 4. XÂY DỰNG VÀ PHÁT TRIỂN HỆ THỐNG 36
4.1 Tổng quan hệ thống 36
4.2 Cài đặt hệ thống 37
4.2.1 Usecase tổng quan 37
4.2.2 Phân rã chức năng 38
4.2.3 Đặc tả chức năng 39
4.3 Giao diện ứng dụng 41

CHƯƠNG 5. ĐÁNH GIÁ THỰC NGHIỆM 53

5.1 Thực nghiệm so sánh các phương pháp phát hiện khuôn mặt 53

5.1.1 Tập dữ liệu và giao thức đánh giá 53

5.1.2 Kết quả thực nghiệm so sánh..... 56

5.1.3 Nhận xét từ kết quả thực nghiệm 57

5.2 Thực nghiệm so sánh các phương pháp phân loại biểu cảm 57

5.2.1 Mục tiêu thực nghiệm..... 57

5.2.2 Tập dữ liệu và giao thức đánh giá 58

5.2.3 Tiêu chí đánh giá..... 60

5.2.4 Kết quả thực nghiệm 60

5.2.5 Phạm vi diễn giải và giới hạn 63

5.3 Thiết kế thực nghiệm đánh giá hệ thống đầu cuối 64

5.3.1 Dữ liệu và khởi tạo hồ sơ khách hàng 64

5.3.2 Nguyên tắc xây dựng dữ liệu camera thử nghiệm..... 65

5.4 Triển khai và kết quả thực nghiệm đầu cuối 66

5.4.1 Môi trường và trình tự thực hiện..... 66

5.4.2 Kết quả tiếp nhận ảnh và liên kết hành trình 67

5.4.3 Đánh giá hiệu quả phân loại biểu cảm trong luồng đầu cuối 69

5.4.4 Kết quả tạo và phân cụm chuỗi trạng thái 70

5.5 Đánh giá hiệu quả hệ thống 73

TÀI LIỆU THAM KHẢO 76

DANH MỤC HÌNH VẼ

Hình 2.1 Bảy biểu cảm khuôn mặt 7
Hình 2.2 Quy trình tổng quát của hệ thống FER dựa trên học sâu . . . 8
Hình 2.3 Kiến trúc P-Net của MTCNN 11
Hình 2.4 Kiến trúc R-Net của MTCNN 12
Hình 2.5 Kiến trúc O-Net của MTCNN 12
Hình 2.6 Quy trình phát hiện khuôn mặt của MTCNN 13
Hình 2.7 Quy trình tạo véc-tơ đặc trưng LBP theo vùng 17
Hình 2.8 Nhiều quan sát trong từng điểm chạm của một lần mua sắm 21

Hình 3.1 Ba giai đoạn của phương pháp đề xuất 26
Hình 3.2 Quy trình phát hiện, cắt và căn chỉnh vùng khuôn mặt 29
Hình 3.3 Thứ tự ưu tiên khi lựa chọn nhãn biểu cảm đại diện 33

Hình 4.1 Kiến trúc tổng quan của hệ thống 36
Hình 4.2 Usecase tổng quan của hệ thống 38
Hình 4.3 Phân rã chức năng của hệ thống 38
Hình 4.4 Giao diện đăng nhập 42
Hình 4.5 Giao diện tổng quan hệ thống 43
Hình 4.6 Giao diện danh sách khách hàng 43
Hình 4.7 Giao diện hồ sơ và lịch sử mua hàng của khách hàng 44
Hình 4.8 Giao diện đăng ký và tìm kiếm khách hàng bằng khuôn mặt 44
Hình 4.9 Giao diện quản lý sản phẩm 45
Hình 4.10 Giao diện lịch sử mua hàng 45
Hình 4.11 Giao diện quản lý điểm chạm 46
Hình 4.12 Giao diện theo dõi lần mua sắm 46
Hình 4.13 Giao diện chi tiết bản ghi quan sát 47
Hình 4.14 Giao diện thống kê phân bố biểu cảm tại điểm chạm 48
Hình 4.15 Giao diện phân tích thay đổi biểu cảm giữa các điểm chạm . 49
Hình 4.16 Giao diện báo cáo chất lượng dữ liệu 50
Hình 4.17 Giao diện tổng quan kết quả phân cụm chuỗi 51
Hình 4.18 Giao diện danh sách cụm và chuỗi medoid 51
Hình 4.19 Giao diện danh sách lần mua sắm được gán cụm 52

Hình 5.1 Normalized Confusion Matrix của ba cấu hình trên PrivateTest 62
Hình 5.2 Danh sách năm hồ sơ khách hàng sau khi khởi tạo từ ảnh KDEF 64

Hình 5.3 Trạng thái các thành phần của hệ thống tại thời điểm thực nghiệm 67
Hình 5.4 Một lần mua sắm có đủ bốn điểm chạm sau khi xử lý ảnh . . 68
Hình 5.5 Các quan sát nguồn Camera được sắp theo thời gian trong một lần mua sắm 69
Hình 5.6 Ma trận nhầm lẫn biểu cảm trên 100 ảnh của lần chạy đầu cuối 70
Hình 5.7 Kết quả lựa chọn số cụm từ 23 chuỗi trạng thái trên giao diện 71
Hình 5.8 Medoid và thống kê của ba cụm trên giao diện hệ thống . . . 72
Hình 5.9 Danh sách các lần mua sắm được gán cụm 72
Hình 5.10 Truy vết một kết quả gán cụm về các quan sát ban đầu . . . 73

DANH MỤC BẢNG BIỂU

Bảng 2.1 So sánh giữa các phương pháp phát hiện khuôn mặt 16

Bảng 3.1 Phạm vi của từng giai đoạn trong phương pháp 27
Bảng 3.2 Thông tin được giữ trong một bản ghi quan sát 31

Bảng 4.1 Các thành phần của hệ thống 37
Bảng 4.2 Đặc tả UC01 – Đăng nhập 39
Bảng 4.3 Đặc tả UC02 – Quản lý khách hàng và dữ liệu khuôn mặt . . 39
Bảng 4.4 Đặc tả UC03 – Quản lý sản phẩm, đơn hàng và điểm chạm . 40
Bảng 4.5 Đặc tả UC04 – Tiếp nhận ảnh và tạo bản ghi quan sát 40
Bảng 4.6 Đặc tả UC05 – Theo dõi lần mua sắm 41
Bảng 4.7 Đặc tả UC06 – Phân tích biểu cảm và phân cụm chuỗi . . . 41

Bảng 5.1 Kết quả chất lượng phát hiện trên tập xác thực WIDER FACE 57
Bảng 5.2 Kết quả hiệu năng phát hiện trên CPU 57
Bảng 5.3 Phân bố ảnh theo lớp trong FER-2013 58
Bảng 5.4 Kết quả tổng thể của ba cấu hình phân loại biểu cảm trên PrivateTest 60
Bảng 5.5 F1 theo từng lớp của ba cấu hình trên PrivateTest 61
Bảng 5.6 Môi trường triển khai tại thời điểm thực nghiệm đầu cuối . . 66
Bảng 5.7 Kết quả tiếp nhận và ghép định danh ảnh KDEF 68
Bảng 5.8 Kết quả biểu cảm của dữ liệu trong luồng đầu cuối 69
Bảng 5.9 Kết quả phân cụm 23 chuỗi trạng thái dự đoán đủ điều kiện 71
Bảng 5.10 Đánh giá hiệu quả của luồng hệ thống đầu cuối 74

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Thuật ngữ	Ý nghĩa
AI	Trí tuệ nhân tạo (Artificial Intelligence)
AP	Độ chính xác trung bình (Average Precision)
API	Giao diện lập trình ứng dụng (Application Programming Interface)
AU	Đơn vị hành động khuôn mặt (Action Unit)
CNN	Mạng nơ-ron tích chập (Convolutional Neural Network)
CPU	Bộ xử lý trung tâm (Central Processing Unit)
CRM	Quản lý quan hệ khách hàng (Customer Relationship Management)
CX	Trải nghiệm khách hàng (Customer Experience)
F1	Điểm F1, trung bình điều hòa của độ chính xác và độ bao phủ
FACS	Hệ thống mã hóa hành động khuôn mặt (Facial Action Coding System)
FER	Nhận dạng biểu cảm khuôn mặt (Facial Expression Recognition)
FN	Số trường hợp âm tính giả (False Negative)
FP	Số trường hợp dương tính giả (False Positive)
FPS	Số khung hình xử lý trong một giây (Frames Per Second)
HOG	Biểu đồ hướng gradient (Histogram of Oriented Gradients)
IoU	Tỷ lệ phần giao trên phần hợp (Intersection over Union)
LBP	Mẫu nhị phân cục bộ (Local Binary Pattern)

Thuật ngữ	Ý nghĩa
MTCNN	Mạng tích chập xếp tầng đa nhiệm (Multi-task Cascaded Convolutional Networks)
NMS	Loại bỏ các dự đoán cực đại không cần thiết (Non-Maximum Suppression)
OpenCV	Thư viện thị giác máy tính mã nguồn mở (Open Source Computer Vision Library)
P95	Phân vị thứ 95 (95th Percentile)
RAM	Bộ nhớ truy cập ngẫu nhiên (Random Access Memory)
SMS	Dịch vụ tin nhắn ngắn (Short Message Service)
SVM	Máy véc-tơ hỗ trợ (Support Vector Machine)
TP	Số trường hợp dương tính đúng (True Positive)
VGG	Họ kiến trúc mạng tích chập của Visual Geometry Group

CHƯƠNG 1. GIỚI THIỆU LUẬN VĂN

1.1 Đặt vấn đề

Trong quá trình chuyển đổi số và phát triển bán lẻ đa nền tảng, khả năng thấu hiểu hành vi cũng như trải nghiệm khách hàng (Customer Experience – CX) ngày càng có vai trò quan trọng đối với sự phát triển của doanh nghiệp. Để có thêm cơ sở đánh giá chất lượng phục vụ cũng như hiểu rõ hơn về khách hàng, doanh nghiệp cần thu thập các dấu hiệu quan sát và phản hồi của khách hàng tại những khu vực như cửa đón tiếp, khu vực chờ, quầy tư vấn, khu trưng bày sản phẩm và quầy thanh toán.

Tuy nhiên, các phương pháp khảo sát truyền thống đang bộc lộ nhiều hạn chế lớn:

- **Có thể gây bất tiện và làm gián đoạn quá trình mua sắm:** Việc yêu cầu khách hàng điền phiếu đánh giá hoặc thực hiện khảo sát tại chỗ có thể gây khó chịu và làm giảm sự hứng thú trong quá trình mua sắm.
- **Thời gian tiếp nhận thông tin dài và tỷ lệ phản hồi thấp:** Các hình thức khảo sát sau giao dịch qua tin nhắn SMS, thư điện tử hoặc ứng dụng di động thường có tỷ lệ phản hồi thấp và cần nhiều thời gian để tổng hợp. Vì vậy, nhân viên và người quản lý khó phát hiện kịp thời những trường hợp khách hàng có trải nghiệm không tốt.
- **Tính thiên lệch của kết quả khảo sát (Survey Bias):** Khách hàng thường chỉ chủ động phản hồi khi có trải nghiệm rất tiêu cực. Vì vậy, kết quả có thể không phản ánh đầy đủ ý kiến của phần lớn khách hàng.

Sự phát triển của trí tuệ nhân tạo (AI) và thị giác máy tính (Computer Vision) tạo điều kiện ứng dụng công nghệ nhận dạng biểu cảm khuôn mặt (Facial Expression Recognition – FER) vào bài toán trên. Thông qua phân tích hình ảnh khuôn mặt, hệ thống có thể ghi nhận các nhãn biểu cảm quan sát được của khách hàng mà không làm gián đoạn quá trình trải nghiệm của khách hàng. Tuy nhiên, nhãn FER chỉ phản ánh biểu hiện khuôn mặt tại thời điểm hình ảnh được thu nhận. Vì vậy, một quan sát riêng lẻ chưa đủ để mô tả toàn bộ quá trình của khách hàng.

Hạn chế của việc phân tích từng quan sát riêng lẻ đặt ra yêu cầu liên kết các kết quả phân loại biểu cảm theo khách hàng, lần mua sắm, khu vực và thứ tự thời gian để hình thành chuỗi trạng thái biểu cảm. Việc phân tích các chuỗi này cần bảo toàn cả thành phần và thứ tự xuất hiện của các nhãn, đồng thời cho phép truy vết kết quả về hồ sơ khách hàng và lịch sử mua hàng trong hệ thống CRM. Tuy nhiên, các

kiểu diễn biến thu được chỉ mô tả những nhãn biểu cảm đã ghi nhận, không trực tiếp phản ánh hành vi hoặc mức độ hài lòng của khách hàng. Đây là khoảng trống mà định hướng giải pháp của luận văn tập trung giải quyết.

1.2 Mục tiêu và định hướng giải pháp

Mục tiêu tổng quát của luận văn là nghiên cứu, đề xuất và kiểm nghiệm một quy trình thu nhận, tổ chức và phân tích các nhãn biểu cảm khuôn mặt của khách hàng tại nhiều điểm chạm trong một lần mua sắm. Quy trình cần liên kết được kết quả xử lý ảnh với danh tính khách hàng, thời gian và khu vực quan sát; từ đó hình thành chuỗi trạng thái có thể thống kê, phân cụm và truy vết về dữ liệu nghiệp vụ trong hệ thống CRM. Kết quả hướng tới hỗ trợ người quản lý quan sát các kiểu diễn biến biểu cảm trong hành trình mua sắm, không thay thế khảo sát trực tiếp và không tự suy diễn mức độ hài lòng của khách hàng.

Để đạt được mục tiêu trên, giải pháp được định hướng theo bốn nội dung chính:

- **Hình thành bản ghi quan sát tại điểm chạm:** Tiếp nhận ảnh cùng thông tin điểm chạm và thời gian; phát hiện khuôn mặt, phân loại biểu cảm, tạo đặc trưng nhận dạng và đối sánh với dữ liệu khuôn mặt đã đăng ký. Kết quả được chuẩn hóa thành bản ghi quan sát có danh tính và ngữ cảnh xác định.
- **Liên kết các quan sát thành chuỗi trạng thái:** Nhóm các bản ghi theo khách hàng và lần mua sắm, sắp xếp theo thời gian và thứ tự điểm chạm, đồng thời thiết lập quy tắc xử lý dữ liệu thiếu, quan sát trùng hoặc xung đột thời gian. Tại mỗi đoạn điểm chạm, một nhãn đại diện được lựa chọn nhất quán để tạo chuỗi đầu vào cho bước phân tích.
- **Phân tích diễn biến biểu cảm tại nhiều điểm chạm:** Thống kê phân bố và sự thay đổi của các nhãn biểu cảm giữa các điểm chạm; sử dụng Optimal Matching để đo độ khác biệt giữa các chuỗi, PAM để phân cụm và Average Silhouette Width để hỗ trợ lựa chọn số cụm. Mỗi cụm được mô tả bằng chuỗi medoid, quy mô, tỷ lệ và mức độ phù hợp của các thành viên.
- **Xây dựng và kiểm nghiệm hệ thống tích hợp:** Kết hợp dịch vụ xử lý ảnh, máy chủ nghiệp vụ, cơ sở dữ liệu và giao diện quản lý để lưu trữ dữ liệu CRM, theo dõi lần mua sắm và hiển thị kết quả phân tích. Các thành phần xử lý ảnh, phương pháp phân cụm và luồng đầu cuối được kiểm nghiệm bằng các bộ dữ liệu công khai, dữ liệu kiểm soát và kịch bản kiểm nghiệm đầu cuối.

1.3 Đóng góp của luận văn

Đóng góp về mặt phương pháp của luận văn thể hiện qua việc đề xuất một quy trình tổ chức và phân tích dữ liệu biểu cảm gắn với hành trình khách hàng tại nhiều

điểm chạm. Luận văn xây dựng cơ chế chuyển kết quả xử lý ảnh thành các bản ghi quan sát có danh tính, thời gian và điểm chạm, sau đó liên kết các bản ghi theo từng lần mua sắm để hình thành chuỗi trạng thái biểu cảm. Quy trình xác định rõ điều kiện sử dụng nhãn, cách lựa chọn nhãn đại diện tại mỗi đoạn điểm chạm và nguyên tắc xử lý dữ liệu thiếu, quan sát trùng hoặc xung đột thời gian trước khi tạo chuỗi. Trên cơ sở dữ liệu đã được tổ chức, luận văn kết hợp thống kê tại điểm chạm với Optimal Matching, PAM và Average Silhouette Width để nhận diện các kiểu diễn biến có bảo toàn thứ tự. Kết quả phân tích không chỉ cung cấp mã cụm mà còn bao gồm chuỗi medoid, quy mô, tỷ lệ, silhouette và liên kết truy vết về lần mua sắm cùng các quan sát ban đầu. Đóng góp phương pháp cốt lõi nằm ở cách kết hợp các thành phần thành một quy trình nhất quán, có thể kiểm tra và truy vết, không phải ở việc đề xuất thuật toán mới thay thế các phương pháp đã sử dụng.

Về mặt thực tiễn và kỹ thuật, luận văn đã thiết kế và xây dựng một hệ thống thử nghiệm tích hợp giao diện web, máy chủ nghiệp vụ, dịch vụ xử lý ảnh và cơ sở dữ liệu. Hệ thống cho phép quản lý khách hàng, mẫu khuôn mặt, điểm chạm, sản phẩm và đơn hàng; tiếp nhận dữ liệu ảnh; nhận dạng khách hàng; ghi nhận biểu cảm và hình thành các lần mua sắm. Đóng góp kỹ thuật chính nằm ở việc liên kết dữ liệu CRM với kết quả xử lý ảnh và mô-đun phân tích chuỗi, qua đó cung cấp các báo cáo về phân bố biểu cảm, sự thay đổi giữa các điểm chạm và kết quả phân cụm, đồng thời cho phép truy vết từ cụm về chuỗi, lần mua sắm và từng bản ghi quan sát. Hệ thống và quy trình đề xuất được kiểm nghiệm thông qua các thực nghiệm so sánh phương pháp phát hiện khuôn mặt, phân loại biểu cảm, dữ liệu chuỗi có cấu trúc biết trước và kịch bản xử lý đầu cuối từ ảnh đến kết quả phân cụm. Các kết quả này cung cấp bằng chứng về khả năng vận hành của giải pháp trong phạm vi dữ liệu và điều kiện thực nghiệm đã xác định.

1.4 Kết cấu của luận văn

Luận văn được tổ chức thành năm chương với các nội dung chính như sau:

- **Chương 1 – Giới thiệu luận văn:** Trình bày bối cảnh, vấn đề nghiên cứu, hạn chế của các cách tiếp cận hiện tại, mục tiêu, định hướng giải pháp, đóng góp và kết cấu của luận văn.
- **Chương 2 – Nền tảng lý thuyết và công nghệ:** Trình bày cơ sở lý thuyết về phát hiện khuôn mặt, nhận dạng biểu cảm, nhận dạng khách hàng và phân tích hành trình tại nhiều điểm chạm; đồng thời giới thiệu các công nghệ được sử dụng trong hệ thống.
- **Chương 3 – Phương pháp đề xuất:** Mô tả phương pháp xử lý ảnh, liên kết kết quả theo khách hàng và lần mua sắm, hình thành chuỗi trạng thái biểu cảm,

phân tích dữ liệu và phân cụm chuỗi trạng thái.

- **Chương 4 – Xây dựng và phát triển hệ thống:** Trình bày kiến trúc, cơ sở dữ liệu, giao diện lập trình, các thành phần xử lý ảnh, chức năng CRM, giao diện quản lý và mô-đun phân tích chuỗi.
- **Chương 5 – Đánh giá thực nghiệm:** Trình bày các thực nghiệm so sánh phương pháp phát hiện khuôn mặt và phân loại biểu cảm, kiểm nghiệm kỹ thuật phân cụm chuỗi trạng thái và đánh giá luồng xử lý đầu cuối của hệ thống.

CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT VÀ CÔNG NGHỆ

2.1 Bối cảnh bài toán

Trong môi trường bán lẻ, quá trình mua sắm của khách hàng thường diễn ra qua nhiều khu vực như cửa vào, khu trưng bày sản phẩm, khu tư vấn và quầy thanh toán. Theo Lemon và Verhoef, hành trình mua sắm là quá trình khách hàng trải qua xuyên suốt các giai đoạn và điểm chạm, qua đó hình thành trải nghiệm khách hàng. Trải nghiệm này được tích lũy từ tập hợp các điểm chạm trong nhiều giai đoạn của quá trình ra quyết định và mua sắm [1]. Vì vậy, một kết quả nhận dạng biểu cảm tại một khu vực chỉ phản ánh một quan sát tại một điểm chạm, chưa thể hiện diễn biến biểu cảm trong toàn bộ quá trình mua sắm.

Các hệ thống CRM thường lưu trữ hồ sơ khách hàng, đơn hàng và lịch sử mua hàng. Những dữ liệu này cho biết khách hàng là ai và đã mua sản phẩm nào, nhưng chưa phản ánh được biểu cảm và phản ứng quan sát được của khách hàng trong quá trình mua sắm. Phương pháp nhận dạng biểu cảm khuôn mặt có thể bổ sung thông tin này từ hình ảnh được ghi nhận tại từng khu vực. Tuy nhiên, nếu các kết quả chỉ được lưu thành những bản ghi riêng biệt, hệ thống không xác định được chúng thuộc khách hàng nào, được tạo ra trong lần mua sắm nào và liên hệ với nhau theo thứ tự ra sao.

Halvorsrud, Kvale và Følstad cho rằng quá trình tương tác thực tế của khách hàng có thể được dựng lại từ các sự kiện quan sát được và sắp xếp theo thời gian [2]. Vận dụng cách tiếp cận này, mỗi lần mua sắm trong luận văn được biểu diễn bằng một chuỗi ghi nhận tại những khu vực được xác định từ trước. Mỗi lần ghi nhận bao gồm mã khách hàng, mã lần mua sắm, khu vực, thời gian và kết quả nhận dạng biểu cảm.

Việc liên kết các bản ghi cho phép theo dõi diễn biến biểu cảm của từng khách hàng trong một lần mua sắm. Trên cơ sở đó, dữ liệu có thể được tổng hợp để xác định biểu cảm xuất hiện phổ biến tại từng khu vực, đồng thời ghi nhận trường hợp nhãn biểu cảm được giữ nguyên hoặc thay đổi giữa hai khu vực liên tiếp. Khi kết hợp với thông tin đơn hàng và lịch sử mua hàng trong CRM, kết quả này cung cấp thêm dữ liệu để xem xét phản ứng của khách hàng trong từng giai đoạn của quá trình mua sắm.

Từ bối cảnh trên, luận văn giải quyết ba nội dung: nhận dạng biểu cảm khuôn mặt; liên kết kết quả theo khách hàng và lần mua sắm; tích hợp dữ liệu của lần mua sắm vào CRM để tra cứu và thống kê. Qua đó, kết quả từ các ảnh riêng lẻ được sắp

xếp để theo dõi diễn biến biểu cảm trong quá trình mua sắm.

2.2 Cơ sở lý thuyết về nhận dạng biểu cảm khuôn mặt

2.2.1 Cảm xúc, biểu cảm khuôn mặt và bài toán FER

Cảm xúc có thể được biểu hiện một phần qua những thay đổi trên khuôn mặt. Hoạt động của các vùng cơ làm thay đổi hình dạng và vị trí tương đối của mắt, lông mày, mũi, miệng và má. Khi khuôn mặt được ghi lại bằng ảnh, những thay đổi này tạo thành các mẫu thị giác thể hiện qua đường nét, hình dạng và sự phân bố điểm ảnh. Vì vậy, ảnh khuôn mặt có thể được sử dụng làm đầu vào để mô hình trích xuất đặc trưng và phân loại biểu cảm.

Năm 1971, Paul Ekman và Wallace V. Friesen công bố nghiên cứu *Constants Across Cultures in the Face and Emotion* nhằm kiểm tra khả năng nhận biết biểu cảm giữa các nền văn hóa. Nghiên cứu thu thập dữ liệu từ cộng đồng Fore tại New Guinea, là nhóm có mức độ tiếp xúc hạn chế với truyền thông phương Tây. Người tham gia nghe các tình huống mô tả cảm xúc và lựa chọn ảnh khuôn mặt phù hợp. Kết quả cho thấy nhiều mẫu biểu cảm được gắn với các nhóm cảm xúc tương tự giữa cộng đồng này và những nhóm đã được khảo sát trước đó; tuy nhiên, sợ hãi và ngạc nhiên có mức độ nhầm lẫn cao hơn các nhóm còn lại [3]. Kết quả này cung cấp cơ sở thực nghiệm cho việc sử dụng sáu nhóm biểu cảm gồm tức giận, ghê tởm, sợ hãi, vui vẻ, buồn bã và ngạc nhiên trong các nghiên cứu nhận dạng biểu cảm khuôn mặt.

Nhận dạng biểu cảm khuôn mặt, viết tắt là FER, là bài toán xác định lớp biểu cảm từ ảnh hoặc chuỗi ảnh khuôn mặt. Trong bài tổng quan về FER dựa trên học sâu, Shan Li và Weihong Deng trình bày các bộ dữ liệu, phương pháp xử lý ảnh tĩnh, phương pháp xử lý chuỗi ảnh và những khó khăn thường gặp. Hai tác giả chỉ ra hai nhóm vấn đề chính: hiện tượng quá khớp (overfitting) khi dữ liệu huấn luyện còn hạn chế; và các biến thiên không liên quan trực tiếp đến biểu cảm, như điều kiện chiếu sáng, tư thế đầu và đặc điểm nhận dạng của từng người [4].

Trong bài báo *Deep Facial Expression Recognition: A Survey*, công bố năm 2022, Shan Li và Weihong Deng tổng hợp quy trình của một hệ thống FER [4]. Theo hai tác giả, hệ thống FER thường gồm các bước phát hiện khuôn mặt, căn chỉnh, tiền xử lý, trích xuất đặc trưng và phân loại. Với ảnh đầu vào I, mô hình phát hiện xác định vùng khuôn mặt B. Vùng này được cắt và chuẩn hóa thành ảnh I_f. Mạng phân loại tiếp nhận I_f, trích xuất đặc trưng và tạo điểm số cho từng lớp biểu cảm. Quy trình xử lý và một số nhóm mạng sâu được minh họa ở Hình 2.2.

Đầu ra của mô hình được sử dụng trong hệ thống gồm bảy nhãn: *Angry*, *Disgust*, *Fear*, *Happy*, *Sad*, *Surprise* và *Neutral*. Sáu nhãn đầu tương ứng với sáu nhóm biểu

cảm cơ bản trong nghiên cứu của Ekman và Friesen. Nhãn *Neutral* được sử dụng theo cách phân chia bảy lớp của bộ dữ liệu FER-2013, do Pierre Luc Carrier và Aaron Courville xây dựng và được Goodfellow cùng cộng sự công bố. Nhãn này giúp mô hình xử lý những khuôn mặt không thể hiện rõ một trong sáu biểu cảm cơ bản, thay vì bắt buộc gán chúng vào một lớp biểu cảm không phù hợp [5]. Với mỗi ảnh khuôn mặt, mô hình trả về nhãn dự đoán và mức tin cậy tương ứng.



Hình 2.1: Bảy biểu cảm khuôn mặt

2.2.2 Quy trình FER tổng quát

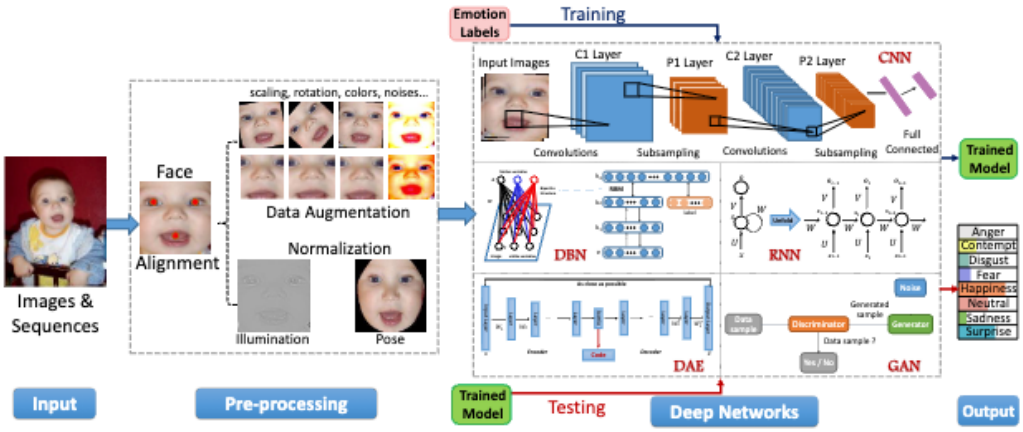
Li và Deng mô tả quy trình nhận dạng biểu cảm khuôn mặt dựa trên học sâu gồm ba giai đoạn chính: tiền xử lý ảnh khuôn mặt, học đặc trưng và phân loại biểu cảm [4]. Đối với ảnh đầu vào, bước đầu tiên là phát hiện khuôn mặt để xác định vùng ảnh chứa khuôn mặt và loại bỏ phần lớn thông tin nền không liên quan. Đây là bước cần thiết vì mô hình nhận dạng biểu cảm chỉ có thể trích xuất đặc trưng phù hợp khi vùng khuôn mặt được xác định chính xác.

Sau khi khuôn mặt được phát hiện, ảnh được căn chỉnh và chuẩn hóa. Căn chỉnh khuôn mặt dựa trên các điểm đặc trưng đã xác định nhằm giảm sự khác biệt về kích thước, vị trí và góc xoay của khuôn mặt. Chuẩn hóa ảnh tiếp tục hạn chế ảnh hưởng của điều kiện chiếu sáng và tư thế đầu trước khi ảnh được đưa vào mạng học sâu. Trong giai đoạn huấn luyện, dữ liệu còn có thể được tăng cường bằng các phép biến đổi như xoay, dịch chuyển, thay đổi tỷ lệ, điều chỉnh độ tương phản hoặc thêm nhiễu nhân tạo vào ảnh. Theo Li và Deng, việc tăng cường dữ liệu giúp mở rộng số lượng mẫu huấn luyện và hạn chế hiện tượng quá khớp khi dữ liệu biểu cảm khuôn mặt còn hạn chế [4].

Ảnh khuôn mặt sau khi tiền xử lý được đưa vào mạng học sâu để trích xuất đặc trưng. Khác với phương pháp truyền thống sử dụng các đặc trưng được thiết kế thủ

công, mạng học sâu hình thành biểu diễn đặc trưng thông qua nhiều lớp biến đổi phi tuyến. Đối với ảnh tĩnh, mạng nơ-ron tích chập thường được sử dụng để học các đặc trưng từ những vùng cục bộ đến biểu diễn tổng thể của khuôn mặt. Những đặc trưng thu được cần thể hiện được sự khác biệt giữa các mẫu biểu cảm, đồng thời hạn chế ảnh hưởng của các yếu tố không liên quan như đặc điểm riêng của từng người, điều kiện chiếu sáng và tư thế khuôn mặt [4].

Phân loại biểu cảm là bước cuối cùng của quy trình. Li và Deng cho biết trong các mô hình học sâu, bước trích xuất đặc trưng và phân loại có thể được huấn luyện đồng thời theo phương pháp đầu cuối. Lớp phân loại tiếp nhận đặc trưng đã học, tạo giá trị dự đoán cho từng lớp và xác định nhãn biểu cảm của ảnh đầu vào. Số lượng và tên các lớp đầu ra phụ thuộc vào bộ dữ liệu cũng như mô hình được sử dụng. Quy trình gồm phát hiện khuôn mặt, căn chỉnh và chuẩn hóa, trích xuất đặc trưng và phân loại biểu cảm được minh họa tại Hình 2.2 [4].



Hình 2.2: Quy trình tổng quát của hệ thống FER dựa trên học sâu (Nguồn: Li và Deng [4])

2.3 Các phương pháp phát hiện khuôn mặt

Phát hiện khuôn mặt là bài toán xác định trong ảnh có khuôn mặt hay không và định vị từng khuôn mặt bằng một khung bao. Từ các công trình của Viola và Jones, Zhang và cộng sự, cùng Deng và cộng sự, quy trình phát hiện có thể được khái quát thành bốn thao tác: khảo sát ảnh tại nhiều vị trí và tỷ lệ; phân biệt vùng khuôn mặt với vùng nền; hiệu chỉnh vị trí khung bao; và loại bỏ các khung dự đoán trùng lặp [6–8]. Mức tin cậy biểu thị mức độ mô hình cho rằng một khung dự đoán chứa khuôn mặt. Với các phương pháp có dự đoán điểm mốc, vị trí mắt, mũi và khóe miệng còn được xác định để hỗ trợ căn chỉnh khuôn mặt trước bước nhận dạng biểu cảm.

Ba công trình trên xây dựng các thao tác này theo những nguyên lý khác nhau. Viola và Jones khảo sát ảnh bằng cửa sổ trượt ở nhiều tỷ lệ, mô tả mỗi cửa sổ bằng

đặc trưng Haar, sử dụng AdaBoost để chọn đặc trưng phân biệt và tổ chức các bộ phân loại theo cấu trúc xếp tầng nhằm loại nhanh vùng nền [6]. Zhang và cộng sự đề xuất MTCNN gồm ba mạng tích chập nối tiếp; vùng ứng viên được sàng lọc và hiệu chỉnh dần từ P-Net đến R-Net và O-Net, đồng thời mô hình dự đoán năm điểm mốc khuôn mặt [7]. Deng và cộng sự đề xuất RetinaFace theo hướng phát hiện một giai đoạn: các khung khuôn mặt được dự đoán trực tiếp trên những mức đặc trưng có độ phân giải khác nhau, kết hợp nhiệm vụ phân loại khuôn mặt, hồi quy khung bao và xác định điểm mốc [8]. Các mục tiếp theo trình bày chi tiết cơ sở lý thuyết của từng phương pháp.

2.3.1 Haar Cascade theo Viola–Jones

Năm 2001, Viola và Jones đề xuất phương pháp phát hiện đối tượng nhanh dựa trên ba thành phần chính: ảnh tích phân để tính đặc trưng hình chữ nhật, AdaBoost để lựa chọn đặc trưng và bộ phân loại xếp tầng để giảm số phép tính. Phương pháp được xây dựng và kiểm chứng chủ yếu cho bài toán phát hiện khuôn mặt chính diện trên ảnh xám [6].

Đầu vào và đầu ra. Đầu vào của phương pháp là ảnh xám, còn đầu ra là các khung bao xác định vị trí khuôn mặt. Ảnh được khảo sát bằng cửa sổ trượt tại nhiều vị trí và tỷ lệ để phát hiện các khuôn mặt có kích thước khác nhau. Mỗi cửa sổ được chuẩn hóa về kích thước cơ sở 24×24 điểm ảnh trước khi được phân loại thành khuôn mặt hoặc vùng nền.

Đặc trưng Haar và ảnh tích phân. Thay vì sử dụng trực tiếp giá trị của từng điểm ảnh, phương pháp mô tả một cửa sổ bằng chênh lệch cường độ giữa các vùng chữ nhật sáng và tối. Các đặc trưng hai vùng, ba vùng và bốn vùng biểu diễn những quan hệ sáng–tối thường gặp trên khuôn mặt, chẳng hạn vùng mắt thường tối hơn vùng má. Do số lượng đặc trưng ứng viên trong một cửa sổ rất lớn, Viola và Jones sử dụng ảnh tích phân để tính nhanh tổng cường độ của mỗi vùng. Giá trị ảnh tích phân tại vị trí (x, y) được xác định bởi:

$$ii(x, y) = \sum_{x'=0}^{x} \sum_{y'=0}^{y} i(x', y'). \tag{2.1}$$

Từ ảnh tích phân, tổng cường độ của vùng chữ nhật có góc trên bên trái (x_1, y_1) và góc dưới bên phải (x_2, y_2) được tính bằng:

$$S(R) = ii(x_2, y_2) - ii(x_1 - 1, y_2) - ii(x_2, y_1 - 1) + ii(x_1 - 1, y_1 - 1). \tag{2.2}$$

Nhờ đó, tổng cường độ của một vùng chỉ cần bốn giá trị đã tính trước và không phụ

thuộc vào số điểm ảnh bên trong vùng.

Lựa chọn đặc trưng bằng AdaBoost. Trong giai đoạn huấn luyện, dữ liệu gồm các cửa sổ chứa khuôn mặt và không chứa khuôn mặt. Mỗi đặc trưng Haar được kết hợp với một ngưỡng và chiều so sánh để tạo thành một bộ phân loại yếu. AdaBoost lựa chọn những bộ phân loại có sai số có trọng số thấp, đồng thời tăng trọng số của các mẫu bị phân loại sai để những vòng tiếp theo tập trung vào các trường hợp khó hơn. Kết quả là một số lượng nhỏ đặc trưng có khả năng phân biệt tốt được giữ lại từ tập đặc trưng ban đầu.

Các bộ phân loại yếu được kết hợp theo cơ chế biểu quyết có trọng số để tạo thành bộ phân loại mạnh. Bộ phân loại có sai số thấp được gán trọng số lớn hơn và có ảnh hưởng nhiều hơn đến quyết định cuối cùng. Tuy nhiên, áp dụng toàn bộ bộ phân loại mạnh cho mọi cửa sổ vẫn tốn nhiều chi phí vì phần lớn cửa sổ trong ảnh chỉ chứa vùng nền.

Cấu trúc xếp tầng. Để giảm số phép tính, các bộ phân loại mạnh được tổ chức thành nhiều tầng. Những tầng đầu sử dụng ít đặc trưng để loại nhanh các cửa sổ không có khả năng chứa khuôn mặt; các tầng sau sử dụng nhiều đặc trưng hơn để kiểm tra những trường hợp khó. Cửa sổ bị loại tại bất kỳ tầng nào sẽ không được xử lý tiếp, còn cửa sổ vượt qua tất cả các tầng được giữ lại làm ứng viên khuôn mặt. Cuối cùng, các khung bao chồng lấn được nhóm và hợp nhất để tạo kết quả phát hiện.

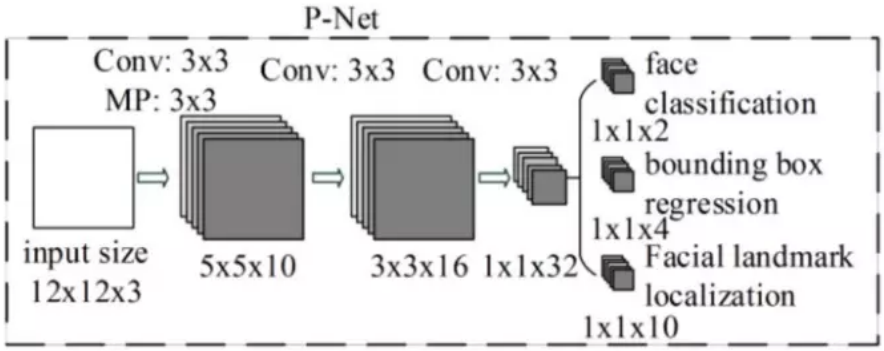
Cách tổ chức trên giúp Haar Cascade có tốc độ xử lý nhanh và yêu cầu tài nguyên tính toán thấp. Tuy nhiên, do sử dụng các đặc trưng được thiết kế trước, phương pháp hoạt động tốt nhất với khuôn mặt chính diện và có thể suy giảm hiệu quả khi khuôn mặt quay nghiêng, bị che khuất, có kích thước nhỏ hoặc xuất hiện trong điều kiện chiếu sáng phức tạp. Đây là cơ sở để so sánh với các phương pháp dựa trên mạng nơ-ron tích chập như MTCNN và RetinaFace được trình bày ở các mục tiếp theo.

2.3.2 MTCNN

Năm 2016, Zhang và cộng sự đề xuất MTCNN, viết tắt của *Multi-task Cascaded Convolutional Networks*, một phương pháp phát hiện khuôn mặt dựa trên ba mạng nơ-ron tích chập xếp tầng gồm P-Net, R-Net và O-Net [7]. Ba mạng lần lượt tạo, sàng lọc và hiệu chỉnh các vùng ứng viên để xác định khung bao khuôn mặt. Ngoài ra, O-Net còn xác định năm điểm mốc gồm hai mắt, mũi và hai khóe miệng để hỗ trợ bước chuẩn hóa ảnh khuôn mặt. Các bộ lọc của mạng được học từ dữ liệu để tạo đặc trưng hình ảnh, thay vì sử dụng các đặc trưng Haar được xác định trước như Viola–Jones.

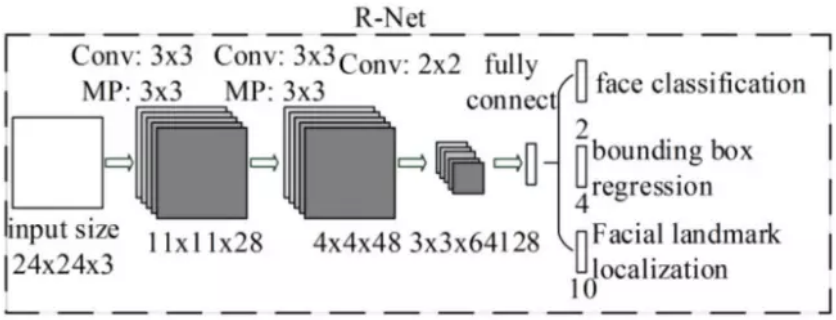
Đầu vào và đầu ra của phương pháp. Đầu vào là một ảnh có thể chứa một hoặc nhiều khuôn mặt với kích thước khác nhau. Ảnh ban đầu được thay đổi về nhiều tỷ lệ để tạo thành tháp ảnh; nhờ đó, cùng một mạng có thể khảo sát khuôn mặt ở nhiều kích thước. Đầu ra cuối cùng của MTCNN gồm khung bao khuôn mặt, mức tin cậy của khung và năm điểm mốc tương ứng với hai mắt, mũi và hai khóe miệng. Khung bao xác định vùng khuôn mặt cần cắt; các điểm mốc là thông tin bổ sung để bước xử lý sau có thể xoay và chuẩn hóa ảnh trước khi nhận dạng biểu cảm.

Giai đoạn P-Net. Mỗi mức của tháp ảnh được đưa qua Proposal Network (P-Net), là một mạng tích chập có nhiệm vụ khảo sát nhanh toàn ảnh. Tại các vị trí đang xét, P-Net tạo điểm xác suất khuôn mặt và véc-tơ hiệu chỉnh khung bao. Những vị trí có điểm thấp bị loại; các khung còn lại được dịch chuyển và thay đổi kích thước theo véc-tơ hiệu chỉnh. Sau đó, thuật toán loại bỏ không cực đại (NMS) gộp hoặc loại các khung chồng lấn mạnh. Đầu ra của giai đoạn này là một tập vùng ứng viên, chưa phải kết quả phát hiện cuối cùng.



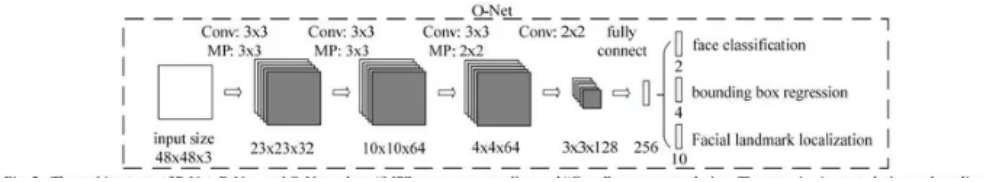
Hình 2.3: Kiến trúc P-Net của MTCNN

Giai đoạn R-Net. Các vùng ứng viên do P-Net tạo ra được cắt từ ảnh, chuẩn hóa theo đầu vào của Refinement Network (R-Net) và kiểm tra lại bằng một mạng có khả năng biểu diễn chi tiết hơn. R-Net tiếp tục dự đoán điểm khuôn mặt và véc-tơ hiệu chỉnh khung bao. Những ứng viên không đạt ngưỡng bị loại; những ứng viên còn lại được hiệu chỉnh và tiếp tục xử lý bằng NMS. Đầu ra của R-Net là một tập ứng viên ít hơn nhưng có vị trí chính xác hơn.

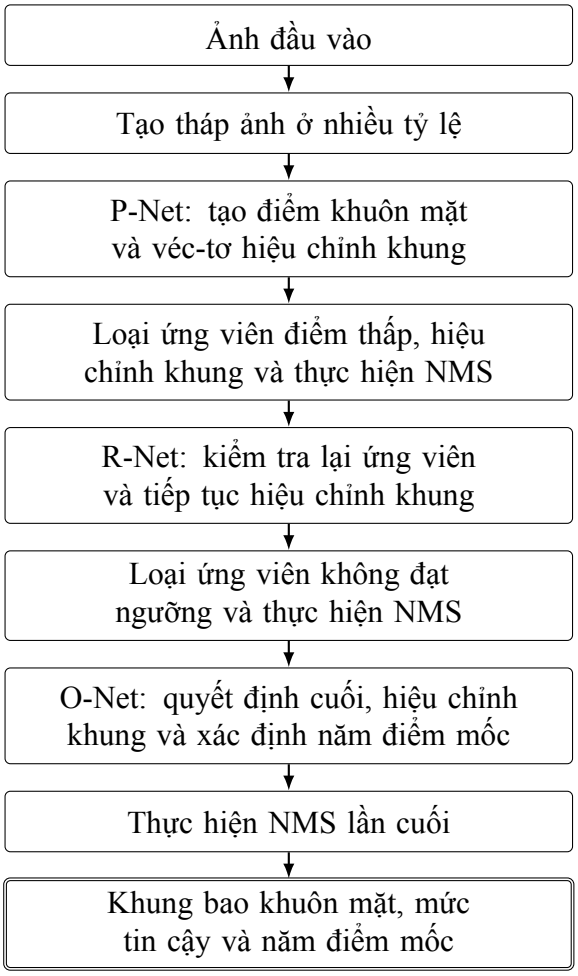


Hình 2.4: Kiến trúc R-Net của MTCNN

Giai đoạn O-Net. Các ứng viên vượt qua R-Net được đưa vào Output Network (O-Net). Mạng này thực hiện lần kiểm tra cuối, tiếp tục dự đoán điểm khuôn mặt và hiệu chỉnh khung bao, đồng thời xác định năm điểm mốc trên khuôn mặt. Sau bước NMS cuối cùng, các khung được giữ lại trở thành kết quả phát hiện của phương pháp.



Hình 2.5: Kiến trúc O-Net của MTCNN



Hình 2.6: Quy trình phát hiện khuôn mặt của MTCNN, do luận văn tổng hợp dựa trên [7]

Cơ chế học đa nhiệm. Trong quá trình huấn luyện, các mạng được học với ba nhiệm vụ: phân loại khuôn mặt và vùng nền, hồi quy độ lệch của khung bao, và định vị điểm mốc khuôn mặt. Nhiệm vụ phân loại cho biết một vùng có phải khuôn mặt hay không; nhiệm vụ hồi quy khung bao xác định cách dịch chuyển và thay đổi kích thước khung để khớp khuôn mặt tốt hơn; nhiệm vụ định vị điểm mốc xác định tọa độ của hai mắt, mũi và hai khóe miệng. Zhang và cộng sự còn sử dụng cơ chế chọn mẫu khó trực tuyến: trong mỗi lô huấn luyện, các mẫu có giá trị mất mát cao được ưu tiên khi cập nhật mạng, giúp mô hình tập trung vào những trường hợp đang bị phân loại sai [7].

Cách hình thành kết quả. Một vùng do P-Net tạo ra chỉ là ứng viên. Vùng này phải tiếp tục đạt ngưỡng tại R-Net và O-Net mới được giữ lại. Mức tin cậy do O-Net tạo ra cho biết mức độ mạng đánh giá vùng đang xét là khuôn mặt; véc-tơ hồi quy được dùng để tạo khung bao cuối cùng; năm điểm mốc mô tả vị trí các bộ phận chính trên khuôn mặt. NMS loại các khung trùng lặp để một khuôn mặt không tạo ra nhiều kết quả gần nhau. Vì vậy, kết quả cuối cùng của MTCNN là tập các khung bao khuôn mặt kèm mức tin cậy và năm điểm mốc, không phải nhãn

biểu cảm. Hệ thống sử dụng các thông tin này để cắt và chuẩn hóa ảnh khuôn mặt trước khi chuyển sang bộ phân loại biểu cảm.

Việc tạo tháp ảnh và thực hiện ba lượt xử lý nối tiếp qua P-Net, R-Net và O-Net làm cho thời gian thực hiện phụ thuộc vào số lượng vùng ứng viên còn lại sau từng giai đoạn. Do đó, chất lượng phát hiện và thời gian xử lý của MTCNN cần được đo trên cùng dữ liệu và phần cứng với các phương pháp còn lại.

2.3.3 RetinaFace

Năm 2020, Deng và cộng sự công bố RetinaFace, một phương pháp định vị khuôn mặt một giai đoạn dựa trên mạng nơ-ron tích chập [8]. Khác với MTCNN sử dụng ba mạng nối tiếp để sàng lọc vùng ứng viên, RetinaFace tổ chức toàn bộ quá trình phát hiện trong một mạng thống nhất. Ảnh lần lượt được xử lý bởi mạng nền, tháp đặc trưng và các nhánh dự đoán. Tại các nhánh đầu ra, mô hình đồng thời tính điểm khuôn mặt, độ lệch của khung bao và vị trí năm điểm mốc. Vì vùng ứng viên không phải lần lượt đi qua ba mạng phát hiện riêng biệt, RetinaFace được xếp vào nhóm phương pháp phát hiện một giai đoạn.

Đầu vào và đầu ra của phương pháp. Đầu vào của RetinaFace là một ảnh có thể chứa một hoặc nhiều khuôn mặt với kích thước khác nhau. Đối với nhiệm vụ phát hiện khuôn mặt, kết quả của mỗi khuôn mặt gồm khung bao, mức tin cậy và năm điểm mốc tương ứng với hai mắt, mũi và hai khóe miệng. Khung bao xác định vùng ảnh cần cắt, còn các điểm mốc cung cấp thông tin hình học để bước xử lý sau có thể chuẩn hóa khuôn mặt. RetinaFace không tạo nhãn biểu cảm; ảnh khuôn mặt sau khi được phát hiện phải tiếp tục được đưa vào bộ phân loại biểu cảm.

Trích xuất đặc trưng ở nhiều mức. Ảnh đầu vào trước hết được đưa qua một mạng tích chập làm mạng nền. Các lớp của mạng nền tạo ra những bản đồ đặc trưng có độ phân giải khác nhau. Bản đồ có độ phân giải cao giữ lại nhiều chi tiết vị trí và phù hợp với khuôn mặt nhỏ; bản đồ sâu hơn có độ phân giải thấp hơn nhưng có vùng quan sát rộng hơn, phù hợp với khuôn mặt lớn. RetinaFace kết hợp các bản đồ này bằng mạng tháp đặc trưng, viết tắt là FPN từ *Feature Pyramid Network*. Trong kiến trúc được công bố, tháp đặc trưng tạo năm mức từ P2 đến P6 để cùng một mạng có thể tìm khuôn mặt ở nhiều kích thước [8].

Trên mỗi mức của tháp đặc trưng, RetinaFace sử dụng một mô-đun ngữ cảnh. Mô-đun này tổng hợp thông tin từ vùng rộng hơn xung quanh vị trí đang xét, nhờ đó quyết định phát hiện không chỉ phụ thuộc vào một vùng ảnh rất nhỏ. Bài báo sử dụng các phép tích chập có khả năng điều chỉnh vị trí lấy mẫu trong mô-đun ngữ cảnh, nhằm thích nghi tốt hơn với sự thay đổi về hình dạng và tư thế khuôn mặt.

Khung tham chiếu và các nhánh dự đoán. Trên các bản đồ đặc trưng, phương pháp đặt các khung tham chiếu tại nhiều vị trí và kích thước. Khung tham chiếu chưa phải là khung khuôn mặt cuối cùng mà chỉ cung cấp vị trí ban đầu để mạng đánh giá. Với mỗi khung, mạng thực hiện đồng thời ba nhiệm vụ liên quan trực tiếp đến phát hiện khuôn mặt: phân loại khuôn mặt và vùng nền, dự đoán độ lệch của khung bao, và dự đoán tọa độ năm điểm mốc. Nhánh phân loại tạo mức tin cậy cho biết khung đang xét có khả năng chứa khuôn mặt hay không. Nhánh hồi quy khung bao xác định cách dịch chuyển và thay đổi kích thước khung tham chiếu để khớp với khuôn mặt. Nhánh điểm mốc xác định mười giá trị tọa độ của hai mắt, mũi và hai khóe miệng.

Trong phương pháp gốc, Deng và cộng sự còn bổ sung nhánh dự đoán các đỉnh của mô hình khuôn mặt ba chiều và huấn luyện các nhiệm vụ trong cùng một mạng [8]. Nhánh này cung cấp thêm thông tin hình học trong quá trình nghiên cứu phương pháp, nhưng không phải đầu ra cần sử dụng trong quy trình nhận dạng biểu cảm của luận văn. Đối với công đoạn phát hiện khuôn mặt, ba kết quả cần thiết vẫn là điểm phân loại, khung bao và năm điểm mốc.

Cách hình thành kết quả. Khi RetinaFace xử lý xong ảnh đầu vào, các nhánh đầu ra tạo dự đoán tại những khung tham chiếu trên tất cả các mức của tháp đặc trưng. Mỗi dự đoán gồm mức tin cậy của khuôn mặt, độ lệch của khung bao và tọa độ năm điểm mốc. Độ lệch được dùng để điều chỉnh khung tham chiếu thành khung bao khuôn mặt; những khung có mức tin cậy thấp bị loại bỏ. Do nhiều khung có thể cùng bao quanh một khuôn mặt, thuật toán loại bỏ không cực đại (NMS) tiếp tục so sánh mức chồng lấn và giữ lại khung có mức tin cậy cao hơn. Đầu ra cuối cùng là tập các khung bao khuôn mặt kèm mức tin cậy và năm điểm mốc.

RetinaFace tạo số lượng lớn dự đoán trên nhiều mức đặc trưng, vì vậy kết quả phụ thuộc vào khả năng phát hiện khuôn mặt ở từng kích thước, ngưỡng tin cậy và bước loại khung trùng lặp. Các yếu tố này cần được giữ thống nhất khi đánh giá phương pháp bằng thực nghiệm.

2.3.4 So sánh giữa các phương pháp

Ba phương pháp đều nhận ảnh làm đầu vào và trả về các khung bao khuôn mặt, nhưng khác nhau ở cách biểu diễn ảnh và cách hình thành kết quả. Viola–Jones sử dụng đặc trưng Haar được thiết kế trước và kiểm tra cửa sổ ảnh bằng chuỗi bộ phân loại xếp tầng. MTCNN học đặc trưng bằng mạng tích chập, sau đó giảm dần số vùng ứng viên qua ba mạng P-Net, R-Net và O-Net. RetinaFace cũng học đặc trưng bằng mạng tích chập nhưng tạo dự đoán trên nhiều mức của tháp đặc trưng trong một mạng phát hiện thống nhất. Bảng 2.1 đối chiếu các khác biệt này.

Bảng 2.1: So sánh giữa các phương pháp phát hiện khuôn mặt

Phương pháp	**Cách biểu diễn ảnh**	**Cách hình thành kết quả**	**Đầu ra**
Haar Cascade	Đặc trưng Haar được tính nhanh bằng ảnh tích phân	Quét cửa sổ ở nhiều vị trí và tỷ lệ; mỗi cửa sổ phải vượt qua chuỗi bộ phân loại mạnh được AdaBoost lựa chọn và tổ chức theo cấu trúc xếp tầng	Khung bao khuôn mặt
MTCNN	Đặc trưng được học bằng ba mạng tích chập trên tháp ảnh nhiều tỷ lệ	P-Net tạo vùng ứng viên, R-Net sàng lọc và hiệu chỉnh, O-Net tạo kết quả cuối; NMS được sử dụng sau các giai đoạn để loại khung trùng lặp	Khung bao, mức tin cậy và năm điểm mốc
RetinaFace	Đặc trưng được học bằng mạng tích chập và kết hợp bằng tháp đặc trưng nhiều mức	Dự đoán đồng thời mức tin cậy của khuôn mặt, độ lệch khung bao và điểm mốc tại các khung tham chiếu; sau đó lọc theo mức tin cậy và thực hiện NMS	Khung bao, mức tin cậy và năm điểm mốc

Viola–Jones và MTCNN đều sử dụng cơ chế loại dần các trường hợp không phù hợp, nhưng thành phần xử lý khác nhau. Viola–Jones loại cửa sổ bằng các bộ phân loại sử dụng đặc trưng Haar, còn MTCNN chuyển vùng ứng viên qua ba mạng tích chập có độ phức tạp tăng dần. RetinaFace không tổ chức thành ba mạng sàng lọc nối tiếp mà tạo dự đoán trên các mức đặc trưng trong cùng một mạng. MTCNN và RetinaFace còn cung cấp năm điểm mốc, trong khi đầu ra cơ bản của Viola–Jones là khung bao khuôn mặt.

So sánh trên chỉ phản ánh sự khác nhau về nguyên lý. Nó chưa cho biết phương pháp nào phát hiện chính xác hơn hoặc xử lý nhanh hơn trong điều kiện của luận văn. Việc lựa chọn phương pháp phải dựa trên kết quả thực nghiệm khi cùng sử dụng một tập dữ liệu, một cách tính chỉ số và một cấu hình phần cứng.

2.4 Các phương pháp phân loại biểu cảm

Sau khi khuôn mặt được phát hiện và chuẩn hóa, ảnh khuôn mặt được đưa vào bộ phân loại để xác định một trong bảy nhãn biểu cảm. Các phương pháp phân loại có thể chia thành hai nhóm chính. Nhóm thứ nhất sử dụng các đặc trưng được xây dựng theo quy tắc xác định trước, sau đó đưa các đặc trưng này vào bộ phân loại. Nhóm thứ hai sử dụng mạng nơ-ron sâu để tự học đặc trưng trực tiếp từ dữ liệu ảnh. Các mục tiếp theo trình bày nguyên lý của hai hướng tiếp cận này.

2.4.1 Phân loại biểu cảm bằng LBP kết hợp SVM

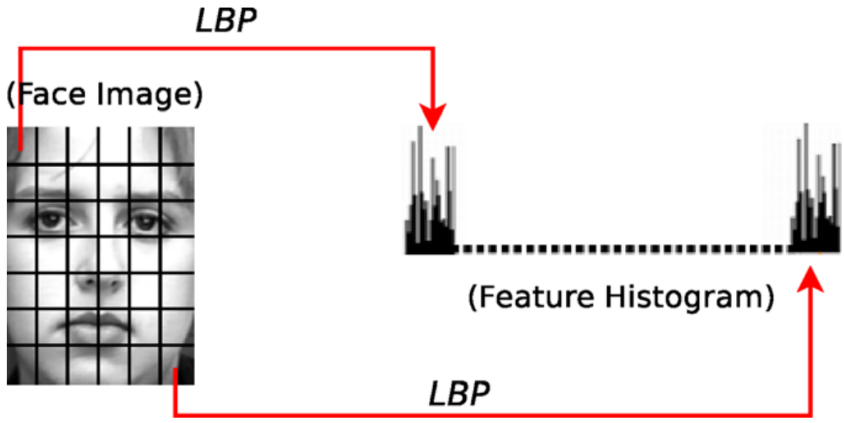
LBP kết hợp SVM là một hướng phân loại biểu cảm dựa trên đặc trưng được xác định trước. LBP mô tả kết cấu cục bộ trên ảnh khuôn mặt, còn SVM sử dụng các đặc trưng đó để phân chia ảnh vào các lớp biểu cảm. Trong bài báo *Facial*

Expression Recognition Based on Local Binary Patterns: A Comprehensive Study, Shan, Gong và McOwan đã nghiên cứu việc sử dụng đặc trưng LBP kết hợp với SVM để phân loại biểu cảm khuôn mặt [**?**].

Đầu vào của phương pháp. Đầu vào là ảnh khuôn mặt đã được phát hiện, căn chỉnh, chuyển về ảnh xám và chuẩn hóa kích thước. Căn chỉnh giúp các bộ phận như mắt, lông mày và miệng nằm ở vị trí tương đối tương ứng giữa các ảnh. Nhờ đó, đặc trưng được trích xuất từ cùng một vùng có thể được so sánh với nhau.

Trích xuất đặc trưng LBP. Tại mỗi vị trí trên ảnh, LBP so sánh cường độ của điểm ảnh trung tâm với các điểm ảnh lân cận. Điểm lân cận có cường độ lớn hơn hoặc bằng điểm trung tâm được biểu diễn bằng giá trị 1; trường hợp còn lại được biểu diễn bằng giá trị 0. Chuỗi giá trị nhị phân thu được tạo thành một mã mô tả quan hệ sáng–tối trong vùng nhỏ quanh điểm đang xét. Nguyên lý này được Ojala, Pietikäinen và Mäenpää phát triển thành toán tử LBP có thể lấy mẫu các điểm lân cận ở những bán kính khác nhau [9].

Để giữ thông tin về vị trí của đặc trưng, ảnh khuôn mặt được chia thành nhiều vùng nhỏ. Hệ thống thống kê số lần xuất hiện của các mã LBP trong từng vùng, sau đó ghép các kết quả theo một thứ tự cố định để tạo thành véc-tơ đặc trưng của toàn bộ khuôn mặt. Vì vậy, véc-tơ không chỉ phản ánh loại kết cấu xuất hiện mà còn cho biết kết cấu đó nằm ở vùng nào trên khuôn mặt. Quá trình này được minh họa trong Hình 2.7.



Hình 2.7: Quy trình tạo véc-tơ đặc trưng LBP theo vùng (Nguồn: Shan và cộng sự [**?**])

Phân loại bằng SVM. Trong giai đoạn huấn luyện, mỗi ảnh được chuyển thành một véc-tơ LBP và gắn với nhãn biểu cảm tương ứng. SVM sử dụng các véc-tơ này để tìm ranh giới phân chia giữa các lớp sao cho khoảng cách từ ranh giới đến những mẫu gần nhất là lớn nhất. Với bài toán nhiều lớp, có thể huấn luyện nhiều

bộ phân loại nhị phân theo cách một lớp so với các lớp còn lại [**?**].

Đầu ra của phương pháp. Khi nhận một ảnh mới, hệ thống thực hiện lại các bước chuẩn hóa và trích xuất đặc trưng LBP, sau đó đưa véc-tơ thu được vào SVM. Các bộ phân loại tạo điểm quyết định cho từng lớp và lớp có điểm phù hợp nhất được chọn làm kết quả. Đầu ra là nhãn biểu cảm dự đoán; điểm quyết định của SVM chỉ phản ánh vị trí của mẫu so với ranh giới phân loại và không mặc nhiên là xác suất.

Như vậy, LBP đảm nhiệm việc mô tả kết cấu trên khuôn mặt theo một quy tắc cố định, còn SVM học ranh giới phân loại từ các véc-tơ đặc trưng. Khả năng phân loại phụ thuộc vào chất lượng căn chỉnh khuôn mặt và mức độ mà đặc trưng LBP biểu diễn được sự khác nhau giữa các biểu cảm.

2.4.2 Phân loại biểu cảm bằng mạng nơ-ron tích chập

CNN là phương pháp học sâu thường được sử dụng để phân loại hình ảnh. Khác với LBP kết hợp SVM, CNN không sử dụng một quy tắc cố định để tạo đặc trưng mà học trực tiếp các đặc trưng cần thiết từ dữ liệu huấn luyện. Trong bài báo *Deep Learning*, LeCun, Bengio và Hinton trình bày nguyên lý học biểu diễn qua nhiều lớp của mạng học sâu [11]. Trên cơ sở đó, Li và Deng hệ thống hóa việc áp dụng mạng học sâu cho nhận dạng biểu cảm khuôn mặt trong bài báo *Deep Facial Expression Recognition: A Survey* [4].

Đầu vào của phương pháp. Đầu vào là ảnh khuôn mặt đã được phát hiện, căn chỉnh và chuẩn hóa. Các ảnh được đưa về cùng kích thước, số kênh màu và miền giá trị điểm ảnh để phù hợp với cấu trúc đầu vào của mạng. Việc chuẩn hóa hạn chế sự khác biệt về vị trí và kích thước khuôn mặt, giúp mạng tập trung học những đặc điểm có liên quan đến biểu cảm.

Trích xuất đặc trưng bằng phép tích chập. Thành phần chính của CNN là các lớp tích chập. Mỗi lớp sử dụng nhiều bộ lọc có kích thước nhỏ để xử lý lần lượt các vùng trên ảnh. Kết quả của mỗi bộ lọc tạo thành một bản đồ đặc trưng, thể hiện vị trí và mức độ xuất hiện của đặc điểm mà bộ lọc phản ứng.

Các bộ lọc không được thiết lập thủ công mà được điều chỉnh trong quá trình huấn luyện. Những lớp đầu thường học các đặc trưng đơn giản như đường biên, hướng cạnh và sự thay đổi cường độ điểm ảnh. Những lớp sâu hơn kết hợp các đặc trưng này thành biểu diễn phức tạp hơn, qua đó mô tả sự thay đổi tại các vùng như mắt, lông mày và miệng. Vì vậy, đặc trưng cuối cùng được hình thành từ dữ liệu thay vì được xác định trước như trong phương pháp LBP.

Biến đổi và giảm kích thước đặc trưng. Sau phép tích chập, hàm kích hoạt phi tuyến được sử dụng để mạng biểu diễn các quan hệ phức tạp trong ảnh. Các lớp

gộp hoặc lớp tích chập có bước dịch lớn hơn có thể được sử dụng để giảm kích thước bản đồ đặc trưng. Quá trình này làm giảm số lượng phép tính, đồng thời giữ lại những thông tin nổi bật phục vụ phân loại. Khi ảnh đi qua nhiều lớp liên tiếp, mạng có thể kết hợp thông tin từ nhiều vùng để hình thành biểu diễn tổng thể của khuôn mặt.

Phân loại biểu cảm. Các bản đồ đặc trưng cuối cùng được chuyển thành một véc-tơ biểu diễn ảnh khuôn mặt. Véc-tơ này được đưa vào lớp phân loại để tạo điểm dự đoán cho từng lớp biểu cảm. Với bài toán bảy lớp, đầu ra tương ứng với các nhãn *Angry*, *Disgust*, *Fear*, *Happy*, *Sad*, *Surprise* và *Neutral*. Các điểm dự đoán có thể được chuẩn hóa thành mức tin cậy của từng lớp; lớp có giá trị lớn nhất được chọn làm nhãn dự đoán.

Quá trình huấn luyện. Mỗi ảnh trong tập huấn luyện được cung cấp cùng nhãn biểu cảm tương ứng. Kết quả dự đoán của mạng được so sánh với nhãn thật để xác định mức sai lệch. Sai lệch này được truyền ngược qua các lớp nhằm điều chỉnh trọng số của bộ lọc và lớp phân loại. Quá trình được lặp lại trên tập dữ liệu huấn luyện để mạng dần học được những đặc trưng giúp phân biệt các lớp biểu cảm.

Đầu ra của phương pháp. Khi nhận một ảnh mới, mạng sử dụng các trọng số đã học để thực hiện liên tiếp quá trình trích xuất đặc trưng và phân loại. Đầu ra gồm nhãn biểu cảm dự đoán và mức tin cậy tương ứng. Toàn bộ quá trình từ ảnh đầu vào đến kết quả phân loại được thực hiện trong cùng một mô hình.

So với LBP kết hợp SVM, CNN có khả năng tự học đặc trưng từ dữ liệu nhưng phụ thuộc nhiều hơn vào số lượng và chất lượng mẫu huấn luyện. Li và Deng chỉ ra rằng sự thay đổi về tư thế khuôn mặt, điều kiện chiếu sáng, đặc điểm riêng của từng người, hiện tượng che khuất và mất cân bằng giữa các lớp có thể ảnh hưởng đến kết quả nhận dạng biểu cảm [4].

2.4.3 Học chuyển giao trong phân loại biểu cảm

Học chuyển giao không phải là một bộ phân loại độc lập mà là cách xây dựng mô hình bằng việc sử dụng lại tri thức từ một nhiệm vụ đã được học trước. Trong bài báo *A Survey on Transfer Learning*, Pan và Yang mô tả học chuyển giao là việc sử dụng tri thức từ miền nguồn để hỗ trợ nhiệm vụ ở miền đích [12]. Đối với nhận dạng biểu cảm, miền nguồn có thể là một tập dữ liệu ảnh lớn hoặc tập dữ liệu khuôn mặt, còn miền đích là tập ảnh khuôn mặt đã được gắn nhãn biểu cảm.

Mô hình được huấn luyện trước. Một mạng CNN sau khi được huấn luyện trên lượng dữ liệu lớn đã hình thành các bộ lọc có khả năng nhận biết những đặc điểm phổ biến của ảnh như đường biên, kết cấu và hình dạng. Thay vì khởi tạo toàn

bộ trọng số ngẫu nhiên, học chuyển giao sử dụng các trọng số này làm điểm bắt đầu cho nhiệm vụ nhận dạng biểu cảm. Phần mạng thực hiện trích xuất đặc trưng thường được gọi là mạng nền.

Thay lớp phân loại. Lớp phân loại của mô hình nguồn được thiết kế cho các nhãn của nhiệm vụ ban đầu nên không thể sử dụng trực tiếp cho bài toán biểu cảm. Lớp này được thay bằng một lớp phân loại mới có số đầu ra tương ứng với bảy nhãn biểu cảm. Khi đó, mạng nền tạo véc-tơ đặc trưng từ ảnh khuôn mặt, còn lớp mới sử dụng véc-tơ này để đưa ra kết quả phân loại.

Cố định mạng nền. Ở cách thứ nhất, trọng số của mạng nền được giữ nguyên và chỉ lớp phân loại mới được huấn luyện trên dữ liệu biểu cảm. Mạng nền đóng vai trò bộ trích xuất đặc trưng cố định. Cách này giảm số lượng tham số cần cập nhật và phù hợp khi dữ liệu của nhiệm vụ mới còn hạn chế, nhưng khả năng thích nghi với đặc điểm riêng của ảnh biểu cảm cũng bị giới hạn.

Tinh chỉnh mô hình. Ở cách thứ hai, một phần hoặc toàn bộ mạng nền tiếp tục được huấn luyện cùng lớp phân loại mới. Quá trình này điều chỉnh các đặc trưng đã học để phù hợp hơn với sự thay đổi trên khuôn mặt. Việc tinh chỉnh thường bắt đầu từ các trọng số đã được huấn luyện trước thay vì học lại toàn bộ mô hình từ đầu. Phạm vi các lớp được tinh chỉnh phụ thuộc vào lượng dữ liệu và mức độ tương đồng giữa nhiệm vụ nguồn với nhiệm vụ nhận dạng biểu cảm.

Đầu ra của mô hình sau khi chuyển giao. Học chuyển giao không làm thay đổi dạng đầu ra của CNN. Sau khi được huấn luyện cho nhiệm vụ mới, mô hình vẫn nhận ảnh khuôn mặt đã chuẩn hóa và trả về nhãn biểu cảm cùng mức tin cậy tương ứng. Điểm khác biệt nằm ở cách khởi tạo và huấn luyện trọng số của mạng, không nằm ở cách biểu diễn kết quả.

Học chuyển giao giúp giảm nhu cầu huấn luyện mô hình từ đầu, nhưng hiệu quả phụ thuộc vào mức độ phù hợp giữa dữ liệu nguồn và dữ liệu biểu cảm. Nếu hai miền dữ liệu khác nhau đáng kể về chất lượng ảnh, góc nhìn, điều kiện chiếu sáng hoặc đặc điểm khuôn mặt, các đặc trưng được học trước có thể không chuyển sang nhiệm vụ mới một cách hiệu quả. Vì vậy, mô hình sau khi chuyển giao vẫn cần được đánh giá trên dữ liệu phù hợp với điều kiện sử dụng.

2.5 Cơ sở phân tích quan sát biểu cảm theo hành trình đa điểm chạm

2.5.1 Hành trình khách hàng và điểm chạm

Hành trình khách hàng mô tả chuỗi tương tác của khách hàng với doanh nghiệp qua nhiều giai đoạn, kênh và điểm chạm theo thời gian. Lemon và Verhoef nhấn mạnh rằng trải nghiệm khách hàng mang tính động và được hình thành qua nhiều

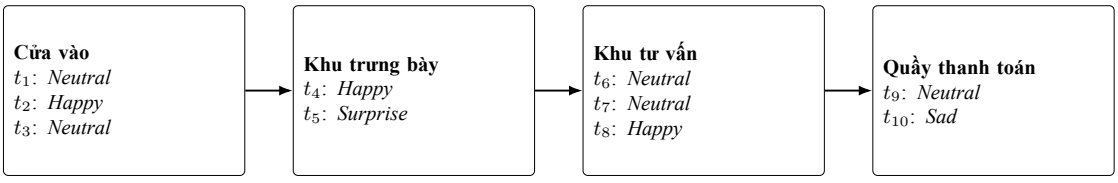
điểm chạm, thay vì chỉ tại một giao dịch đơn lẻ [1]. Điểm chạm có thể là lần khách hàng tiếp xúc với không gian, nhân viên, sản phẩm hoặc hệ thống của doanh nghiệp. Trong bối cảnh bán lẻ của luận văn, camera tại từng khu vực cung cấp một nguồn quan sát biểu cảm tương ứng với điểm chạm, nhưng không tự mô tả toàn bộ trải nghiệm tại khu vực đó.

Halvorsrud, Kvale và Følstad đề xuất khung phân tích hành trình khách hàng, trong đó quá trình cung cấp dịch vụ từ góc nhìn khách hàng được biểu diễn bằng các điểm chạm có thứ tự. Cách biểu diễn này hỗ trợ so sánh hành trình dự kiến với hành trình thực tế [2]. Cơ sở trên phù hợp để đặt các kết quả FER theo trục thời gian. Việc xác định tên khu vực, mã lần mua sắm và quy tắc liên kết quan sát giữa các nguồn thu nhận là phần thiết kế của luận văn, không phải nội dung được suy ra trực tiếp từ khung lý thuyết.

2.5.2 Quan sát tại điểm chạm đến chuỗi biểu cảm

Một kết quả FER tại một thời điểm được xem là một quan sát gồm điểm chạm, thời gian, nhãn biểu cảm và véc-tơ xác suất. Một điểm chạm có thể tạo nhiều quan sát khi khách hàng xuất hiện trong nhiều khung hình tại các thời điểm khác nhau. Các quan sát này được giữ theo thứ tự thời gian thay vì rút gọn ngay thành một nhãn đại diện, nhờ đó có thể xem xét sự biến thiên của kết quả FER bên trong cùng một khu vực. Tuy nhiên, các dự đoán gần nhau theo thời gian có thể tương quan và dao động do tư thế hoặc chất lượng ảnh; vì vậy, quy tắc lựa chọn bản ghi khi so sánh giữa các khu vực phải được xác định rõ trong phương pháp của luận văn.

Các quan sát được tổ chức theo hai cấp. Ở cấp điểm chạm, hệ thống giữ tập quan sát của cùng khách hàng tại cùng khu vực theo thời gian. Ở cấp lần mua sắm, các tập quan sát tại nhiều điểm chạm được sắp xếp theo thời điểm ghi nhận để tạo chuỗi hành trình. Hình 2.8 minh họa cách tổ chức này; các nhãn trong dữ liệu thực tế phải do quy trình xử lý tạo ra, không được gán trước theo vị trí của điểm chạm.



Hình 2.8: Nhiều quan sát trong từng điểm chạm của một lần mua sắm

Cấu trúc này hỗ trợ thống kê phân bố, biến thiên trong điểm chạm và các cặp nhãn giữa hai điểm chạm liên tiếp. Khi tạo cặp, phương pháp chọn bản ghi đầu tiên, cuối cùng hoặc có mức tin cậy cao nhất. Kết quả chỉ mô tả nhãn trước–sau, không chứng minh trải nghiệm tốt lên hay xấu đi.

Hạn chế của phân tích cục bộ và nhu cầu phân tích chuỗi dữ liệu theo thời gian. Thống kê phân bố tần suất hoặc phân tích từng cặp điểm chạm kề nhau chỉ phản ánh các biến động cục bộ giữa hai bước kế tiếp, làm mất đi tính chỉnh thể của toàn bộ tiến trình tương tác dài hạn. Trong lý thuyết về trải nghiệm khách hàng (Customer Experience), Lemon và Verhoef nhấn mạnh rằng trải nghiệm mang tính động và được tích lũy xuyên suốt qua một chuỗi các điểm chạm nối tiếp nhau [1]. Phản ứng hoặc trạng thái tâm lý tại một điểm chạm luôn chịu sự chi phối từ lịch sử tương tác ở những điểm chạm trước đó. Trong phương pháp luận phân tích chuỗi (Sequence Analysis), Abbott chỉ ra rằng các hiện tượng tương tác và hành vi con người không thể được làm sáng tỏ thỏa đáng nếu chỉ xem xét các biến số tĩnh tại từng thời điểm hoặc phân rã hành trình thành các lát cắt thời gian độc lập [**?**]. Thay vào đó, hành vi bản chất là một quỹ đạo (trajectory) gồm các sự kiện hoặc trạng thái có trật tự thời gian chặt chẽ. Do vậy, chuỗi quan sát cần được biểu diễn dưới dạng chuỗi trạng thái rời rạc theo thời gian (categorical sequence / categorical time series) $S = (s_1, s_2, \ldots, s_L)$ trên một tập hữu hạn các trạng thái cảm xúc Σ [**?**, **?**]. Cách tiếp cận chuỗi bảo toàn trọn vẹn ba thuộc tính căn bản: trật tự thời gian (order), thời điểm và vị trí chuyển tiếp (timing), và tính liên tục toàn cục (duration/continuity), khắc phục hoàn toàn nhược điểm của các phương pháp phân tích "túi sự kiện" (bag-of-events) phi tuần tự.

Vai trò của kỹ thuật phân cụm chuỗi trong đánh giá và phân tích hành vi người dùng. Khi dữ liệu hành vi được tổ chức thành các chuỗi theo trục thời gian, kỹ thuật phân cụm chuỗi (Sequence Clustering Technique) đóng vai trò phương pháp luận trung tâm trong việc đánh giá và phân tích hành vi người dùng. Dựa trên các nghiên cứu về phân cụm hành vi khách hàng của John, Shobayo và Ogunleye [**?**], cùng các tổng quan về phân cụm chuỗi dữ liệu định danh theo thời gian của Khalifa và cộng sự [**?**] và Kinjo [**?**], vai trò của phương pháp phân cụm được thể hiện qua các khía cạnh lý thuyết cốt lõi sau:

- *Kiểm soát sự bùng nổ tổ hợp và giảm chiều dữ liệu chuỗi thời gian:* Trong môi trường tương tác thực tế, hành trình của người dùng có tính dị thể cao (heterogeneous); mỗi cá nhân có thể tạo ra một chuỗi tương tác riêng biệt về độ dài, thứ tự và thời gian lưu lại. Khi số lượng điểm chạm và số lượng trạng thái biểu cảm gia tăng, không gian các chuỗi khả dĩ bùng nổ theo cấp số nhân. Việc phân tích hoặc trực quan hóa từng chuỗi riêng lẻ trở nên quá tải và bất khả thi. Theo John và cộng sự, các thuật toán phân cụm học không giám sát đóng vai trò phân tách tập dữ liệu lớn và phức tạp thành các nhóm thuần nhất dựa trên độ tương đồng hành vi [**?**]. Đối với dữ liệu chuỗi, phân cụm chuỗi hoạt động như một cơ chế giảm chiều dữ liệu phi tuyến, thu gọn hàng nghìn

chuỗi hành trình phức tạp về một số hữu hạn các nhóm mẫu đồng nhất, biến dữ liệu tuần tự phi cấu trúc thành các cấu trúc nhóm có thể đo lường và diễn giải được [**?**].

- *Nhận diện các hình mẫu hành vi đặc trưng (Behavioral Archetypes):* Phân khúc người dùng truyền thống thường dựa trên các thuộc tính tĩnh (như nhân khẩu học, độ tuổi) vốn không phản ánh được động thái phản ứng thực tế tại hiện trường. Ngược lại, kỹ thuật phân cụm chuỗi cho phép khám phá các mẫu hành vi tiềm ẩn (hidden patterns) và các liên kết trong hành vi mua sắm từ dữ liệu chuỗi thực nghiệm [**?**]. Các cá nhân có quỹ đạo cảm xúc và phản ứng tương tự nhau được gom vào cùng một nhóm, hình thành nên các ”chân dung hành vi động” (dynamic behavioral personas) đại diện cho các phong cách tương tác điển hình của người dùng (ví dụ: nhóm duy trì trạng thái hài lòng xuyên suốt, nhóm chuyển từ phân vân sang tích cực, hoặc nhóm phát sinh phản ứng tiêu cực kéo dài) [**?**].
- *Trích xuất chuỗi đại diện (Prototypical Sequences / Medoids) làm chuẩn mực phân tích:* Trong không gian chuỗi định danh theo thời gian, các phép toán cộng trừ đại số không thể thực hiện, do đó không tồn tại khái niệm trọng tâm hình học (mean/centroid) như dữ liệu số liên tục. Kỹ thuật phân cụm chuỗi dựa trên khoảng cách giải quyết bài toán này bằng cách phát hiện các ”nguyên mẫu” (prototype detection) hoặc trích xuất chuỗi đại diện thực tế (medoid) nằm ở vị trí trung tâm nhất của mỗi cụm [**?**, **?**]. Chuỗi medoid đóng vai trò là ”hành trình mẫu” trực quan, phản ánh chính xác cấu trúc diễn tiến thực tế của toàn bộ cụm, hỗ trợ diễn giải ngữ nghĩa của mẫu hành vi một cách minh bạch mà không bị làm méo mó bởi các giá trị trung bình nhân tạo.
- *Phát hiện các nút thắt trải nghiệm, điểm đứt gãy và phân tách quỹ đạo tích cực – tiêu cực:* So sánh cấu trúc chuỗi giữa các cụm cho phép phân biệt rõ ràng giữa các quỹ đạo hành vi thành công (như duy trì cảm xúc tích cực hoặc chuyển từ e dè sang hài lòng, dẫn đến quyết định mua hàng) với các quỹ đạo tiêu cực (như cảm xúc thất vọng kéo dài dẫn đến rời bỏ tương tác). Đặc biệt, phân cụm chuỗi giúp xác định chính xác điểm chạm hoặc thời điểm xuất hiện bước chuyển pha trạng thái đột ngột (critical state transitions / inflection points), qua đó làm nổi bật các ”nút thắt cổ chai” (bottlenecks) hoặc các điểm phát sinh vấn đề trong quy trình phục vụ [**?**].
- *Hỗ trợ đánh giá tác động, dự báo và can thiệp cá nhân hóa:* Các cụm chuỗi sau khi được phân tách cung cấp nhãn phân đoạn hành vi chất lượng cao để đối sánh với các chỉ số kinh doanh hoặc chỉ số kết quả (như giá trị giao dịch,

mức độ gắn bó thương hiệu) [**?**]. Đồng thời, việc mô hình hóa các cụm chuỗi điển hình tạo cơ sở lý thuyết cho các hệ thống dự báo sớm: dựa trên vài điểm chạm đầu tiên của một người dùng, hệ thống có thể phán đoán xu hướng quỹ đạo tiếp theo và đề xuất can thiệp kịp thời nhằm cải thiện trải nghiệm trước khi người dùng kết thúc tương tác.

Cơ sở lý thuyết về đo độ bất đồng chuỗi bằng So khớp Tối ưu. Để thực hiện phân cụm trên dữ liệu chuỗi định danh theo thời gian, thách thức phương pháp luận lớn nhất là định nghĩa độ đo khoảng cách (dissimilarity metric) giữa các chuỗi có độ dài không bằng nhau và có sự co giãn về trục thời gian. Các khoảng cách hình học thông thường như Euclid hay Manhattan không thể áp dụng trực tiếp. Thuật toán So khớp Tối ưu (Optimal Matching – OM), kế thừa từ thuật toán Needleman–Wunsch trong sinh tin học và được Abbott đưa vào phân tích chuỗi xã hội và hành vi, lượng hóa độ khác biệt giữa hai chuỗi bằng chi phí nhỏ nhất của các phép toán chỉnh sửa cần thiết để biến đổi chuỗi này thành chuỗi kia [**?**, **?**]. Ba phép toán cơ bản gồm:

- *Phép chèn (Insertion) và xóa (Deletion), gọi chung là chi phí indel:* Cho phép bù trừ sự chênh lệch về độ dài chuỗi và sự dịch chuyển mốc thời gian giữa các quan sát;
- *Phép thay thế (Substitution):* Đo lường chi phí thay thế một trạng thái này bằng một trạng thái khác tại cùng vị trí, phản ánh mức độ bất đồng về mặt bản chất giữa các trạng thái định danh.

Chi phí biến đổi tối thiểu giữa hai chuỗi S_u và S_v tạo thành ma trận khoảng cách đối xứng, không âm $D = [d_{\text{OM}}(S_u, S_v)]$, phản ánh cấu trúc hình học khoảng cách phi Euclid giữa toàn bộ các quỹ đạo hành vi [**?**, **?**].

Thuật toán phân cụm dựa trên khoảng cách và kiểm định độ hợp lệ của cụm. Từ ma trận khoảng cách D, các thuật toán phân cụm không gian phi Euclid được áp dụng để nhóm các chuỗi hành vi. Phương pháp phân hoạch quanh phần tử đại diện (Partitioning Around Medoids – PAM), do Kaufman và Rousseeuw đề xuất, là lựa chọn tiêu chuẩn trong phân tích chuỗi [**?**, **?**]. Khác với thuật toán k-means đòi hỏi tính toán trọng tâm đại số trong không gian Euclid, PAM hoạt động trực tiếp trên ma trận khoảng cách tùy ý, tìm kiếm K phần tử đại diện thực sự (medoids) thuộc tập dữ liệu sao cho tổng khoảng cách từ tất cả các chuỗi đến medoid gần nhất của chúng là nhỏ nhất. PAM có tính vững (robustness) cao, ít nhạy cảm với các chuỗi dị biệt (outliers) và bảo đảm tính diễn giải nguyên vẹn cho các hình mẫu hành vi tìm được [**?**].

Như John và cộng sự [**?**] đã nhấn mạnh trong nghiên cứu phân cụm hành vi

khách hàng, việc lựa chọn số lượng cụm K tối ưu cần dựa trên các chỉ số hình học nội tại khách quan nhằm bảo đảm tính phân tách và độ đồng nhất của cụm. Tiêu chuẩn đánh giá phổ biến và tin cậy nhất là hệ số độ rộng bóng trung bình (Average Silhouette Width – ASW) của Rousseeuw [**?**]. Với mỗi chuỗi i, hệ số silhouette s_i so sánh khoảng cách trung bình nội cụm a_i với khoảng cách trung bình đến cụm lân cận gần nhất b_i:

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)} \in [-1, 1], \qquad \text{ASW} = \frac{1}{N} \sum_{i=1}^{N} s_i. \tag{2.3}$$

Giá trị s_i tiến gần 1 chứng tỏ chuỗi được phân vào đúng cụm và tách biệt rõ rệt với các cụm khác; giá trị gần 0 cho thấy chuỗi nằm ở ranh giới giữa hai cụm; và giá trị âm cảnh báo chuỗi có thể đã bị gán nhầm cụm. Chỉ số ASW đo lường mức độ gắn kết nội cụm và mức độ phân tách tổng thể của toàn bộ cấu trúc phân cụm, cung cấp tiêu chuẩn định lượng khách quan để xác định số lượng cụm K tối ưu trong phân tích chuỗi hành vi người dùng.

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

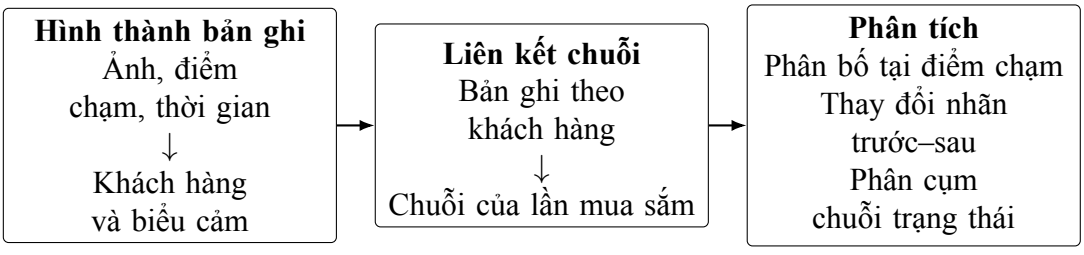
3.1 Tổng quan phương pháp

Giải pháp của luận văn là tổ chức và kết hợp kết quả nhận dạng biểu cảm tại nhiều điểm chạm, thay vì chỉ xem xét biểu cảm tại một vị trí cố định. Mỗi nhãn biểu cảm cần được đặt trong ngữ cảnh gồm khách hàng, điểm chạm, thời điểm và lần mua sắm tương ứng để có thể khảo sát diễn biến trong hành trình khách hàng. Trên cơ sở đó, luận văn đề xuất phương pháp gồm ba giai đoạn: hình thành bản ghi quan sát, liên kết các bản ghi thành chuỗi và phân tích các chuỗi đã hình thành.

Trong phạm vi nghiên cứu, mỗi điểm chạm được gắn với một khu vực xác định trước trong cửa hàng, chẳng hạn tiếp đón, tư vấn hoặc thanh toán. Đầu vào gồm hình ảnh rời, mã điểm chạm và thời gian ghi nhận. Danh sách điểm chạm và các mẫu khuôn mặt tham chiếu của khách hàng đã đăng ký là dữ liệu được chuẩn bị trước. Phương pháp chỉ nhận dạng các khách hàng đã có mẫu khuôn mặt trong kho tham chiếu. Nếu không tìm thấy mẫu phù hợp hoặc kết quả đối sánh không đạt ngưỡng chấp nhận, quan sát sẽ không được gắn với khách hàng và không được sử dụng để hình thành chuỗi hành trình cá nhân.

Phương pháp sử dụng ba cấp biểu diễn dữ liệu. *Bản ghi quan sát* chứa kết quả xử lý một khuôn mặt tại một điểm chạm và thời điểm cụ thể. *Chuỗi quan sát* là tập bản ghi của cùng khách hàng trong cùng một lần mua sắm, được sắp xếp theo thời gian. *Chuỗi trạng thái* là biểu diễn rút gọn của chuỗi quan sát, trong đó mỗi đoạn quan sát liên tiếp tại cùng điểm chạm được thay bằng một nhãn biểu cảm đại diện. Việc giữ cả chuỗi gốc và chuỗi rút gọn giúp kết quả phân tích có thể truy vết về dữ liệu đã tạo ra nó.

Quy trình tổng thể được trình bày tại Hình 3.1. Trước hết, ảnh được xử lý để phát hiện khuôn mặt, phân loại biểu cảm và đối sánh khách hàng. Tiếp theo, các bản ghi được phân tách theo khách hàng và lần mua sắm, kiểm tra thứ tự rồi tổ chức thành chuỗi. Cuối cùng, dữ liệu được sử dụng để mô tả phân bố biểu cảm, sự thay đổi nhãn giữa các điểm chạm và những nhóm chuỗi có diễn biến tương tự.



Hình 3.1: Ba giai đoạn của phương pháp đề xuất

Bảng 3.1 xác định đầu vào, quy tắc chính và đầu ra của từng giai đoạn. Mục 3.2 trình bày cách tạo một bản ghi tại điểm chạm; Mục 3.3 trình bày cơ chế hình thành chuỗi; Mục 3.4 trình bày các phép phân tích trên dữ liệu đó. Chương này tập trung vào mô hình dữ liệu, quy tắc biến đổi và tiêu chí phân tích của phương pháp đề xuất; kiến trúc phần mềm, giao diện, API và cách tổ chức các thành phần triển khai được trình bày riêng ở Chương 4.

Bảng 3.1: Phạm vi của từng giai đoạn trong phương pháp

Giai đoạn	**Đầu vào**	**Quy tắc chính**	**Đầu ra**
Hình thành bản ghi	Ảnh, điểm chạm, thời gian và kho mẫu khuôn mặt	Phát hiện khuôn mặt, phân loại biểu cảm, chấp nhận danh tính theo ngưỡng	Bản ghi của khách hàng tại điểm chạm
Liên kết chuỗi	Các bản ghi đã xác định khách hàng	Phân tách lần mua sắm, sắp xếp thời gian, gom đoạn điểm chạm	Chuỗi quan sát và chuỗi trạng thái
Phân tích	Bản ghi hoặc chuỗi đáp ứng điều kiện của phép phân tích	Thống kê nhãn, đếm cặp thay đổi, tính khoảng cách và phân cụm	Phân bố, các cặp nhãn và nhóm chuỗi tương tự

Phương pháp xem bảy nhãn biểu cảm là các trạng thái phân loại, không sử dụng chúng như kết quả đánh giá tổng thể về mức độ hài lòng của khách hàng. Nhận dạng khách hàng cung cấp căn cứ để liên kết các bản ghi, còn phân loại biểu cảm cung cấp trạng thái cho phép phân tích chuỗi; hai kết quả được xác định độc lập trước khi kết hợp trong cùng một bản ghi quan sát.

3.2 Phương pháp hình thành bản ghi tại các điểm chạm

Mục tiêu của giai đoạn này là chuyển dữ liệu ảnh thành một đơn vị quan sát có danh tính và ngữ cảnh cụ thể. Mỗi khuôn mặt được xử lý riêng; vì vậy, một ảnh có thể tạo nhiều bản ghi nếu chứa nhiều khách hàng được nhận dạng thành công. Nhãn biểu cảm của một khuôn mặt được kết hợp với kết quả đối sánh của chính vùng khuôn mặt đó.

3.2.1 Xác định dữ liệu đầu vào và ngữ cảnh điểm chạm

Một sự kiện thu nhận được biểu diễn bởi bộ dữ liệu (e, I, a, t), trong đó e là mã sự kiện, I là ảnh, a là mã điểm chạm và t là thời điểm ghi nhận ảnh. Phương pháp giả định mã điểm chạm thuộc tập điểm chạm đã xác định trước, ảnh có thể giải mã và thời điểm có đủ thông tin để quy đổi về cùng một mốc so sánh. Thời điểm thu nhận ảnh, thay vì thời điểm xử lý, được sử dụng để thiết lập thứ tự quan sát.

Mã sự kiện e dùng để phân biệt các lần thu nhận và loại bỏ bản sao của cùng một

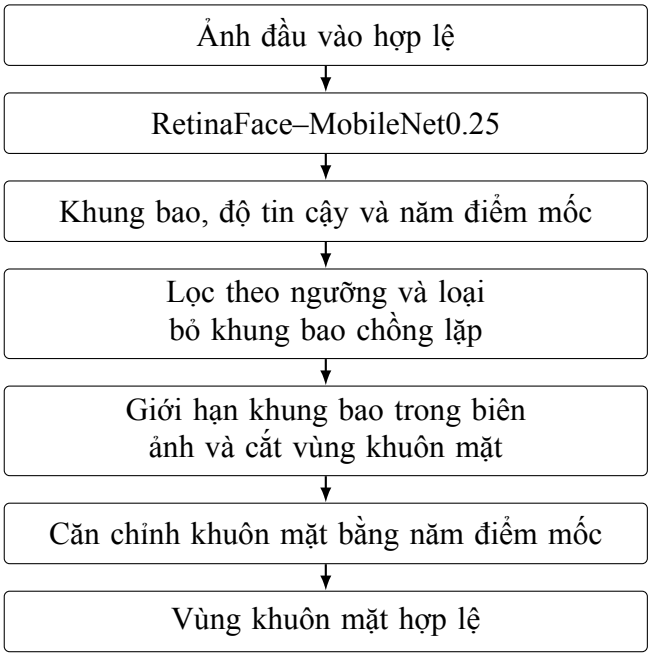
sự kiện. Hai ảnh khác nhau được ghi nhận liên tiếp vẫn là hai sự kiện độc lập, kể cả khi chứa cùng một khách hàng. Vì vậy, số lượng quan sát phụ thuộc vào chiến lược lấy mẫu ảnh; tần suất lấy mẫu cần được giữ nhất quán hoặc được kiểm soát khi so sánh phân bố giữa các điểm chạm.

3.2.2 Phát hiện và trích xuất vùng khuôn mặt

Phương pháp sử dụng RetinaFace với mạng nền MobileNet0.25 để định vị khuôn mặt. Cấu hình này được lựa chọn vì đạt sự cân bằng tốt giữa chất lượng phát hiện và tốc độ xử lý trên CPU trong thực nghiệm so sánh với Haar Cascade và MTCNN; kết quả chi tiết được trình bày tại Mục 5.1.2. Bộ phát hiện trả về khung bao, điểm tin cậy phát hiện và các điểm mốc khuôn mặt. Các khung bao được lọc theo ngưỡng tin cậy phát hiện và bước loại bỏ khung bao chồng lặp. Ngưỡng này kiểm soát việc chấp nhận một vùng ảnh là khuôn mặt, khác với ngưỡng đối sánh danh tính ở bước sau.

Với mỗi khuôn mặt được phát hiện, tọa độ khung bao được giới hạn trong phạm vi ảnh trước khi cắt vùng ảnh tương ứng. Vùng khuôn mặt chỉ được chấp nhận khi có chiều rộng và chiều cao lớn hơn không. Ảnh không có vùng khuôn mặt hợp lệ không tạo ra bản ghi quan sát. Nếu ảnh có nhiều khuôn mặt, mỗi vùng hợp lệ được xem là một ứng viên quan sát độc lập, còn vùng cắt không hợp lệ bị loại. Các vùng khuôn mặt hợp lệ sau đó được chuyển đồng thời sang nhánh phân loại biểu cảm và nhánh trích xuất đặc trưng danh tính.

Vùng khuôn mặt được cắt ở bước trước được căn chỉnh hình học bằng năm điểm mốc do RetinaFace xác định, gồm hai mắt, mũi và hai khóe miệng. Từ các điểm mốc này, phương pháp ước lượng phép biến đổi đồng dạng để xoay, thay đổi tỷ lệ và đưa khuôn mặt về vị trí chuẩn. Quy trình từ ảnh đầu vào đến vùng khuôn mặt hợp lệ được tóm tắt tại Hình 3.2. Ảnh sau căn chỉnh được sử dụng làm đầu vào chung cho nhánh phân loại biểu cảm và nhánh trích xuất đặc trưng danh tính. Trước khi suy luận, mỗi nhánh tiếp tục thay đổi kích thước và chuẩn hóa ảnh theo yêu cầu của mô hình tương ứng. Việc căn chỉnh giúp giảm ảnh hưởng của độ nghiêng và sự khác biệt về tỷ lệ khuôn mặt; tuy nhiên, độ sáng, độ mờ, che khuất và sai số phát hiện điểm mốc vẫn có thể ảnh hưởng đến kết quả phân loại biểu cảm và đối sánh danh tính.



Hình 3.2: Quy trình phát hiện, cắt và căn chỉnh vùng khuôn mặt

3.2.3 Xác định nhãn biểu cảm của quan sát

Nhánh biểu cảm sử dụng mô hình CNN Emotion được cung cấp bởi thư viện DeepFace. Vùng khuôn mặt được chuyển thành ảnh xám và đưa về kích thước 48×48 pixel trước khi vào bộ phân loại. Mô hình trả về điểm số cho bảy lớp: *Angry*, *Disgust*, *Fear*, *Happy*, *Sad*, *Surprise* và *Neutral* [**?**]. Gọi tập nhãn này là $\mathcal{E}$ và p_k là điểm đầu ra của lớp k trên thang $[0, 1]$, nhãn và mức tin cậy của quan sát được xác định bởi

$$\widehat{y} = \arg\max_{k \in \mathcal{E}} p_k, \qquad q = \max_{k \in \mathcal{E}} p_k. \tag{3.1}$$

Bản ghi quan sát giữ nhãn $\widehat{y}$, mức tin cậy q và véc-tơ điểm số của cả bảy lớp. Mức tin cậy được sử dụng khi lựa chọn quan sát đại diện hoặc xử lý trường hợp các nhãn có cùng tần suất. Ví dụ, nếu *Happy* và *Neutral* có cùng số lần xuất hiện lớn nhất, nhãn có tổng mức tin cậy cao hơn được ưu tiên. Khi không thu được kết quả suy luận hợp lệ, trường biểu cảm được xem là thiếu dữ liệu thay vì tự động gán một nhãn mặc định như *Neutral*.

3.2.4 Xác định khách hàng bằng đối sánh khuôn mặt

Nhánh nhận dạng danh tính sử dụng mô hình ArcFace được cung cấp bởi thư viện DeepFace để chuyển vùng khuôn mặt đã căn chỉnh thành véc-tơ đặc trưng $\boldsymbol{z} \in \mathbb{R}^{512}$ [13]. Tập tham chiếu gồm các véc-tơ đặc trưng $\boldsymbol{z}_j$ được tạo từ ảnh khuôn mặt mẫu của khách hàng. Đối với mỗi vùng khuôn mặt được phát hiện và căn chỉnh ở bước trước, khoảng cách cô-sin giữa véc-tơ $\boldsymbol{z}$ vừa tạo và từng véc-tơ tham chiếu

$\boldsymbol{z}_j$ được tính theo:

$$d(\boldsymbol{z}, \boldsymbol{z}_j) = 1 - \frac{\boldsymbol{z}^{\mathsf{T}} \boldsymbol{z}_j}{\|\boldsymbol{z}\|_2 \|\boldsymbol{z}_j\|_2}. \tag{3.2}$$

Khoảng cách càng nhỏ thì hai véc-tơ càng giống nhau. Mẫu tham chiếu có khoảng cách nhỏ nhất được xác định bởi:

$$j^* = \arg\min_j d(\boldsymbol{z}, \boldsymbol{z}_j), \qquad d_{\min} = d(\boldsymbol{z}, \boldsymbol{z}_{j^*}). \tag{3.3}$$

Khách hàng gắn với mẫu $\boldsymbol{z}_{j^*}$ được xác định là người xuất hiện trong ảnh khi $d_{\min} \leq \tau_{\text{id}}$, trong đó τ_{id} là ngưỡng đối sánh danh tính. Nếu $d_{\min} > \tau_{\text{id}}$, khuôn mặt được xem là không khớp với khách hàng nào trong tập tham chiếu. Khi một khách hàng có nhiều ảnh mẫu, phép so sánh được thực hiện với từng mẫu và sử dụng khoảng cách nhỏ nhất làm căn cứ quyết định.

Luận văn kế thừa phương pháp phân tích đường cong ROC [**?**] để xác định ngưỡng đối sánh τ_{id}. Từ tập ảnh hiệu chỉnh, các cặp ảnh cùng người và các cặp ảnh của hai người khác nhau được tạo ra, sau đó khoảng cách cô-sin được tính cho từng cặp. Các giá trị khoảng cách quan sát được lần lượt được xem là ngưỡng ứng viên. Tại mỗi ngưỡng, tỷ lệ nhận đúng được tính trên các cặp cùng người và tỷ lệ nhận nhầm được tính trên các cặp khác người; hai tỷ lệ này tạo thành một điểm trên đường cong ROC. Phương án đề xuất đặt tỷ lệ nhận nhầm mục tiêu bằng 0 và chọn ngưỡng có tỷ lệ nhận đúng cao nhất trong số các ngưỡng đáp ứng điều kiện này. Nếu nhiều ngưỡng cho cùng tỷ lệ nhận đúng, ngưỡng lớn nhất được chọn.

3.2.5 Kết hợp kết quả thành bản ghi tại điểm chạm

Một bản ghi quan sát được hình thành khi vùng khuôn mặt có thể gắn với một khách hàng theo quy tắc đối sánh ở Mục 3.2.4. Bản ghi kết hợp danh tính, biểu cảm và ngữ cảnh thu nhận của cùng một vùng khuôn mặt. Các nhóm thông tin cần thiết cho các bước liên kết và phân tích tiếp theo được trình bày tại Bảng 3.2.

Điều kiện hình thành quan sát của khách hàng và điều kiện sử dụng nhãn biểu cảm cần được phân biệt. Nếu danh tính được xác định nhưng biểu cảm không hợp lệ, quan sát vẫn có thể tham gia xác định lần mua sắm nhưng không đóng góp nhãn cho thống kê hoặc chuỗi trạng thái. Ngược lại, nếu phân loại được biểu cảm nhưng không xác định được khách hàng, kết quả không được đưa vào chuỗi hành trình cá nhân trong phạm vi phương pháp này.

Đầu ra của giai đoạn là các bản ghi tại điểm chạm có mã khách hàng và thời gian, cùng thông tin cho biết biểu cảm có hợp lệ hay không. Việc ghép các bản ghi thành một lần mua sắm được thực hiện theo cơ chế ở Mục 3.3.

Bảng 3.2: Thông tin được giữ trong một bản ghi quan sát

Nhóm thông tin	**Nội dung và mục đích**
Nguồn quan sát	Mã sự kiện, chỉ số khuôn mặt và khung bao để phân biệt các khuôn mặt trong cùng ảnh và truy vết nguồn
Ngữ cảnh điểm chạm	Mã điểm chạm và thời điểm ảnh được ghi nhận
Danh tính	Mã khách hàng đã được chấp nhận và khoảng cách đến mẫu tham chiếu được chọn
Biểu cảm	Nhãn dự đoán, mức tin cậy và điểm số của bảy lớp; để trống nếu phân loại không thành công
Chất lượng và khả năng truy vết	Chỉ báo hợp lệ của ảnh, danh tính và biểu cảm; thông tin nguồn và mô hình cần thiết để kiểm tra điều kiện phân tích

3.3 Cơ chế liên kết chuỗi biểu cảm

Giai đoạn liên kết xác định các bản ghi thuộc cùng một lần mua sắm và sắp xếp chúng thành chuỗi theo thời gian. Trước hết, các bản ghi được nhóm theo mã khách hàng. Trong từng nhóm, khoảng cách thời gian giữa các bản ghi được sử dụng để phân chia thành các lần mua sắm. Sau đó, các bản ghi của mỗi lần mua sắm được sắp xếp theo thời gian ghi nhận để tạo chuỗi quan sát.

3.3.1 Nguyên tắc phân tách bản ghi theo khách hàng và lần mua sắm

Các bản ghi được nhóm theo mã khách hàng và sắp xếp theo thời gian ghi nhận. Nếu khoảng thời gian giữa hai bản ghi liên tiếp không vượt quá ngưỡng Δ, các bản ghi này được xếp vào cùng một lần mua sắm. Nếu khoảng thời gian vượt quá Δ, bản ghi sau được xem là điểm bắt đầu của một lần mua sắm mới. Trong phương án đề xuất, ngưỡng được chọn là $\Delta = 30$ phút.

Gọi t_{last} là thời điểm của quan sát gần nhất trong lần mua sắm đang xét và t_i là thời điểm của bản ghi kế tiếp sau khi sắp xếp. Nếu chưa hình thành lần mua sắm, bản ghi đầu tiên khởi tạo một lần mới; nếu đã có, bản ghi được đưa vào lần hiện tại khi

$$0 \leq t_i - t_{\text{last}} \leq \Delta. \tag{3.4}$$

Khi $t_i - t_{\text{last}} > \Delta$, lần trước kết thúc tại mốc quan sát cuối của nó và bản ghi kế tiếp bắt đầu một lần mua sắm khác. Khu vực thanh toán hoặc sự xuất hiện của đơn hàng không tự quyết định ranh giới chuỗi.

Ngưỡng Δ ảnh hưởng trực tiếp đến dữ liệu phân tích: ngưỡng quá ngắn có thể chia một lần mua sắm thành nhiều chuỗi, còn ngưỡng quá dài có thể ghép hai lần đến cửa hàng. Vì vậy, cần giữ cố định ngưỡng trong một phép so sánh và đánh giá lại khi thay đổi bối cảnh thu nhận. Cơ chế cũng phụ thuộc vào chất lượng đối sánh danh tính; nhận dạng nhầm có thể đưa bản ghi vào sai khách hàng trước khi quy

tắc sắp xếp các bản ghi theo thời gian được áp dụng.

3.3.2 Xử lý quan sát thiếu hoặc xung đột

Trong một lần mua sắm v, chuỗi quan sát được biểu diễn dưới dạng

$$O_v = (o_{v,1}, o_{v,2}, \ldots, o_{v,n_v}), \qquad t_{v,1} \leq t_{v,2} \leq \cdots \leq t_{v,n_v}, \tag{3.5}$$

trong đó mỗi $o_{v,i}$ chứa điểm chạm, thời gian và kết quả xử lý của một bản ghi. Nếu nhiều bản ghi có cùng thời gian, mã bản ghi chỉ được dùng làm tiêu chí phụ để tạo thứ tự xác định, không được diễn giải là thứ tự xảy ra thực tế của các quan sát.

Nếu cùng một thời điểm có các bản ghi tại những điểm chạm khác nhau trong một lần mua sắm, các bản ghi đó được xem là xung đột thứ tự. Chúng vẫn có thể đóng góp vào thống kê độc lập tại điểm chạm nếu biểu cảm hợp lệ, nhưng bị loại trước khi tạo cặp thay đổi và chuỗi trạng thái để phân cụm. Phương pháp không chọn một bản ghi để giữ lại chỉ vì nó có mức tin cậy biểu cảm hoặc điểm đối sánh tốt hơn.

Khi một khu vực dự kiến không có quan sát, phương pháp ghi nhận tình trạng thiếu dữ liệu, không chèn một nhãn giả định vào chuỗi. Dữ liệu thiếu có thể do khách hàng không đi qua khu vực, nguồn thu nhận bỏ lỡ hoặc mô hình không tạo được kết quả hợp lệ. Vì vậy, chuỗi sau khi lọc chỉ phản ánh các điểm chạm đã được ghi nhận; giữa hai quan sát liên tiếp vẫn có thể tồn tại điểm chạm không được quan sát.

Các bản ghi của cùng một khách hàng phải được sắp xếp theo thời gian trước khi chia thành từng lần mua sắm vì quy tắc phân tách dựa trên khoảng cách giữa các quan sát liên tiếp. Ví dụ, ba bản ghi tại 09:00, 09:20 và 09:40 đều cách bản ghi liền trước không quá 30 phút nên thuộc cùng một lần mua sắm. Nếu áp dụng quy tắc trên một thứ tự khác với thứ tự thời gian, ranh giới lần mua sắm có thể bị xác định sai. Do đó, thứ tự thu nhận hoặc thứ tự xử lý không được dùng thay cho thời điểm quan sát trong quy tắc tại Mục 3.3.1.

3.3.3 Gom quan sát thành các chuỗi dữ liệu tại điểm chạm

Đầu vào của bước này là chuỗi quan sát đã được xử lý tại Mục 3.3.2. Những bản ghi liên tiếp có cùng mã điểm chạm được gom thành một chuỗi dữ liệu tại điểm chạm. Mỗi chuỗi dữ liệu được đặc trưng bởi mã điểm chạm, thời gian của bản ghi đầu tiên và cuối cùng, tập bản ghi thành phần và tổng số quan sát. Một chuỗi dữ liệu mới được xác lập khi mã điểm chạm thay đổi.

Ví dụ, dãy điểm chạm A, A, B, B, A được chia thành ba chuỗi dữ liệu theo thứ tự $A \to B \to A$. Chuỗi thứ nhất gồm hai bản ghi đầu tại A, chuỗi thứ hai gồm hai bản

ghi tại B và chuỗi thứ ba gồm bản ghi cuối tại A. Bản ghi tại A ở cuối dãy không được gộp với hai bản ghi tại A ở đầu dãy vì giữa chúng có các bản ghi tại điểm B. Cách xử lý này thể hiện việc khách hàng rời điểm A, chuyển sang điểm B rồi quay lại điểm A.

Việc gom các bản ghi giúp nhiều ảnh được ghi nhận liên tiếp tại cùng một điểm chạm không làm chuỗi dài thêm không cần thiết. Nhờ đó, chuỗi thể hiện thứ tự khách hàng xuất hiện tại các điểm chạm thay vì số lượng ảnh được ghi nhận tại từng vị trí. Các chuỗi dữ liệu tại điểm chạm là đầu vào của bước lựa chọn biểu cảm đại diện được trình bày tại Mục 3.3.4.

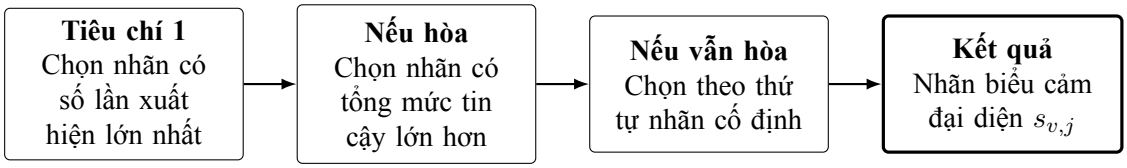
3.3.4 Tiêu chí lựa chọn nhãn biểu cảm đại diện

Để tạo chuỗi trạng thái dùng cho phân cụm toàn bộ diễn biến biểu cảm, mỗi chuỗi dữ liệu tại điểm chạm được biểu diễn bằng một nhãn. Phương pháp lựa chọn nhãn biểu cảm đại diện dựa trên số lần xuất hiện và mức tin cậy của các nhãn trong chuỗi dữ liệu.

Gọi $G_{v,j}$ là tập bản ghi thuộc chuỗi dữ liệu thứ j của lần mua sắm v, và $n_j(k)$ là số bản ghi mang nhãn biểu cảm k trong chuỗi dữ liệu đó. Nhãn xuất hiện nhiều nhất được chọn làm nhãn đại diện:

$$s_{v,j} \in \arg\max_{k \in \mathcal{E}} n_j(k). \tag{3.6}$$

Nếu nhiều nhãn có cùng số lần xuất hiện lớn nhất, tổng mức tin cậy của các bản ghi thuộc từng nhãn được tính và nhãn có tổng mức tin cậy cao hơn được lựa chọn. Nếu số lần xuất hiện và tổng mức tin cậy vẫn bằng nhau, nhãn đứng trước trong thứ tự cố định *Angry*, *Disgust*, *Fear*, *Happy*, *Sad*, *Surprise*, *Neutral* được sử dụng làm nhãn đại diện. Thứ tự áp dụng các tiêu chí được trình bày tại Hình 3.3.



Hình 3.3: Thứ tự ưu tiên khi lựa chọn nhãn biểu cảm đại diện

3.4 Phương pháp phân tích

Trên cơ sở các phương pháp phân tích chuỗi được trình bày tại Mục 2.5, luận văn áp dụng Optimal Matching để đo độ khác biệt giữa các chuỗi trạng thái, PAM để phân cụm các chuỗi tương tự và Average Silhouette Width để hỗ trợ lựa chọn số cụm. Phương pháp phân tích được tổ chức theo ba mức: thống kê phân bố biểu

cảm tại từng điểm chạm, xác định sự thay đổi biểu cảm giữa các điểm chạm liên tiếp và phân cụm toàn bộ chuỗi trạng thái. Mỗi mức phân tích sử dụng một dạng dữ liệu đầu vào và cung cấp một góc nhìn khác nhau về diễn biến biểu cảm trong quá trình mua sắm.

3.4.1 Phân tích phân bố và thay đổi biểu cảm theo điểm chạm

Phân tích ở cấp điểm chạm được thực hiện theo hai mức bổ sung cho nhau. Mức thứ nhất mô tả cơ cấu biểu cảm tại từng điểm chạm; mức thứ hai xem xét sự chuyển đổi biểu cảm giữa hai điểm chạm liên tiếp trong cùng một lần mua sắm. Cách tổ chức này cho phép vừa nhận diện trạng thái biểu cảm phổ biến tại mỗi khu vực, vừa theo dõi chiều hướng thay đổi của biểu cảm trong hành trình khách hàng.

Phân bố biểu cảm tại từng điểm chạm. Đơn vị thống kê là một bản ghi có ảnh hợp lệ, xác định được khách hàng và có nhãn biểu cảm hợp lệ. Tại mỗi điểm chạm trong khoảng thời gian được chọn, gọi n_k là số bản ghi mang biểu cảm thứ k, với $k = 1, 2, \ldots, 7$. Tổng số bản ghi N và tỷ lệ P_k của từng biểu cảm được tính theo

$$N = n_1 + n_2 + \cdots + n_7, \qquad P_k = \frac{n_k}{N} \times 100\%. \tag{3.7}$$

Kết quả trình bày đồng thời số lượng và tỷ lệ của từng nhãn. Khoảng thời gian phân tích có thể được chia thành các khoảng nhỏ hơn và áp dụng cùng phép đếm để quan sát sự thay đổi tại một điểm chạm. Khi so sánh các khu vực hoặc các khoảng thời gian, phạm vi dữ liệu và cách lấy mẫu được giữ thống nhất.

Thay đổi biểu cảm giữa các điểm chạm. Phép phân tích sử dụng các đoạn điểm chạm đã được hình thành từ bản ghi hợp lệ và không xung đột thời gian. Biểu cảm của mỗi đoạn có thể được xác định theo ba quy tắc, tùy mục tiêu phân tích: nhãn của bản ghi đầu tiên mô tả trạng thái khi bắt đầu được quan sát, nhãn của bản ghi cuối cùng mô tả trạng thái ở cuối đoạn, còn nhãn của bản ghi có mức tin cậy cao nhất đại diện cho quan sát rõ nhất trong đoạn. Phương án đề xuất sử dụng quy tắc mức tin cậy cao nhất và áp dụng nhất quán trên toàn bộ tập dữ liệu được so sánh.

Hai đoạn liên tiếp trong cùng một lần mua sắm tạo một cặp có hướng từ điểm chạm trước sang điểm chạm sau. Với chuỗi đoạn $A \to B \to C$, các cặp được tạo là $A \to B$ và $B \to C$.

Với mỗi hướng di chuyển giữa hai điểm chạm, gọi $n_{k,l}$ là số cặp có biểu cảm k tại điểm chạm trước và biểu cảm l tại điểm chạm sau; N là tổng số cặp quan sát theo hướng đó. Tỷ lệ của từng tổ hợp biểu cảm được tính theo

$$P_{k,l} = \frac{n_{k,l}}{N} \times 100\%. \tag{3.8}$$

Mỗi lần xuất hiện của một cặp điểm chạm được tính là một cặp quan sát. Trường hợp $k = l$ biểu thị nhãn được giữ nguyên, còn $k \neq l$ biểu thị nhãn đã thay đổi. Kết quả gồm số lượng và tỷ lệ của từng tổ hợp biểu cảm giữa hai điểm chạm.

3.4.2 Phân cụm chuỗi trạng thái và lựa chọn số cụm

Quy trình phân cụm gồm ba bước liên tiếp: đo độ khác biệt giữa các chuỗi trạng thái bằng Optimal Matching (OM), phân cụm từ ma trận khoảng cách bằng PAM và lựa chọn số cụm bằng Average Silhouette Width (ASW). Các phương pháp này đã được trình bày tại Mục 2.5.2.

Trước hết, OM được sử dụng để đo độ khác biệt giữa từng cặp chuỗi trạng thái S_v được hình thành tại Mục 3.3.4. Đầu vào của phép so sánh gồm các nhãn biểu cảm được sắp xếp theo thứ tự xuất hiện của các chuỗi dữ liệu tại điểm chạm.

Khi áp dụng OM, chi phí chèn và xóa được đặt bằng 1. Chi phí thay thế bằng 0 đối với hai nhãn giống nhau và bằng 2 đối với hai nhãn khác nhau; mức chi phí này được áp dụng như nhau cho mọi cặp nhãn biểu cảm. Khoảng cách được giữ ở dạng giá trị thô và không chuẩn hóa theo độ dài chuỗi.

Các khoảng cách OM giữa từng cặp chuỗi được tổng hợp thành ma trận khoảng cách D có kích thước $N \times N$, với N là số chuỗi được đưa vào phân tích. Mã điểm chạm, thời điểm và thời lượng được giữ làm thông tin mô tả chuỗi, nhưng không tham gia trực tiếp vào phép tính khoảng cách OM.

Tiếp theo, ma trận khoảng cách D được đưa vào PAM để phân cụm các chuỗi trạng thái. Với mỗi giá trị K, kết quả gồm nhãn cụm của từng chuỗi và chuỗi medoid đại diện cho mỗi cụm.

Phương pháp khảo sát lần lượt các giá trị K bắt đầu từ 2. Giới hạn trên của K được xác định từ tổng số chuỗi, số chuỗi trạng thái phân biệt, kích thước cụm tối thiểu và giới hạn khảo sát đặt trước. Kích thước cụm tối thiểu được lấy theo giá trị lớn hơn giữa số lượng tối thiểu tuyệt đối và tỷ lệ tối thiểu trên tổng số chuỗi. Các phương án tạo ra cụm nhỏ hơn giới hạn này bị loại khỏi tập ứng viên.

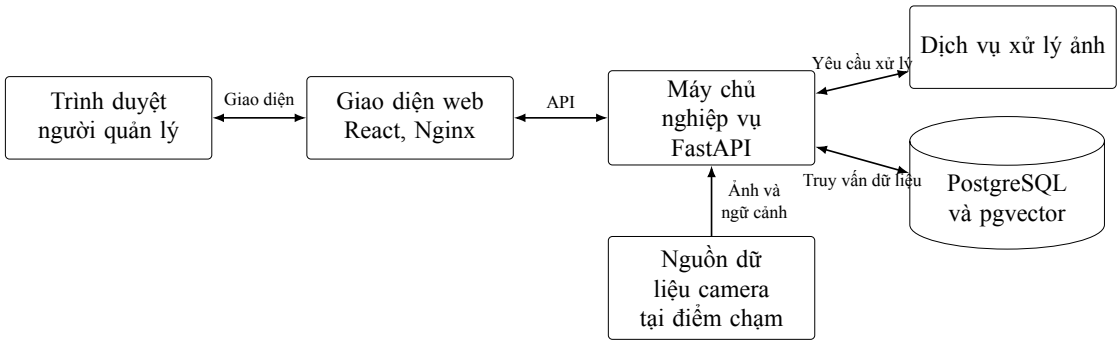
ASW được tính cho từng phương án còn lại. Gọi A^* là giá trị ASW lớn nhất, luận văn chọn giá trị K nhỏ nhất có ASW không thấp hơn $A^* - \varepsilon$, với $\varepsilon = 0{,}02$. Kết quả cuối cùng gồm số cụm được chọn, chuỗi medoid của từng cụm, số chuỗi trong cụm, nhãn cụm của từng lần mua sắm, khoảng cách đến medoid và hệ số silhouette.

CHƯƠNG 4. XÂY DỰNG VÀ PHÁT TRIỂN HỆ THỐNG

4.1 Tổng quan hệ thống

Hệ thống được xây dựng để quản lý dữ liệu khách hàng, tiếp nhận dữ liệu ảnh từ camera tại các điểm chạm, nhận dạng khách hàng, ghi nhận biểu cảm và tổng hợp diễn biến biểu cảm trong từng lần mua sắm. Luồng xử lý bắt đầu khi nguồn dữ liệu camera gửi ảnh kèm mã sự kiện, điểm chạm và thời gian ghi nhận. Kết quả xử lý ảnh được kết hợp với dữ liệu khách hàng để tạo bản ghi quan sát, liên kết vào lần mua sắm và cung cấp dữ liệu cho các chức năng phân tích.

Kiến trúc hệ thống gồm giao diện web, máy chủ nghiệp vụ, dịch vụ xử lý ảnh và cơ sở dữ liệu; nguồn dữ liệu camera là tác nhân bên ngoài cung cấp ảnh tại các điểm chạm. Giao diện web tiếp nhận thao tác của người quản lý. Máy chủ nghiệp vụ cung cấp API, thực hiện các quy tắc quản lý dữ liệu và điều phối quá trình xử lý ảnh. Dịch vụ xử lý ảnh phát hiện khuôn mặt, phân loại biểu cảm và tạo véc-tơ đặc trưng danh tính. Cơ sở dữ liệu lưu thông tin khách hàng, mẫu khuôn mặt, điểm chạm, sản phẩm, đơn hàng, sự kiện ảnh, bản ghi quan sát, lần mua sắm và kết quả phân cụm.



Hình 4.1: Kiến trúc tổng quan của hệ thống

Bảng 4.1 trình bày công nghệ và nhiệm vụ của các thành phần phần mềm. Các thành phần này được đóng gói thành các dịch vụ riêng và được khởi chạy bằng Docker Compose. Nguồn dữ liệu camera được biểu diễn như một thành phần bên ngoài, cung cấp dữ liệu đầu vào cho máy chủ nghiệp vụ qua giao diện tiếp nhận ảnh; thành phần này không nằm trong phạm vi xây dựng của hệ thống.

Bảng 4.1: Các thành phần của hệ thống

Thành phần	Công nghệ	Nhiệm vụ
Giao diện web	React, TypeScript, Ant Design, ECharts, Nginx	Hiển thị các chức năng CRM, theo dõi lần mua sắm, báo cáo biểu cảm và kết quả phân cụm chuỗi.
Máy chủ nghiệp vụ	FastAPI, SQLAlchemy	Xác thực người dùng, cung cấp API, quản lý dữ liệu, gọi dịch vụ xử lý ảnh, đối sánh khách hàng và liên kết bản ghi theo lần mua sắm.
Dịch vụ xử lý ảnh	FastAPI, OpenCV, RetinaFace–MobileNet0.25, DeepFace Emotion, ArcFace	Phát hiện và căn chỉnh khuôn mặt, phân loại biểu cảm, tạo véc-tơ đặc trưng danh tính và trả kết quả theo từng khuôn mặt.
Cơ sở dữ liệu	PostgreSQL, pgvector, Alembic	Lưu dữ liệu nghiệp vụ, véc-tơ khuôn mặt và kết quả phân tích; quản lý thay đổi cấu trúc cơ sở dữ liệu.

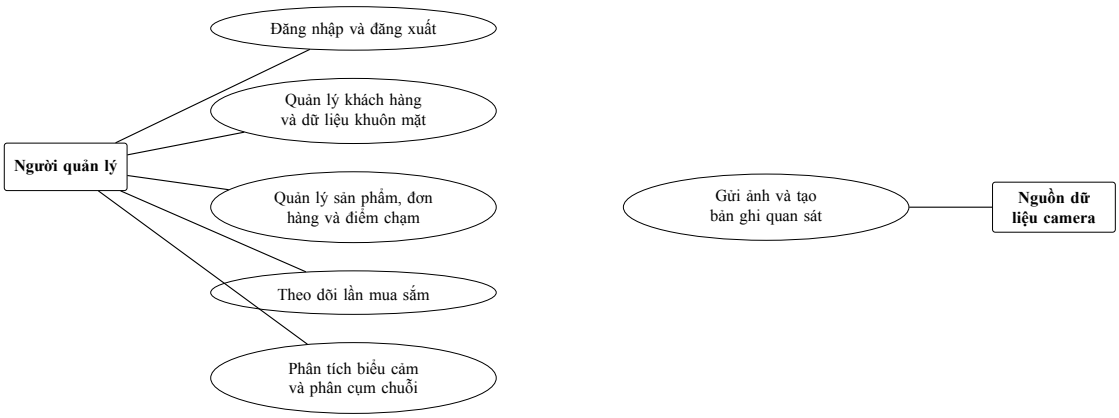
Khi nhận một sự kiện ảnh, máy chủ nghiệp vụ kiểm tra dữ liệu đầu vào rồi chuyển ảnh sang dịch vụ xử lý ảnh. Mỗi khuôn mặt hợp lệ tạo một kết quả gồm khung bao, nhãn biểu cảm, mức tin cậy và véc-tơ đặc trưng. Máy chủ sử dụng véc-tơ này để đối sánh với dữ liệu khuôn mặt đã lưu. Khi xác định được khách hàng, bản ghi quan sát được tạo và liên kết với lần mua sắm tương ứng. Các bản ghi sau đó được sử dụng để thống kê biểu cảm tại điểm chạm, phân tích sự thay đổi giữa các điểm chạm và phân cụm chuỗi trạng thái.

4.2 Cài đặt hệ thống

Các chức năng được cài đặt dựa trên kiến trúc tại Hình 4.1. Phần này trình bày tác nhân sử dụng, cách phân rã chức năng và đặc tả các chức năng chính đã được xây dựng.

4.2.1 Usecase tổng quan

Hệ thống có hai tác nhân chính. Người quản lý sử dụng giao diện web để quản lý dữ liệu và xem kết quả phân tích. Nguồn dữ liệu camera gửi ảnh cùng thông tin điểm chạm và thời gian để tạo dữ liệu quan sát. Các use case tổng quan được thể hiện tại Hình 4.2.

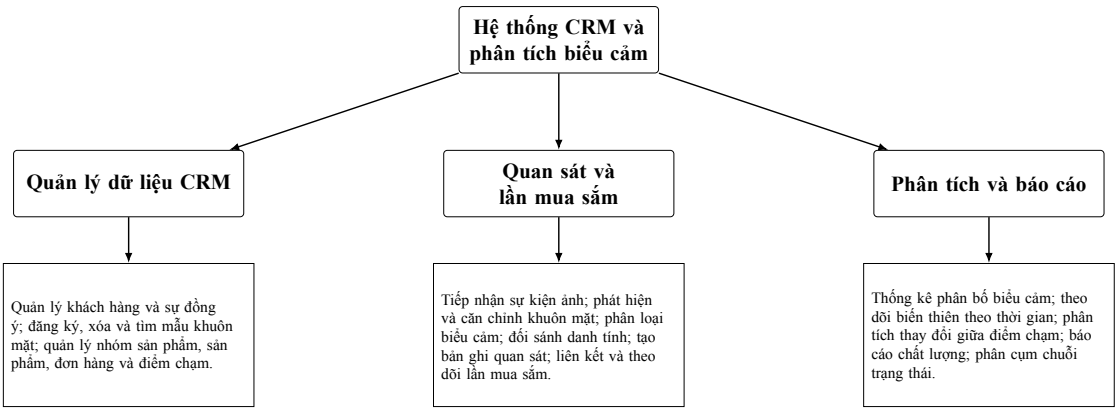


Hình 4.2: Usecase tổng quan của hệ thống

Người quản lý đăng nhập trước khi sử dụng các chức năng nghiệp vụ. Nhóm quản lý dữ liệu gồm khách hàng, mẫu khuôn mặt, sản phẩm, đơn hàng và điểm chạm. Nhóm theo dõi trình bày các bản ghi theo từng lần mua sắm. Nhóm phân tích cung cấp phân bố biểu cảm, sự thay đổi giữa các điểm chạm, chất lượng dữ liệu và phân cụm chuỗi trạng thái. Nguồn dữ liệu camera tương tác với chức năng tạo bản ghi quan sát thông qua API.

4.2.2 Phân rã chức năng

Các chức năng của hệ thống được chia thành ba nhóm: quản lý dữ liệu CRM, xử lý quan sát và lần mua sắm, phân tích và báo cáo. Cấu trúc phân rã được thể hiện tại Hình 4.3.



Hình 4.3: Phân rã chức năng của hệ thống

Nhóm quản lý dữ liệu CRM cung cấp thông tin khách hàng và dữ liệu mua hàng. Nhóm quan sát tiếp nhận ảnh, tạo kết quả nhận dạng và tổ chức các bản ghi theo từng lần mua sắm. Nhóm phân tích sử dụng các bản ghi đã hình thành để tạo báo cáo và chuỗi trạng thái. Dữ liệu được trao đổi giữa ba nhóm thông qua máy chủ nghiệp vụ và cơ sở dữ liệu.

4.2.3 Đặc tả chức năng

Các use case chính được đặc tả theo tác nhân, điều kiện thực hiện, luồng xử lý và kết quả đầu ra.

Bảng 4.2: Đặc tả UC01 – Đăng nhập

Mã use case	UC01
Tên chức năng	Đăng nhập
Tác nhân	Người quản lý
Sự kiện kích hoạt	Người quản lý mở trang đăng nhập và gửi thông tin tài khoản.
Tiền điều kiện	Tài khoản đã được tạo trong hệ thống.
Luồng chính	1) Nhập địa chỉ thư điện tử và mật khẩu; 2) giao diện gửi yêu cầu xác thực; 3) máy chủ kiểm tra tài khoản và mật khẩu; 4) phiên đăng nhập được tạo; 5) giao diện chuyển đến trang tổng quan.
Luồng thay thế	Thông tin không hợp lệ được trả về cùng thông báo đăng nhập không thành công.
Kết quả	Người quản lý truy cập được các chức năng của hệ thống.

Bảng 4.3: Đặc tả UC02 – Quản lý khách hàng và dữ liệu khuôn mặt

Mã use case	UC02
Tên chức năng	Quản lý khách hàng và dữ liệu khuôn mặt
Tác nhân	Người quản lý
Sự kiện kích hoạt	Người quản lý mở chức năng Khách hàng hoặc Dữ liệu khuôn mặt.
Tiền điều kiện	Người quản lý đã đăng nhập.
Luồng chính	1) Tạo hoặc chọn hồ sơ khách hàng; 2) cập nhật thông tin và trạng thái đồng ý sử dụng dữ liệu khuôn mặt; 3) chọn ảnh đăng ký; 4) dịch vụ xử lý ảnh tạo véc-tơ đặc trưng; 5) máy chủ lưu mẫu khuôn mặt gắn với khách hàng; 6) hồ sơ và lịch sử mua hàng được hiển thị khi tra cứu.
Luồng thay thế	Ảnh không đọc được hoặc không có khuôn mặt hợp lệ được trả về trạng thái lỗi tương ứng.
Kết quả	Hồ sơ khách hàng và mẫu khuôn mặt được lưu trong cơ sở dữ liệu.

Bảng 4.4: Đặc tả UC03 – Quản lý sản phẩm, đơn hàng và điểm chạm

Mã use case	UC03
Tên chức năng	Quản lý sản phẩm, đơn hàng và điểm chạm
Tác nhân	Người quản lý
Sự kiện kích hoạt	Người quản lý chọn chức năng Sản phẩm, Mua hàng hoặc Khu vực.
Tiền điều kiện	Người quản lý đã đăng nhập.
Luồng chính	1) Tạo nhóm sản phẩm và sản phẩm; 2) khai báo các điểm chạm cùng thứ tự; 3) tạo đơn hàng cho khách hàng; 4) thêm sản phẩm và số lượng; 5) máy chủ tính giá trị từng dòng và tổng đơn; 6) đơn hàng được liên kết với lần mua sắm phù hợp.
Luồng thay thế	Dữ liệu thiếu trường bắt buộc hoặc tham chiếu đến khách hàng, sản phẩm hay điểm chạm không tồn tại được từ chối.
Kết quả	Danh mục, điểm chạm và lịch sử mua hàng được cập nhật.

Bảng 4.5: Đặc tả UC04 – Tiếp nhận ảnh và tạo bản ghi quan sát

Mã use case	UC04
Tên chức năng	Tiếp nhận ảnh và tạo bản ghi quan sát
Tác nhân	Nguồn dữ liệu camera
Sự kiện kích hoạt	Nguồn dữ liệu camera gửi ảnh, mã sự kiện, điểm chạm và thời gian ghi nhận.
Tiền điều kiện	Điểm chạm đã được khai báo và đang hoạt động.
Luồng chính	1) Máy chủ kiểm tra dữ liệu đầu vào; 2) ảnh được chuyển sang dịch vụ xử lý ảnh; 3) khuôn mặt được phát hiện, căn chỉnh và đưa vào hai nhánh nhận dạng; 4) máy chủ đối sánh véc-tơ khuôn mặt với dữ liệu đã lưu; 5) kết quả được lưu thành sự kiện ảnh và các bản ghi quan sát; 6) bản ghi xác định được khách hàng được liên kết với lần mua sắm.
Luồng thay thế	Mã sự kiện đã tồn tại trả về kết quả đã lưu; ảnh lỗi hoặc không có khuôn mặt được lưu với trạng thái xử lý tương ứng; khuôn mặt không đạt ngưỡng đối sánh không tạo bản ghi gắn với khách hàng.
Kết quả	Sự kiện ảnh và các bản ghi quan sát hợp lệ được lưu trong cơ sở dữ liệu.

Bảng 4.6: Đặc tả UC05 – Theo dõi lần mua sắm

Mã use case	UC05
Tên chức năng	Theo dõi lần mua sắm
Tác nhân	Người quản lý
Sự kiện kích hoạt	Người quản lý mở chức năng Theo dõi mua sắm và chọn một lần mua sắm.
Tiền điều kiện	Người quản lý đã đăng nhập và đã có bản ghi quan sát.
Luồng chính	1) Giao diện tải danh sách lần mua sắm; 2) người quản lý chọn một lần; 3) máy chủ trả thông tin khách hàng, chuỗi điểm chạm, các quan sát và đơn hàng; 4) giao diện sắp xếp bản ghi theo thời gian; 5) người quản lý mở chi tiết một quan sát để xem kết quả nhận dạng và lịch sử xử lý.
Luồng thay thế	Lần mua sắm không có đơn hàng vẫn hiển thị chuỗi quan sát và trạng thái tương ứng.
Kết quả	Toàn bộ diễn biến đã ghi nhận của lần mua sắm được hiển thị theo thời gian.

Bảng 4.7: Đặc tả UC06 – Phân tích biểu cảm và phân cụm chuỗi

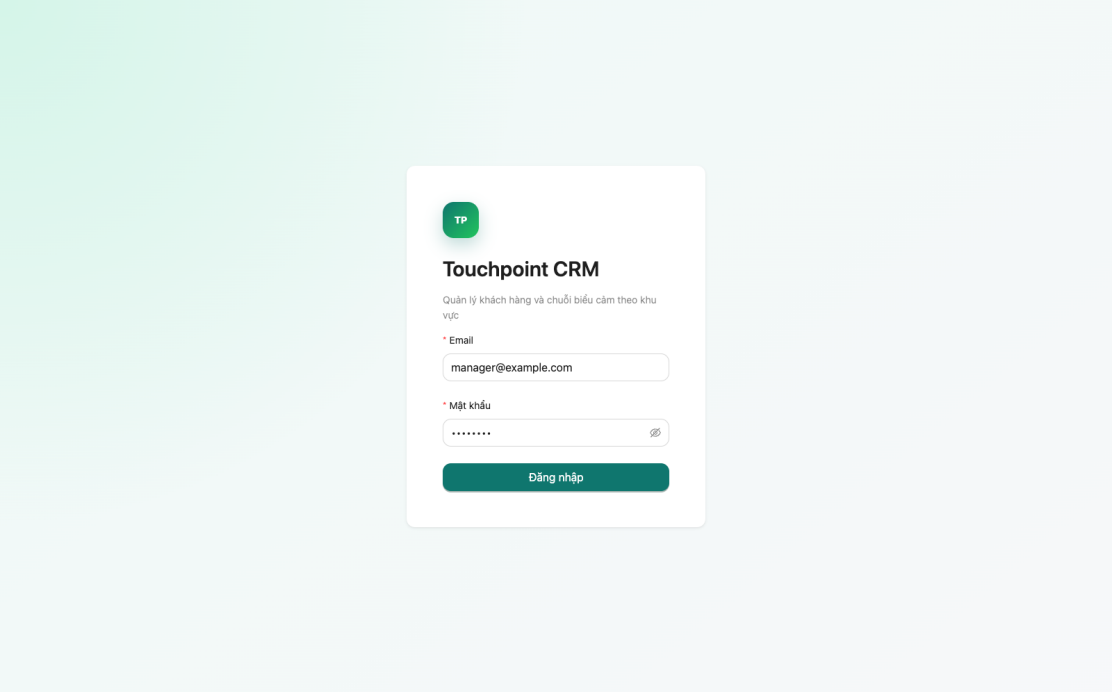
Mã use case	UC06
Tên chức năng	Phân tích biểu cảm và phân cụm chuỗi
Tác nhân	Người quản lý
Sự kiện kích hoạt	Người quản lý mở chức năng Phân tích biểu cảm và lựa chọn phạm vi dữ liệu.
Tiền điều kiện	Người quản lý đã đăng nhập và dữ liệu quan sát đã được lưu.
Luồng chính	1) Chọn điểm chạm, khoảng thời gian hoặc nguồn dữ liệu; 2) máy chủ tổng hợp phân bố, biến thiên hoặc cặp thay đổi; 3) với phân cụm, máy chủ tạo chuỗi trạng thái và ma trận khoảng cách; 4) PAM được chạy với các giá trị số cụm; 5) ASW được dùng để chọn số cụm; 6) giao diện hiển thị medoid, quy mô cụm và danh sách lần mua sắm được gán cụm.
Luồng thay thế	Khi dữ liệu không đủ điều kiện cho phép phân tích đã chọn, máy chủ trả trạng thái và lý do tương ứng.
Kết quả	Báo cáo biểu cảm hoặc kết quả phân cụm được hiển thị và lưu theo lần phân tích.

4.3 Giao diện ứng dụng

Giao diện ứng dụng được tổ chức theo thanh điều hướng bên trái. Các màn hình dưới đây được chụp lại ngày 13/10/2026 từ hệ thống đang chạy với dữ liệu `KDEF-RANDOM-TIME-20261013-LIVE`, sau khi ảnh camera được gửi qua luồng tiếp nhận, xử lý và lưu trữ. Lần chạy này không tạo đơn hàng, nên các màn hình

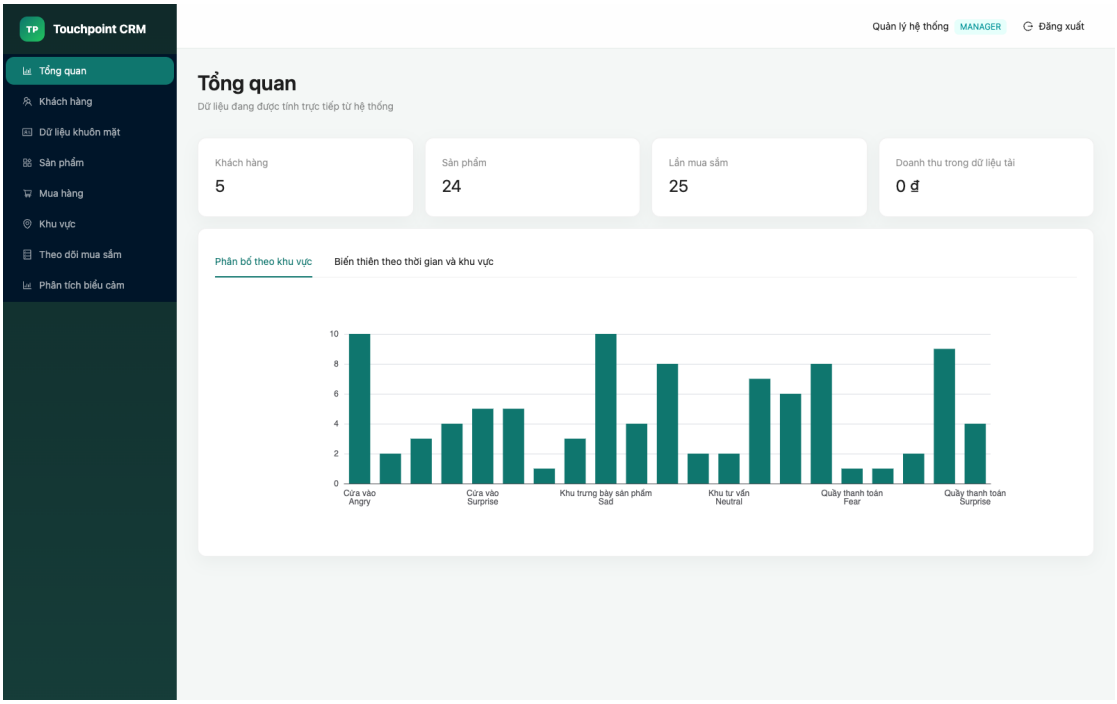
lịch sử đơn hàng hiển thị trạng thái chưa có dữ liệu.

Màn hình đăng nhập. Người quản lý nhập địa chỉ thư điện tử và mật khẩu để bắt đầu phiên sử dụng. Sau khi xác thực thành công, giao diện chuyển đến trang tổng quan.



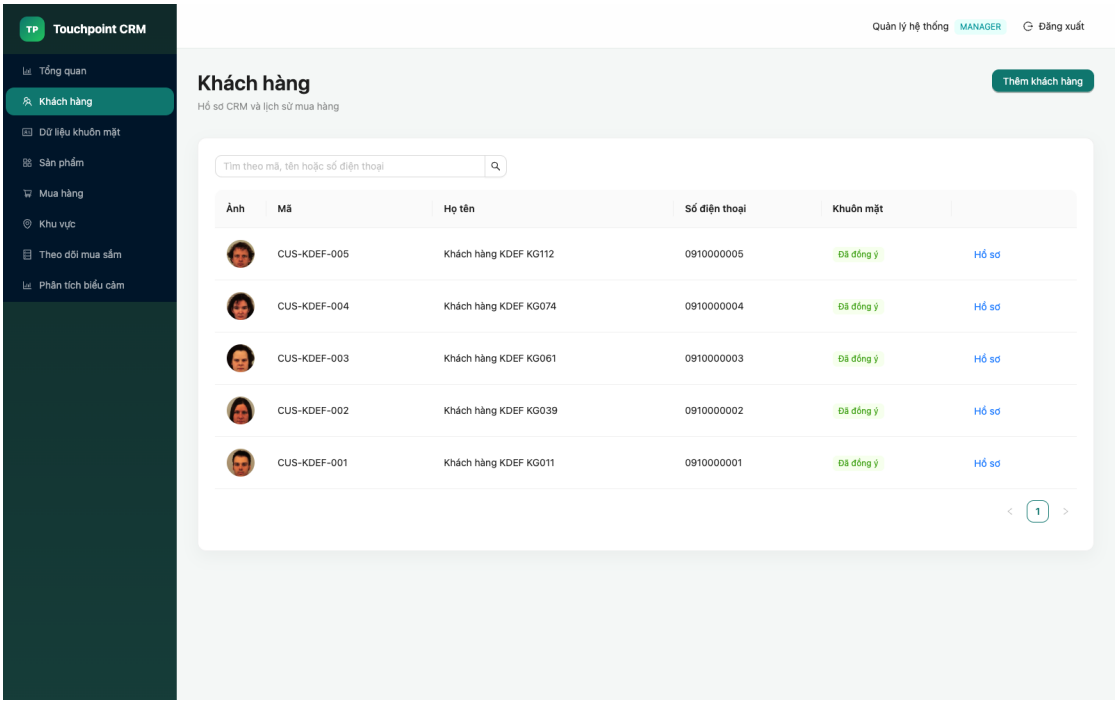
Hình 4.4: Giao diện đăng nhập

Màn hình tổng quan. Trang tổng quan hiển thị số khách hàng, sản phẩm, lần mua sắm, doanh thu và các biểu đồ biểu cảm theo khu vực hoặc thời gian.



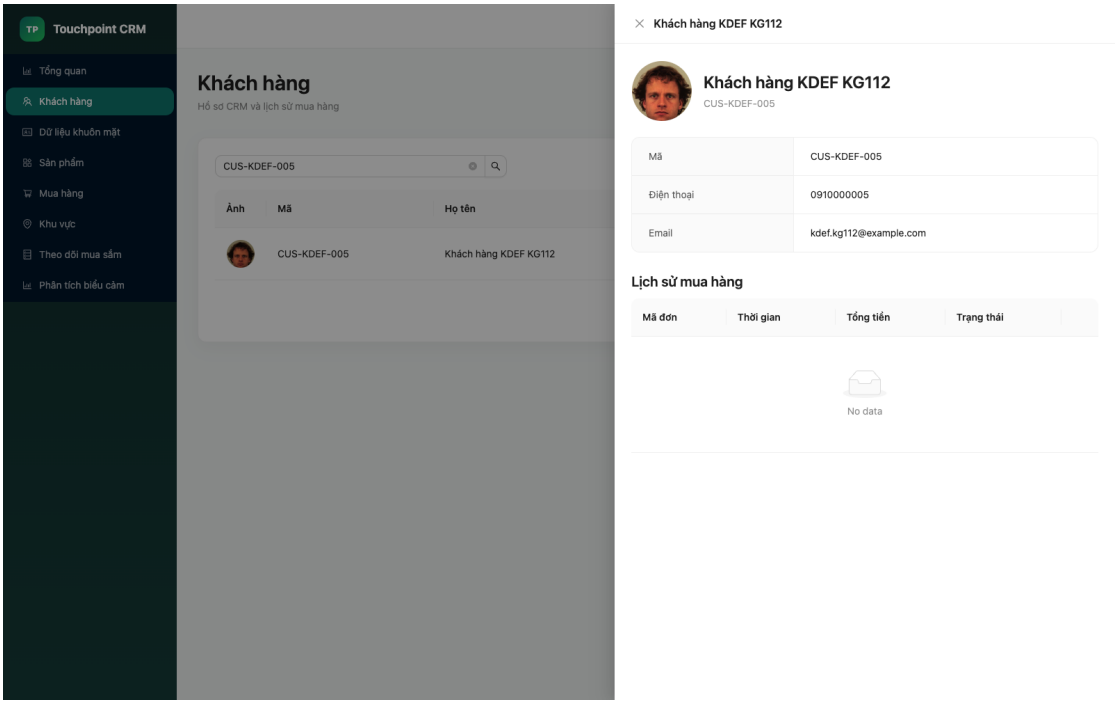
Hình 4.5: Giao diện tổng quan hệ thống

Màn hình khách hàng. Danh sách khách hàng hỗ trợ tìm kiếm theo mã, họ tên hoặc số điện thoại. Người quản lý có thể tạo hồ sơ mới và mở chi tiết từng khách hàng.



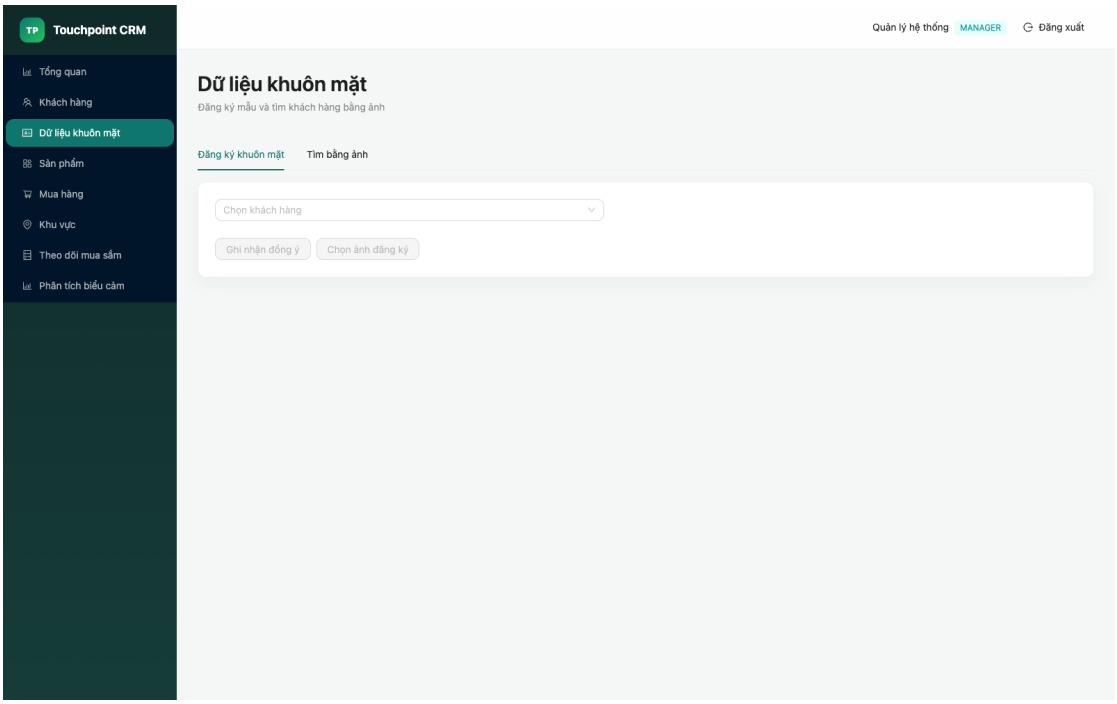
Hình 4.6: Giao diện danh sách khách hàng

Màn hình hồ sơ trình bày thông tin khách hàng và lịch sử đơn hàng đã lưu. Dữ liệu này được sử dụng để tra cứu các lần mua sắm và kết quả phân tích liên quan.



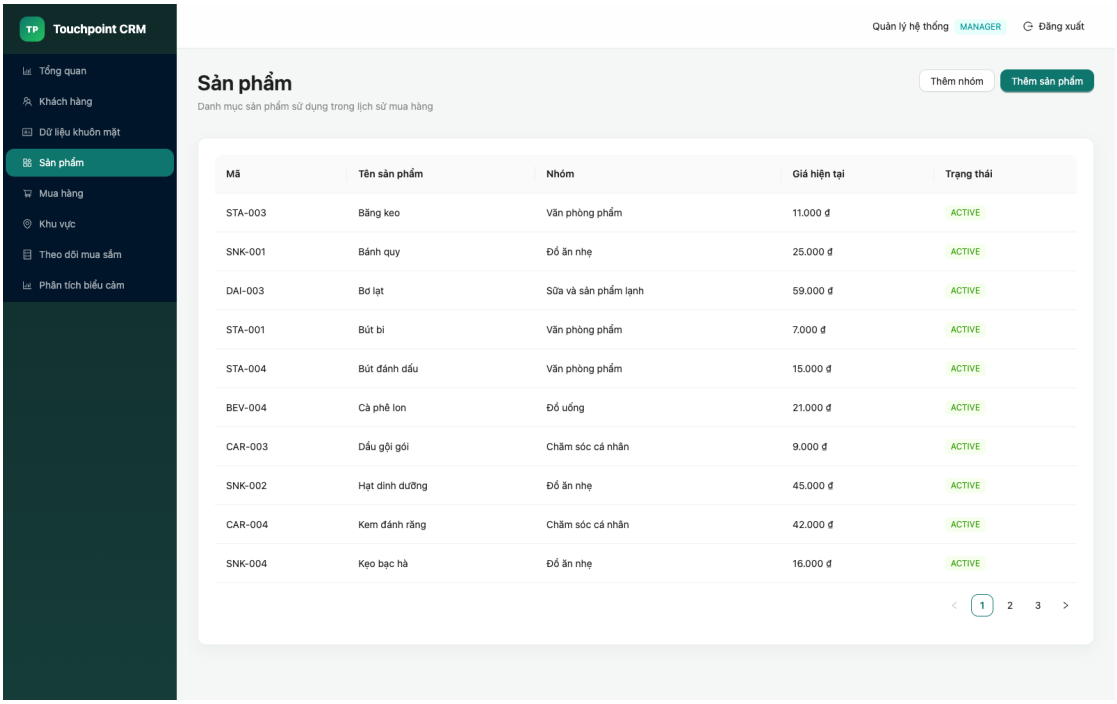
Hình 4.7: Giao diện hồ sơ và lịch sử mua hàng của khách hàng

Màn hình dữ liệu khuôn mặt. Chức năng này gồm hai phần: đăng ký ảnh khuôn mặt cho khách hàng và tìm khách hàng bằng một ảnh truy vấn. Kết quả tìm kiếm hiển thị trạng thái đối sánh cùng khoảng cách giữa các véc-tơ đặc trưng.



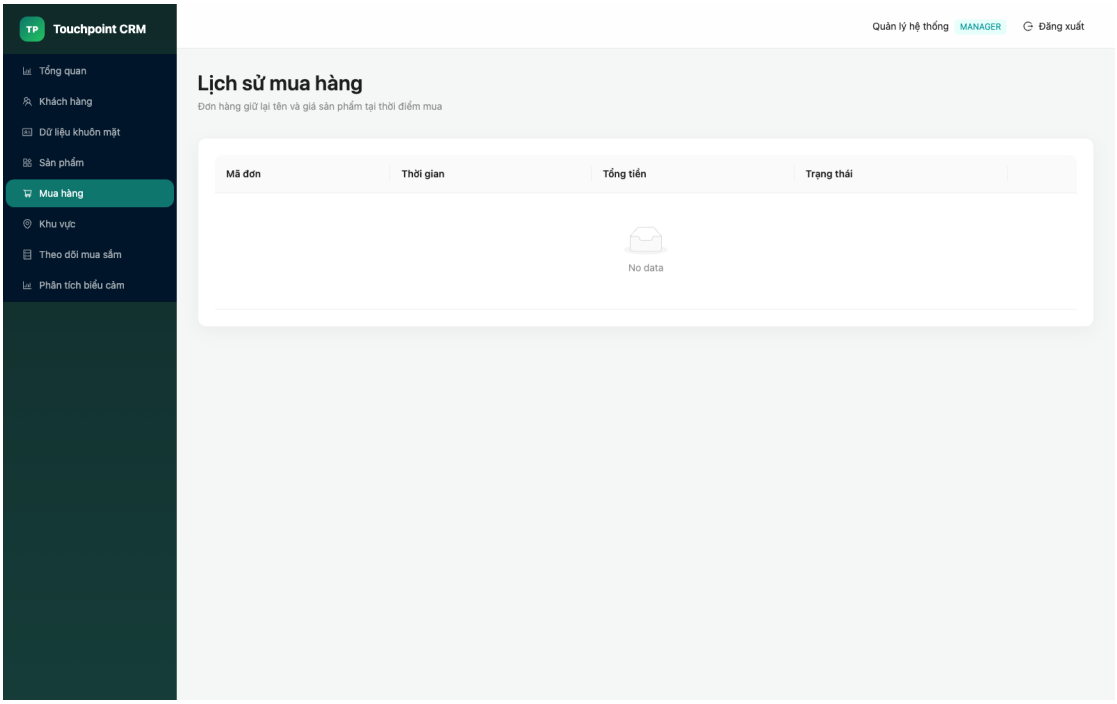
Hình 4.8: Giao diện đăng ký và tìm kiếm khách hàng bằng khuôn mặt

Màn hình sản phẩm. Người quản lý tạo nhóm sản phẩm, thêm sản phẩm và theo dõi mã, tên, nhóm, giá hiện tại cùng trạng thái sử dụng.



Hình 4.9: Giao diện quản lý sản phẩm

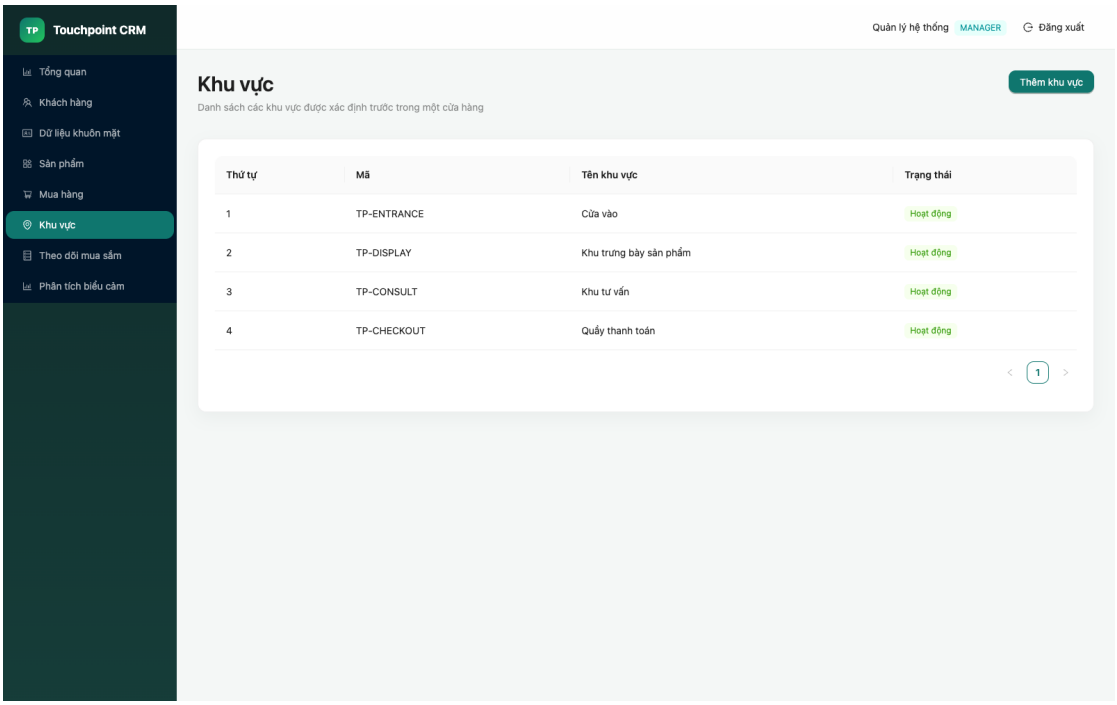
Màn hình lịch sử mua hàng. Danh sách đơn hàng trình bày khách hàng, thời gian, tổng tiền và trạng thái. Khi chọn một đơn hàng, giao diện hiển thị các sản phẩm và giá trị từng dòng.



Hình 4.10: Giao diện lịch sử mua hàng

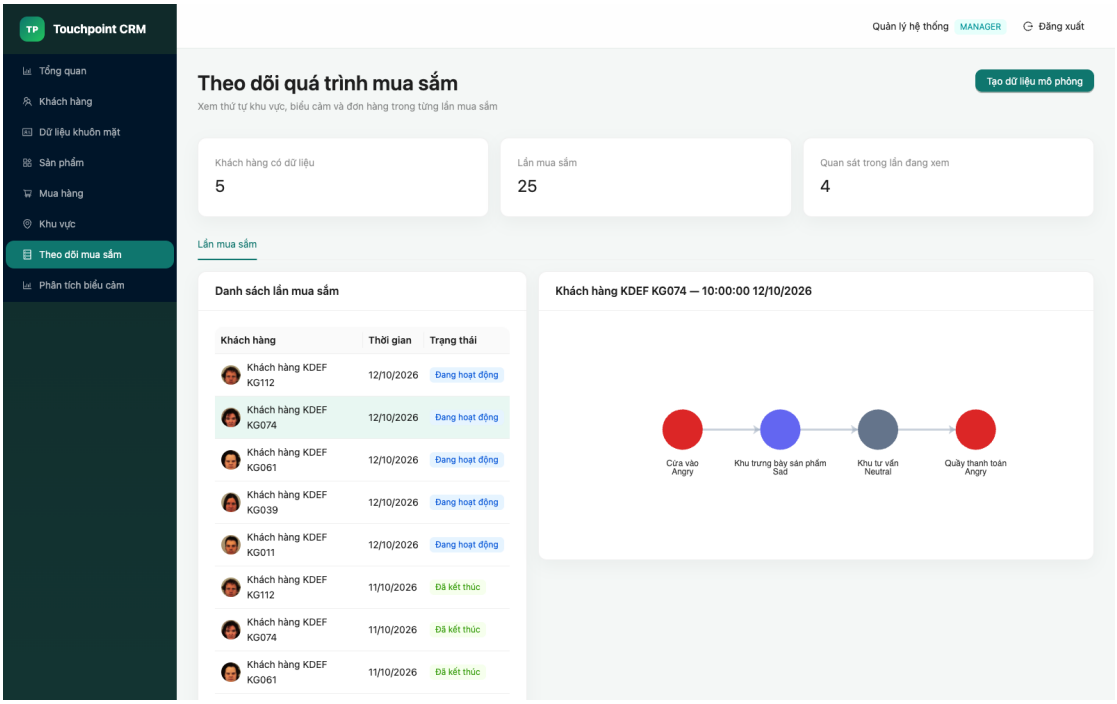
Màn hình khu vực. Các điểm chạm được khai báo bằng mã, tên, thứ tự và trạng thái hoạt động. Mã điểm chạm được gửi kèm mỗi sự kiện ảnh để xác định vị trí

quan sát.



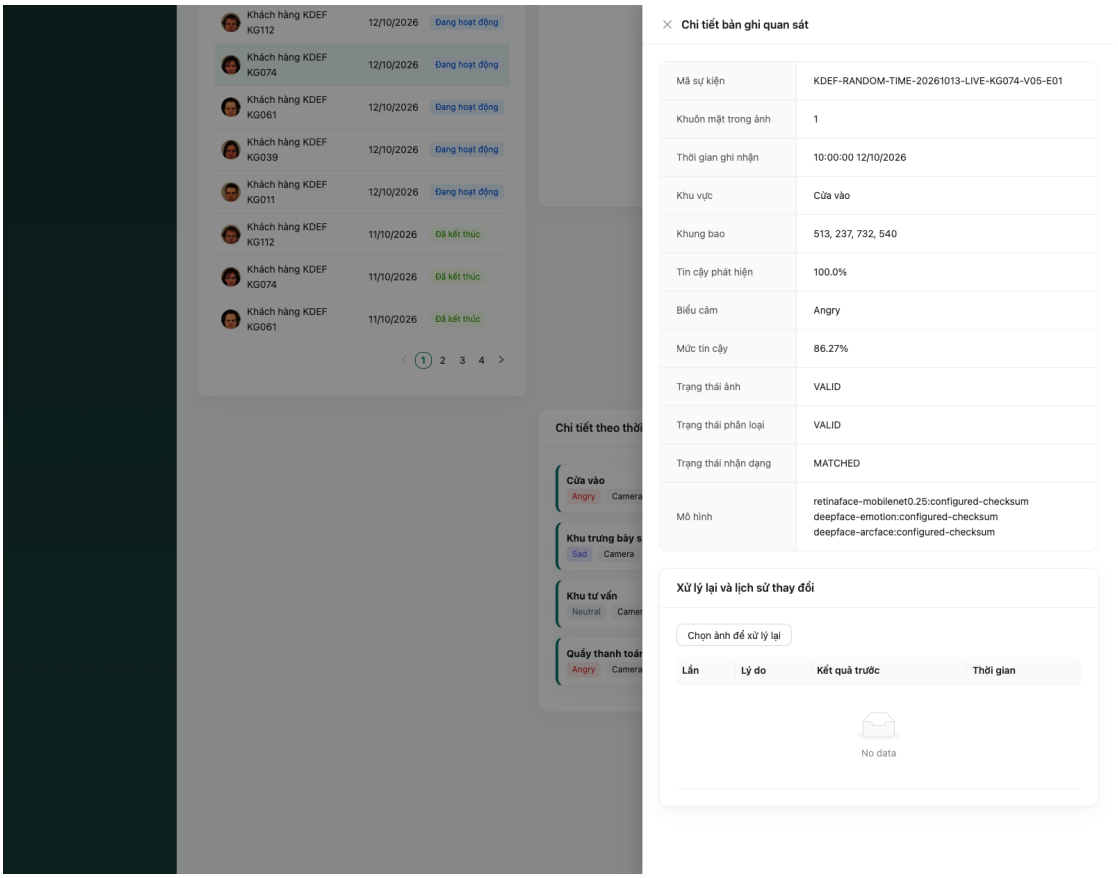
Hình 4.11: Giao diện quản lý điểm chạm

Màn hình theo dõi mua sắm. Giao diện hiển thị danh sách các lần mua sắm và phần chi tiết của lần đang chọn. Các quan sát được sắp xếp theo thời gian, kèm điểm chạm, biểu cảm, nguồn dữ liệu và đơn hàng liên quan.



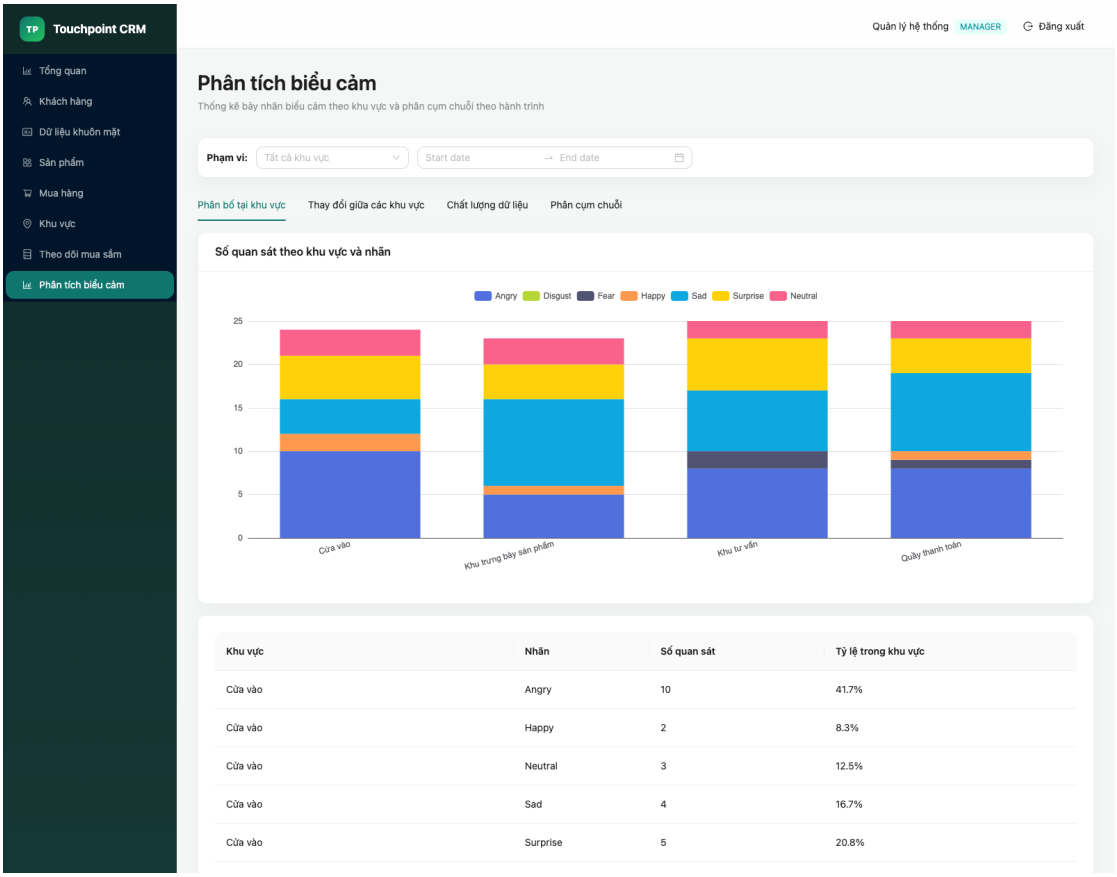
Hình 4.12: Giao diện theo dõi lần mua sắm

Người quản lý có thể mở một bản ghi để xem mã sự kiện, thời gian, điểm chạm, khung bao khuôn mặt, nhãn biểu cảm, khoảng cách nhận dạng, trạng thái xử lý và các phiên bản mô hình đã sử dụng.



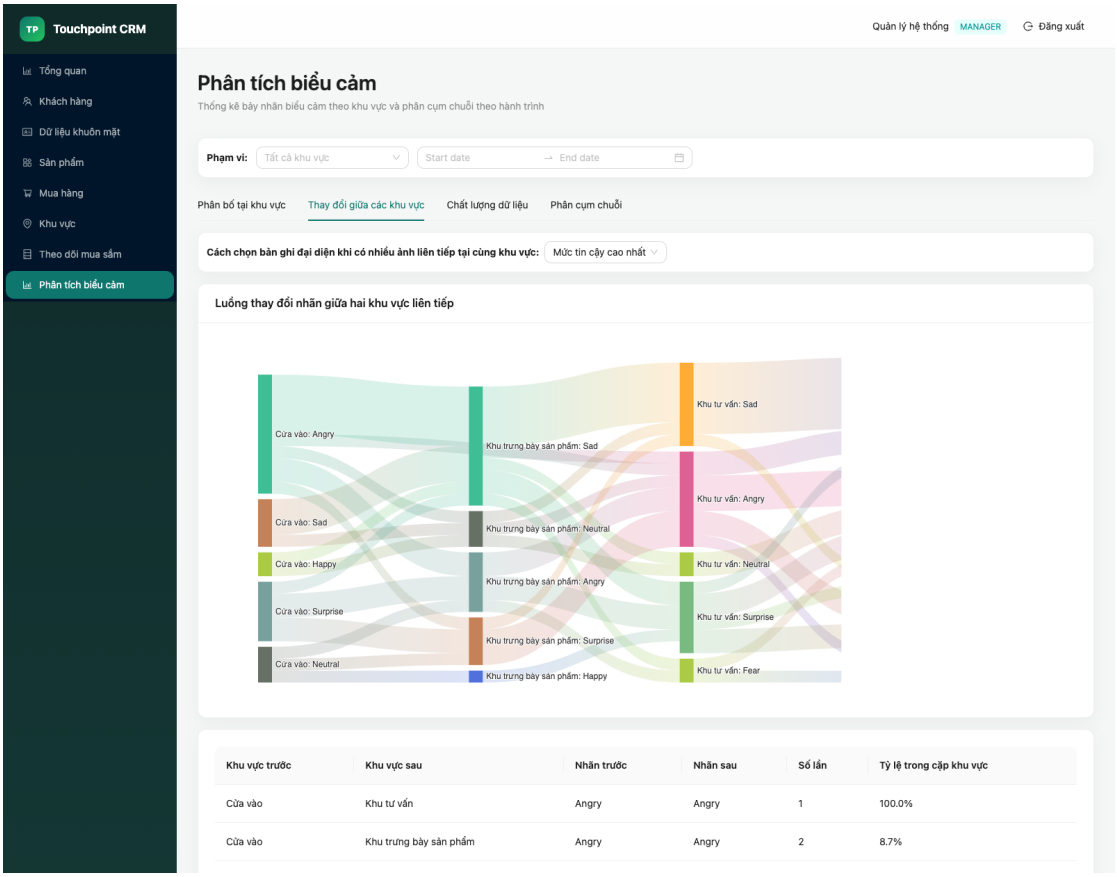
Hình 4.13: Giao diện chi tiết bản ghi quan sát

Màn hình phân bố biểu cảm. Người quản lý chọn điểm chạm và khoảng thời gian. Kết quả gồm biểu đồ số quan sát và bảng số lượng, tỷ lệ của bảy nhãn biểu cảm tại từng điểm chạm.



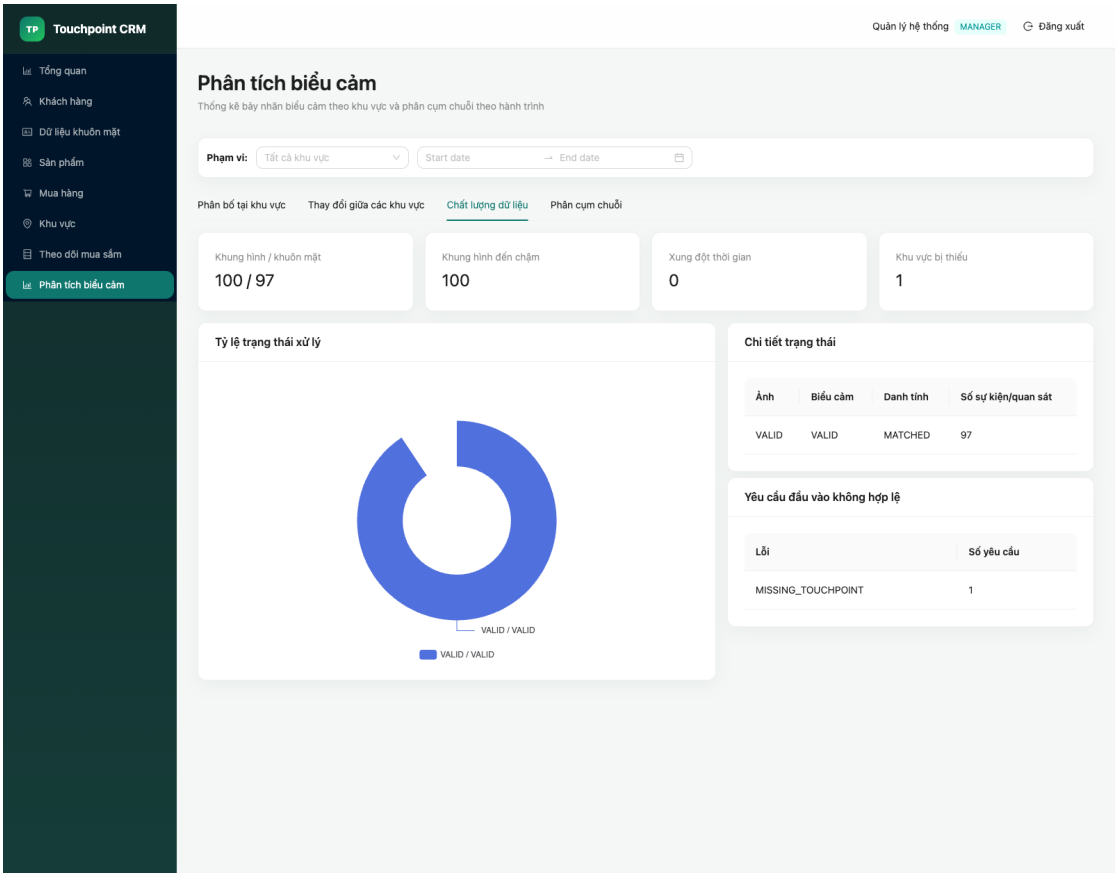
Hình 4.14: Giao diện thống kê phân bố biểu cảm tại điểm chạm

Màn hình thay đổi biểu cảm. Giao diện cho phép chọn cách lấy bản ghi đại diện tại mỗi đoạn điểm chạm và hiển thị các tổ hợp biểu cảm giữa hai điểm chạm liên tiếp bằng biểu đồ cùng bảng số liệu.



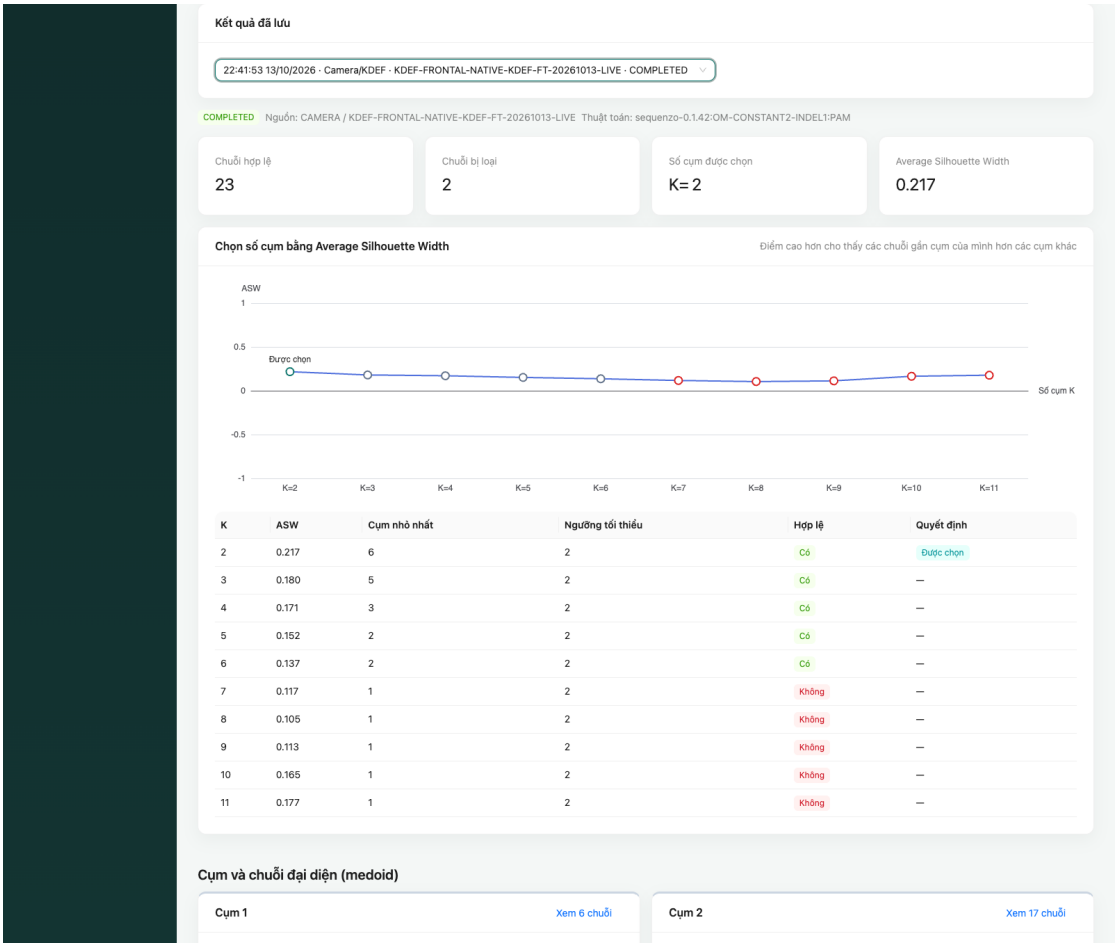
Hình 4.15: Giao diện phân tích thay đổi biểu cảm giữa các điểm chạm

Màn hình chất lượng dữ liệu. Các chỉ số gồm số khung hình, số khuôn mặt, bản ghi đến chậm, xung đột thời gian, điểm chạm bị thiếu và số lượng theo từng trạng thái xử lý. Ảnh dưới đây hiển thị báo cáo toàn hệ thống: một lỗi thiếu mã khu vực được lưu từ phép thử ngày 30/09/2026, không thuộc 100 khung KDEF mới. Chỉ số khu vực thiếu đếm khoảng trống giữa điểm đầu và điểm cuối đã quan sát, khác với số hành trình không đủ cả bốn điểm chạm dùng ở Chương 5.



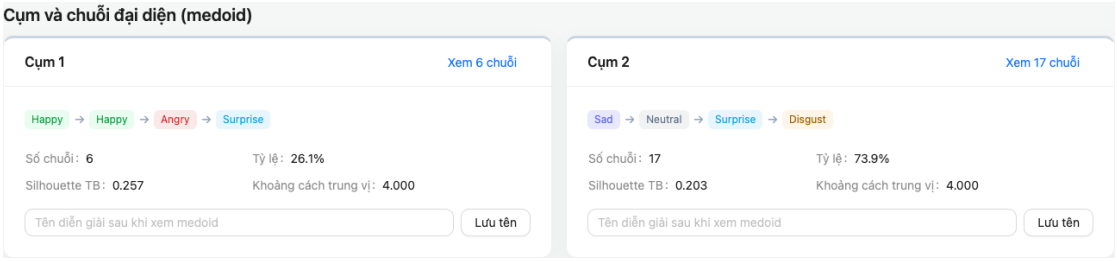
Hình 4.16: Giao diện báo cáo chất lượng dữ liệu

Màn hình phân cụm chuỗi. Người quản lý chọn nguồn dữ liệu và mã lần chạy để tạo một lần phân tích. Phần tổng quan hiển thị số chuỗi được sử dụng, số chuỗi bị loại, số cụm được chọn, ASW và kết quả theo từng giá trị K.



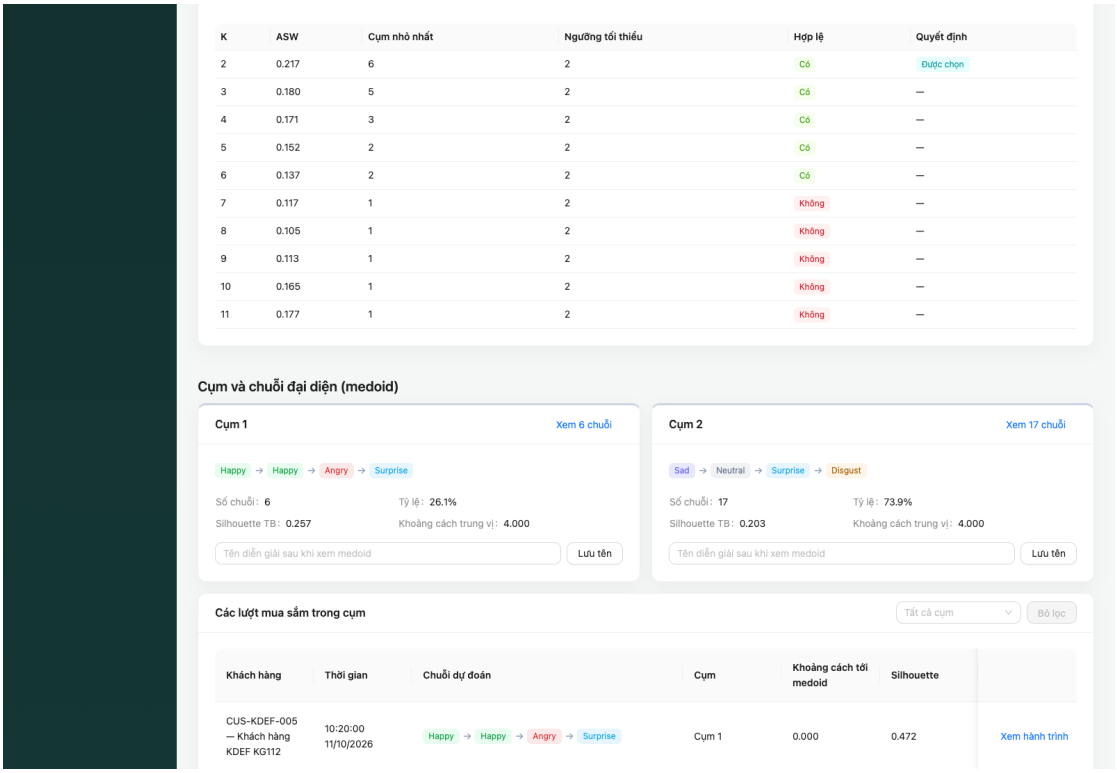
Hình 4.17: Giao diện tổng quan kết quả phân cụm chuỗi

Mỗi cụm được trình bày bằng chuỗi medoid, số lượng thành viên, tỷ lệ, silhouette trung bình và khoảng cách trung vị. Người quản lý có thể đặt tên cho cụm sau khi xem chuỗi đại diện.



Hình 4.18: Giao diện danh sách cụm và chuỗi medoid

Bảng gán cụm hiển thị mã lần mua sắm, chuỗi trạng thái, cụm được gán, khoảng cách đến medoid và silhouette. Nút xem hành trình mở lại lần mua sắm tương ứng để đối chiếu với các bản ghi quan sát.



Hình 4.19: Giao diện danh sách lần mua sắm được gán cụm

CHƯƠNG 5. ĐÁNH GIÁ THỰC NGHIỆM

Chương này trình bày quá trình đánh giá giải pháp ở cấp thành phần và cấp hệ thống. Hai thực nghiệm đầu so sánh các phương pháp phát hiện khuôn mặt và phân loại biểu cảm trên các bộ dữ liệu có nhãn chuẩn. Sau đó, toàn bộ hệ thống được triển khai, chạy lại với dữ liệu camera thử nghiệm xây dựng từ KDEF và đánh giá theo luồng từ ảnh đầu vào đến kết quả phân cụm có khả năng truy vết. Cách tổ chức này tách kết quả của từng mô hình khỏi kết quả vận hành của hệ thống, tránh sử dụng một chỉ số đơn lẻ để đại diện cho toàn bộ giải pháp.

5.1 Thực nghiệm so sánh các phương pháp phát hiện khuôn mặt

5.1.1 Tập dữ liệu và giao thức đánh giá

Thực nghiệm sử dụng toàn bộ tập xác thực của WIDER FACE gồm 3.226 ảnh. WIDER FACE được xây dựng cho bài toán phát hiện khuôn mặt; toàn bộ tập dữ liệu chứa 32.203 ảnh với 393.703 khung bao khuôn mặt và có biến thiên lớn về kích thước khuôn mặt, tư thế, mức độ che khuất, biểu cảm và điều kiện chiếu sáng [14]. Tập xác thực được sử dụng vì nhãn chuẩn đã được công bố: vị trí của từng khuôn mặt được đánh dấu bằng khung bao và bộ dữ liệu cung cấp các tệp nhãn đánh giá tương ứng với ba mức khó Easy, Medium và Hard. Ba mức này không do hệ thống tự phân chia trong quá trình thực nghiệm mà được lấy trực tiếp từ nhãn đánh giá của WIDER FACE.

WIDER FACE được lựa chọn trước hết vì phù hợp với đối tượng cần đánh giá. Bước đầu tiên của hệ thống là xác định tất cả khuôn mặt xuất hiện trong một khung hình; kết quả của bước này quyết định vùng ảnh được chuyển sang phân loại biểu cảm và tạo véc-tơ đặc trưng nhận dạng. Do đó, thực nghiệm cần một bộ dữ liệu có nhãn vị trí khuôn mặt, có thể chứa nhiều khuôn mặt trong cùng ảnh và phản ánh các trường hợp khuôn mặt nhỏ, bị che khuất hoặc xuất hiện trong cảnh đông người. Đây cũng là những điều kiện có thể gặp khi thu nhận hình ảnh tại cửa hàng. Sự đa dạng của WIDER FACE cho phép kiểm tra trực tiếp mức suy giảm của mô hình khi điều kiện quan sát trở nên phức tạp, thay vì chỉ đánh giá trên các ảnh chân dung có một khuôn mặt rõ và gần camera.

Lý do thứ hai là khả năng so sánh và tái lập. WIDER FACE cung cấp cùng một tập ảnh, khung bao chuẩn, danh sách khuôn mặt được tính ở từng mức khó và quy tắc đánh giá cho mọi mô hình. Haar Cascade, MTCNN và RetinaFace vì vậy được đối chiếu trên cùng đầu vào và cùng tiêu chuẩn, hạn chế trường hợp kết quả khác nhau do sử dụng các bộ ảnh hoặc cách ghép dự đoán khác nhau. Việc báo cáo riêng kết quả Easy, Medium và Hard còn giúp phát hiện trường hợp một mô hình đạt kết

quả tốt trên khuôn mặt lớn, rõ nhưng bỏ sót nhiều khuôn mặt nhỏ hoặc bị che. Đặc điểm này phù hợp hơn với mục tiêu lựa chọn thành phần phát hiện cho hệ thống so với một giá trị chính xác tổng hợp duy nhất.

Các giao thức đánh giá nhận dạng hoặc xác minh khuôn mặt không được sử dụng cho thực nghiệm này vì chúng đo khả năng xác định hai ảnh có thuộc cùng một người hay không, trong khi chưa kiểm tra mô hình có tìm được đầy đủ các khuôn mặt trong ảnh gốc hay không. Tương tự, tập dữ liệu biểu cảm gồm các vùng khuôn mặt đã được cắt sẵn chỉ đánh giá bước phân loại sau phát hiện. Giao thức phát hiện vật thể tổng quát có thể đánh giá độ chính xác định vị ở nhiều ngưỡng IoU, nhưng không cung cấp các nhóm độ khó chuyên biệt cho khuôn mặt theo quy ước của WIDER FACE. Vì vậy, các giao thức này có thể được dùng cho những mục tiêu đánh giá khác, nhưng không thay thế trực tiếp giao thức WIDER FACE trong thực nghiệm so sánh thành phần phát hiện khuôn mặt.

Việc lựa chọn WIDER FACE cũng xác định phạm vi của kết luận. Kết quả tại mục này chỉ chứng minh chất lượng và hiệu năng của bước phát hiện khuôn mặt trên tập xác thực WIDER FACE; kết quả không trực tiếp chứng minh độ chính xác nhận dạng khách hàng, độ chính xác phân loại biểu cảm hoặc khả năng vận hành đầu cuối của hệ thống. Các nội dung đó được kiểm tra bằng các thực nghiệm riêng ở những mục tiếp theo.

Cấu hình của ba mô hình phát hiện được cố định trước khi đo. Haar Cascade sử dụng tệp `haarcascade_frontalface_default.xml` của OpenCV [15]. MTCNN sử dụng mô hình tiền huấn luyện của `facenet-pytorch` phiên bản 2.6.0 [16], với `min_face_size=20`, các ngưỡng $[0{,}6; 0{,}7; 0{,}7]$ và hệ số tỷ lệ $0{,}709$. RetinaFace sử dụng mạng nền MobileNet0.25 cùng trọng số tiền huấn luyện trên tập huấn luyện WIDER FACE từ kho mã `Pytorch_Retinaface` [17]. Việc cố định một cấu hình cho mỗi phương pháp giúp kết quả giữa các lượt chạy có thể tái lập và tránh trộn lẫn ảnh hưởng của nhiều mạng nền hoặc thư viện triển khai.

Ba mô hình nhận cùng ảnh gốc và tự thay đổi kích thước ảnh theo quy trình riêng. Trước khi đo chính thức, mỗi mô hình xử lý thử 20 ảnh; bước chạy thử giúp hoàn tất việc khởi tạo bộ nhớ và các thành phần tính toán, qua đó giảm ảnh hưởng bất thường của những lượt suy luận đầu tiên đến kết quả đo thời gian.

Sau đó, mỗi mô hình được chạy ba lượt trên cùng danh sách ảnh và thứ tự mô hình được xoay vòng giữa các lượt. Thời gian đo bao gồm các bước tiền xử lý, suy luận và hậu xử lý của mô hình phát hiện khuôn mặt, nhưng không bao gồm thời gian đọc ảnh, ghi tệp hoặc tính các chỉ số đánh giá.

Thực nghiệm sử dụng CPU với một luồng PyTorch và một luồng OpenCV trên

Apple M4 Pro, RAM 24 GiB và macOS 26.5. Môi trường phần mềm gồm Python 3.11.7, OpenCV 4.10.0 và PyTorch 2.2.2.

Chất lượng phát hiện khuôn mặt được đánh giá theo giao thức của bộ dữ liệu WIDER FACE. Chỉ số chính là độ chính xác trung bình (AP) được báo cáo riêng trên ba mức khó Easy, Medium và Hard. Khung dự đoán được đối chiếu với khung chuẩn bằng tỷ lệ phần giao trên phần hợp (IoU), với ngưỡng chấp nhận bằng 0,5 theo giao thức đánh giá phát hiện đối tượng [**?**, 18]. Với khung bao dự đoán B_p và khung bao chuẩn B_g, IoU được xác định bởi

$$\mathrm{IoU}(B_p, B_g) = \frac{|B_p \cap B_g|}{|B_p \cup B_g|}. \tag{5.1}$$

Mỗi khung bao dự đoán chỉ được ghép với một khung bao chuẩn. Gọi P là độ chính xác và R là độ bao phủ tại ngưỡng đang xét; các chỉ số P, R và F1 được tính theo [**?**, 18]

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F1 = \frac{2PR}{P + R}. \tag{5.2}$$

Ngưỡng IoU bảo đảm một dự đoán chỉ được tính là đúng khi khung bao không những chỉ ra sự tồn tại của khuôn mặt mà còn định vị đủ gần với khung chuẩn. Một dự đoán thỏa ngưỡng và được ghép với một khung chuẩn chưa được sử dụng được tính là dương tính đúng (TP). Khung dự đoán không ghép được tính là dương tính sai (FP), còn khuôn mặt trong nhãn chuẩn không có dự đoán tương ứng được tính là âm tính sai (FN).

Độ chính xác P cho biết trong các vùng được mô hình dự đoán là khuôn mặt, tỷ lệ dự đoán đúng là bao nhiêu; chỉ số này phản ánh mức độ phát hiện nhầm nền hoặc vật thể khác thành khuôn mặt. Độ bao phủ R cho biết trong toàn bộ khuôn mặt có trong dữ liệu, mô hình phát hiện được bao nhiêu; chỉ số này phản ánh mức độ bỏ sót. Độ bao phủ có ý nghĩa trực tiếp với hệ thống đề xuất vì một khuôn mặt bị bỏ sót sẽ không tạo được vùng đầu vào cho các bước phân loại biểu cảm và tạo đặc trưng nhận dạng. Tuy nhiên, chỉ sử dụng riêng một trong hai chỉ số có thể dẫn đến đánh giá lệch: giảm ngưỡng tin cậy thường làm tăng độ bao phủ nhưng cũng có thể tăng số phát hiện nhầm, trong khi tăng ngưỡng có thể cải thiện độ chính xác nhưng làm bỏ sót nhiều khuôn mặt hơn. F1 là trung bình điều hòa của P và R, được sử dụng để mô tả mức cân bằng giữa hai loại sai sót tại một ngưỡng vận hành xác định.

Chương trình đánh giá do luận văn xây dựng tính AP theo giao thức WIDER

FACE. Các dự đoán được sắp theo mức tin cậy; chương trình quét qua 1.000 ngưỡng để tạo đường độ chính xác–độ bao phủ, nội suy đường này và tính diện tích phía dưới đường cong [**?**, 14]. Quy trình tính toán đã được đối chiếu với bộ đánh giá WIDER FACE độc lập để kiểm tra tính đúng đắn. Khác với P, R và F1 được tính tại một ngưỡng cố định, AP tổng hợp kết quả trên toàn bộ dải ngưỡng. AP được chọn làm chỉ số chất lượng chính vì mức tin cậy của ba mô hình không được hiệu chỉnh trên cùng một thang xác suất; việc chỉ so sánh tại một giá trị ngưỡng có thể tạo lợi thế cho một cấu hình cụ thể. Các chỉ số P, R và F1 vẫn được báo cáo để mô tả hành vi của từng mô hình tại ngưỡng vận hành đã cố định: Haar Cascade không lọc thêm, MTCNN dùng đầu ra sau ngưỡng O-Net 0,7 và RetinaFace dùng ngưỡng tin cậy 0,6.

AP được trình bày riêng cho ba nhóm dễ, trung bình và khó nhằm tránh trường hợp kết quả tốt trên các khuôn mặt lớn, rõ che khuất việc mô hình bỏ sót khuôn mặt nhỏ, bị che hoặc xuất hiện trong cảnh đông người. Cách phân tách này cho phép quan sát mức suy giảm của từng phương pháp khi độ khó tăng và xác định phương pháp duy trì chất lượng ổn định hơn trong điều kiện phức tạp. Như vậy, AP trên ba mức khó cung cấp đánh giá chất lượng tổng thể, còn P, R và F1 giải thích cụ thể hai loại sai sót tại ngưỡng vận hành.

Hiệu năng tính toán được đánh giá từ n bản ghi thời gian xử lý $t_1, t_2, \ldots, t_n$, tính bằng mili giây. Độ trễ trung vị T_{50} là phân vị thứ 50, còn T_{95} là giá trị mà 95% số lượt xử lý không vượt quá. Tốc độ xử lý và tỷ lệ ảnh không phát hiện được tính theo

$$\mathrm{FPS} = \frac{n}{\sum_{i=1}^{n} t_i/1000}, \qquad q_{\mathrm{miss}} = \frac{N_{\text{no detection}}}{N_{\text{images with faces}}}. \tag{5.3}$$

Trong đó, $N_{\text{no detection}}$ là số ảnh có khuôn mặt chuẩn nhưng mô hình không trả về khung phát hiện, còn $N_{\text{images with faces}}$ là tổng số ảnh có ít nhất một khuôn mặt chuẩn. Trung vị hạn chế ảnh hưởng của một số lượt chạy bất thường; T_{95} phản ánh nhóm lượt chạy chậm; FPS biểu diễn thông lượng trung bình; và q_{miss} cho biết tỷ lệ ảnh không tạo được đầu vào cho bước xử lý tiếp theo. Các chỉ số này được báo cáo riêng vì một mô hình phát hiện tốt nhưng quá chậm hoặc thường không trả kết quả vẫn có thể không phù hợp với luồng xử lý của hệ thống.

5.1.2 Kết quả thực nghiệm so sánh

Bảng 5.1 và Bảng 5.2 được tạo từ cùng lần chạy `wider-val-cpu-20260921`. Mỗi mô hình có 9.678 bản ghi thời gian, tương ứng với 3.226 ảnh qua ba lượt chạy.

Kết quả AP đã được đối chiếu bằng bộ đánh giá WIDER FACE độc lập và trùng khớp đến sai số làm tròn.

Bảng 5.1: Kết quả chất lượng phát hiện trên tập xác thực WIDER FACE

Mô hình	AP dễ	AP trung bình	AP khó	Độ chính xác	Độ bao phủ	F1
Haar Cascade – OpenCV, cấu hình mặt chính diện mặc định	0,4252	0,3668	0,1754	0,6906	0,1514	0,2484
MTCNN – facenet-pytorch	0,8132	0,7706	0,4990	0,9081	0,4063	0,5614
RetinaFace – MobileNet0.25	**0,9082**	**0,8830**	**0,7388**	**0,9106**	**0,4784**	**0,6273**

Bảng 5.2: Kết quả hiệu năng phát hiện trên CPU

Mô hình	Trung vị (ms)	Phân vị 95 (ms)	Số ảnh/giây	Tỷ lệ ảnh không phát hiện
Haar Cascade	131,52	257,71	7,03	0,2228
MTCNN	197,95	418,26	4,55	0,0615
RetinaFace–MobileNet0.25	**64,53**	**131,99**	**13,01**	**0,0320**

5.1.3 Nhận xét từ kết quả thực nghiệm

Kết quả thực nghiệm cho thấy ba phương pháp khác nhau cả về chất lượng phát hiện và chi phí suy luận. Haar Cascade có kết quả thấp nhất trên cả ba nhóm dễ, trung bình và khó. Mức giảm mạnh ở nhóm khó cho thấy cấu hình phát hiện mặt chính diện mặc định gặp khó khăn khi dữ liệu có nhiều khuôn mặt nhỏ, bị che khuất hoặc không ở tư thế chính diện. MTCNN cải thiện rõ rệt AP và giảm tỷ lệ ảnh không phát hiện so với Haar Cascade. Đổi lại, MTCNN có độ trễ trung vị và độ trễ tại phân vị thứ 95 cao nhất, phản ánh chi phí của quá trình xử lý nối tiếp qua ba tầng trên tháp ảnh đa tỷ lệ trong cấu hình thực nghiệm.

RetinaFace sử dụng mạng nền MobileNet0.25 duy trì AP cao nhất ở cả ba mức khó, đồng thời đạt độ trễ thấp nhất và số ảnh xử lý trong một giây cao nhất. Khoảng cách 0,2398 AP so với MTCNN trên nhóm khó cho thấy lợi thế của RetinaFace rõ hơn khi điều kiện phát hiện trở nên phức tạp. Tỷ lệ ảnh không phát hiện 0,0320 cũng cho thấy số ảnh không tạo được đầu vào cho bước phân loại biểu cảm thấp hơn so với hai phương pháp còn lại. Trong phạm vi tập dữ liệu WIDER FACE, trên thiết bị CPU và với bộ tham số đã cố định, RetinaFace sử dụng mạng nền MobileNet0.25 thể hiện sự cân bằng tốt nhất giữa chất lượng phát hiện và tốc độ xử lý. Kết quả này chỉ phản ánh cấu hình thực nghiệm đã mô tả, không phải kết luận khái quát cho mọi dữ liệu hoặc nền tảng phần cứng.

5.2 Thực nghiệm so sánh các phương pháp phân loại biểu cảm

5.2.1 Mục tiêu thực nghiệm

Thực nghiệm so sánh hai phương pháp phân loại biểu cảm trên cùng tập dữ liệu FER-2013. Phương pháp thứ nhất sử dụng đặc trưng LBP kết hợp với bộ phân loại SVM. Phương pháp thứ hai sử dụng mô hình CNN phân loại biểu cảm Emotion

được tích hợp trong thư viện DeepFace. DeepFace là thư viện Python cung cấp giao diện để nạp và thực thi các mô hình phục vụ những tác vụ phân tích khuôn mặt. Trong thực nghiệm này, DeepFace được dùng để nạp kiến trúc CNN Emotion và bộ trọng số ban đầu; phép phân loại biểu cảm được thực hiện bởi mô hình CNN này [**?**, **?**]. Mô hình nhận ảnh khuôn mặt xám kích thước 48×48 pixel và tạo đầu ra gồm điểm dự đoán cho bảy lớp biểu cảm.

Thực nghiệm được thực hiện theo hai giai đoạn. Giai đoạn thứ nhất đối chiếu LBP kết hợp SVM với mô hình CNN Emotion sử dụng bộ trọng số do DeepFace cung cấp, chưa được tinh chỉnh trên FER-2013. Giai đoạn thứ hai tinh chỉnh chính mô hình CNN này bằng tập *Training* của FER-2013, sau đó đánh giá lại trên tập kiểm tra chưa được dùng trong huấn luyện hoặc lựa chọn epoch. Cách tổ chức này trả lời hai câu hỏi riêng: việc tinh chỉnh trên FER-2013 cải thiện mô hình CNN ở mức nào, và sau tinh chỉnh, mô hình CNN có ưu điểm hoặc hạn chế gì so với LBP kết hợp SVM.

Các chỉ số được dùng để xem xét tỷ lệ dự đoán đúng chung, mức độ đồng đều giữa bảy lớp, độ trễ suy luận và kích thước mô hình. Phép đo tại mục này chỉ áp dụng cho bước phân loại trên ảnh khuôn mặt đã được cắt sẵn; nó không bao gồm phát hiện khuôn mặt, tạo véc-tơ ArcFace, đối sánh danh tính, truyền dữ liệu và ghi cơ sở dữ liệu. Vì vậy, kết quả tốc độ không được diễn giải thành độ trễ đầu cuối của hệ thống.

5.2.2 Tập dữ liệu và giao thức đánh giá

Thực nghiệm sử dụng FER-2013, gồm ảnh khuôn mặt xám kích thước 48×48 pixel và bảy nhãn *Angry*, *Disgust*, *Fear*, *Happy*, *Sad*, *Surprise* và *Neutral* [5]. Toàn bộ 35.887 ảnh được giữ theo cách chia chính thức thành 28.709 ảnh *Training*, 3.589 ảnh *PublicTest* và 3.589 ảnh *PrivateTest*. Phân bố từng lớp được trình bày tại Bảng 5.3.

Bảng 5.3: Phân bố ảnh theo lớp trong FER-2013

Tập dữ liệu	Angry	Disgust	Fear	Happy	Sad	Surprise	Neutral	Tổng
Training	3.995	436	4.097	7.215	4.830	3.171	4.965	28.709
PublicTest	467	56	496	895	653	415	607	3.589
PrivateTest	491	55	528	879	594	416	626	3.589

Tập *Training* được dùng để huấn luyện LBP kết hợp SVM. Mỗi ảnh được mô tả bằng LBP với tám điểm lân cận, bán kính bằng 1 và lưới không gian 6×6. Hai cấu hình SVM được khảo sát trên *PublicTest*: nhân tuyến tính với $C = 1$ và nhân RBF với $C = 10$, γ được xác định theo quy tắc *scale* của thư viện. Cấu hình RBF

đạt Macro-F1 bằng 0,4493, cao hơn mức 0,3126 của cấu hình tuyến tính, nên được cố định trước khi đánh giá cuối trên *PrivateTest*. Cách sử dụng LBP theo vùng và SVM phù hợp với hướng phương pháp được mô tả bởi Shan và cộng sự [**?**].

Trong giai đoạn thứ nhất, mô hình Emotion sử dụng trực tiếp trọng số do DeepFace cung cấp và không được huấn luyện trên FER-2013. Ảnh được chuyển qua bước tiền xử lý của mô hình; đầu ra là bảy điểm tương ứng với bảy lớp biểu cảm. Kết quả của cấu hình này tạo đường cơ sở để xác định việc tinh chỉnh ở giai đoạn sau thực sự làm thay đổi chất lượng như thế nào.

Trong giai đoạn thứ hai, mô hình Emotion được khởi tạo từ chính bộ trọng số nêu trên và toàn bộ các lớp của mạng được cho phép cập nhật. Mô hình được huấn luyện trên 28.709 ảnh *Training* bằng bộ tối ưu Adam, tốc độ học 10^{-5}, hàm mất mát entropy chéo cho nhãn số nguyên và kích thước lô bằng 128. Trọng số lớp được sử dụng để giảm ảnh hưởng của phân bố không cân bằng. Dữ liệu huấn luyện được tăng cường bằng phép lật ngang, xoay, tịnh tiến và thay đổi độ tương phản trong phạm vi đã cố định trước lần chạy.

Số epoch tối đa được đặt bằng 20. Sau mỗi epoch, Macro-F1 được tính trên *PublicTest*; trọng số chỉ được lưu khi chỉ số này tăng ít nhất 0,001. Quá trình dừng khi bốn epoch liên tiếp không tạo được mức cải thiện yêu cầu. Với giá trị khởi tạo ngẫu nhiên được cố định bằng 20261007 để có thể lặp lại lần chạy, mô hình tốt nhất xuất hiện tại epoch thứ nhất, đạt Macro-F1 bằng 0,4483 trên *PublicTest*. Bốn epoch tiếp theo không vượt qua kết quả này nên quá trình kết thúc sau năm epoch huấn luyện và khôi phục trọng số của epoch thứ nhất. Tập *PrivateTest* không được đọc để cập nhật trọng số, chọn epoch hoặc điều chỉnh siêu tham số; nó chỉ được sử dụng cho phép đánh giá cuối.

Quá trình tinh chỉnh được thực hiện trên MacBook Pro sử dụng bộ xử lý Apple M4 Pro gồm 12 lõi CPU, trong đó có tám lõi hiệu năng và bốn lõi tiết kiệm năng lượng, cùng 24 GB bộ nhớ hợp nhất. Môi trường TensorFlow chỉ nhận diện thiết bị CPU và không nhận diện GPU; vì vậy, toàn bộ quá trình huấn luyện lại được thực hiện trên CPU.

Ba cấu hình cuối cùng gồm LBP kết hợp SVM, CNN Emotion trước tinh chỉnh và CNN Emotion sau tinh chỉnh đều được đánh giá trên cùng 3.589 ảnh *PrivateTest*. Môi trường thực nghiệm sử dụng macOS 26.5, Python 3.11.7, scikit-learn 1.6.1, DeepFace 0.0.101, TensorFlow 2.21.0 và OpenCV 4.11.0. Trước khi đo độ trễ, mỗi phương pháp xử lý thử 20 ảnh; sau đó toàn bộ tập kiểm tra được chạy ba lượt để ghi nhận thời gian suy luận.

5.2.3 Tiêu chí đánh giá

Độ chính xác tổng thể được tính bằng tỷ lệ số ảnh dự đoán đúng trên tổng số ảnh kiểm tra. Chỉ số này cho biết tỷ lệ đúng chung nhưng chịu ảnh hưởng của phân bố lớp: lớp *Happy* có 879 ảnh trong *PrivateTest*, trong khi lớp *Disgust* chỉ có 55 ảnh. Vì vậy, chỉ sử dụng độ chính xác tổng thể có thể che khuất kết quả thấp ở lớp ít mẫu.

Đối với từng lớp, Precision, Recall và F1 được tính theo cách xem lớp đang xét là dương tính và sáu lớp còn lại là âm tính. Precision phản ánh mức độ hạn chế gán nhầm vào một biểu cảm; Recall phản ánh khả năng tìm đủ các ảnh thực sự thuộc biểu cảm đó; F1 mô tả sự cân bằng giữa hai đại lượng. Macro-F1 là trung bình cộng F1 của bảy lớp, còn Balanced Accuracy là trung bình Recall của bảy lớp. Hai chỉ số này cho mỗi lớp vai trò ngang nhau, do đó phù hợp hơn độ chính xác tổng thể khi FER-2013 có phân bố không cân bằng. Macro-F1 được chọn làm tiêu chí chất lượng chính. Normalized Confusion Matrix được dùng để xác định các cặp nhãn thường bị dự đoán sai; mỗi hàng biểu diễn nhãn thực tế, mỗi cột biểu diễn nhãn dự đoán và tổng các tỷ lệ trên một hàng bằng 1.

Chi phí thực thi được mô tả bằng độ trễ trung vị, độ trễ tại phân vị 95 và 99, số ảnh xử lý trong một giây, kích thước tệp mô hình và tỷ lệ ảnh xử lý thất bại. Quy tắc lựa chọn được xác định trước như sau: chọn phương pháp có Macro-F1 cao nhất; nếu các phương pháp cách giá trị cao nhất dưới 0,01 thì ưu tiên độ trễ phân vị 95 thấp hơn, sau đó ưu tiên mô hình nhỏ hơn. Quy tắc này bảo đảm tốc độ không được dùng để che khuất một chênh lệch chất lượng lớn giữa các phương pháp.

5.2.4 Kết quả thực nghiệm

Bảng 5.4 trình bày kết quả trên *PrivateTest*. Cả ba cấu hình đều xử lý đủ 3.589 ảnh và không phát sinh trường hợp lỗi. So với CNN Emotion trước tinh chỉnh, CNN Emotion sau tinh chỉnh giảm Accuracy từ 0,4848 xuống 0,4823, tương ứng 0,0025 điểm. Tuy nhiên, Macro-F1 tăng từ 0,4159 lên 0,4506 và Balanced Accuracy tăng từ 0,4178 lên 0,4576, tương ứng mức tăng 0,0347 và 0,0398 điểm. Như vậy, tinh chỉnh không làm tăng tỷ lệ đúng chung nhưng cải thiện rõ khả năng xử lý đồng đều giữa các lớp.

Bảng 5.4: Kết quả tổng thể của ba cấu hình phân loại biểu cảm trên PrivateTest

Phương pháp	Accuracy	Macro-F1	Balanced Accuracy	T_{50} (ms)	T_{95} (ms)	Ảnh/giây	Kích thước (MiB)	Tỷ lệ lỗi
LBP + SVM	0,4572	**0,4635**	0,4459	3,48	3,53	287,58	77,12	0,0000
CNN Emotion trước tinh chỉnh	**0,4848**	0,4159	0,4178	**2,32**	**2,62**	**428,72**	**5,70**	0,0000
CNN Emotion sau tinh chỉnh	0,4823	0,4506	**0,4576**	2,35	2,62	422,51	5,70	0,0000

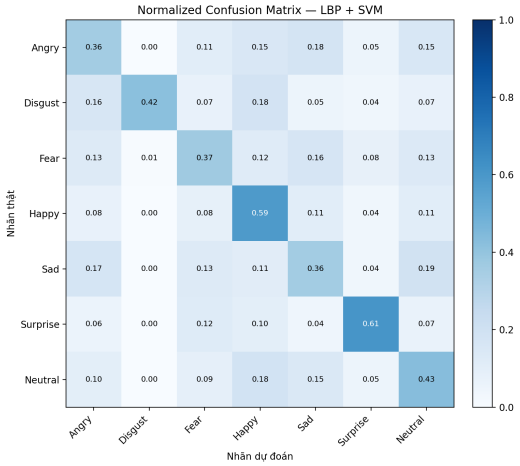
Khi đối chiếu với LBP kết hợp SVM, CNN Emotion sau tinh chỉnh có Accuracy

cao hơn 0,0251 điểm và Balanced Accuracy cao hơn 0,0117 điểm. Ngược lại, Macro-F1 của LBP kết hợp SVM cao hơn 0,0129 điểm. Kết quả này không cho phép kết luận một phương pháp tốt hơn trên mọi tiêu chí. Mô hình CNN sau tinh chỉnh dự đoán đúng nhiều ảnh hơn xét trên toàn bộ tập kiểm tra, còn LBP kết hợp SVM vẫn đạt trung bình F1 giữa bảy lớp cao hơn một mức nhỏ.

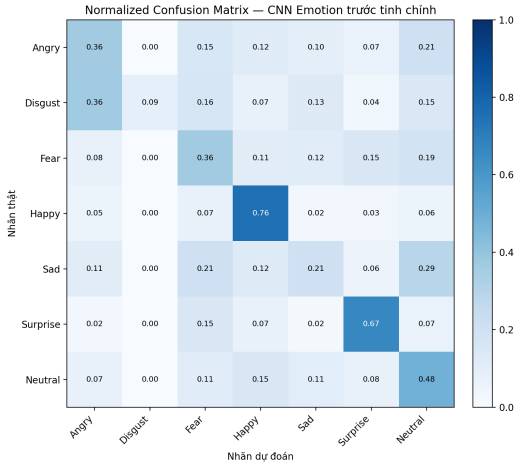
Kết quả F1 theo từng lớp tại Bảng 5.5 làm rõ tác động của quá trình tinh chỉnh. Mức cải thiện lớn nhất xuất hiện ở lớp *Disgust*, từ 0,1563 lên 0,3738; F1 của *Angry*, *Happy* và *Sad* cũng tăng. Ngược lại, F1 của *Fear* và *Neutral* giảm, còn *Surprise* gần như không thay đổi. Vì vậy, mức tăng Macro-F1 không xuất phát từ việc tất cả các lớp cùng tốt lên, mà chủ yếu do mô hình giảm được kết quả quá thấp ở một số lớp.

Bảng 5.5: F1 theo từng lớp của ba cấu hình trên PrivateTest

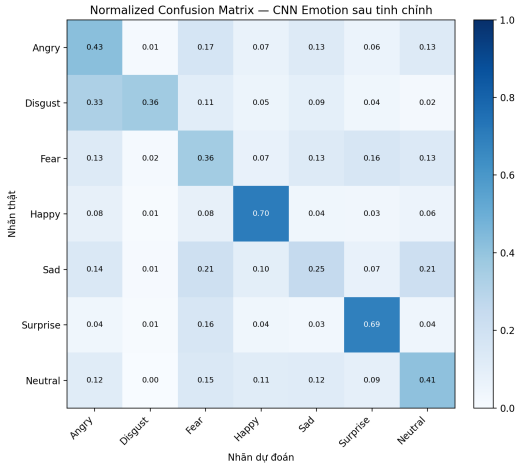
Lớp	**Số ảnh**	**LBP + SVM**	**CNN trước tinh chỉnh**	**CNN sau tinh chỉnh**
Angry	491	0,3504	0,3951	**0,4054**
Disgust	55	**0,5476**	0,1563	0,3738
Fear	528	**0,3749**	0,3387	0,3261
Happy	879	0,5857	0,7151	**0,7202**
Sad	594	**0,3572**	0,2688	0,2983
Surprise	416	**0,6094**	0,6041	0,6047
Neutral	626	0,4190	**0,4334**	0,4256



(a) LBP kết hợp SVM



(b) CNN Emotion trước tinh chỉnh



(c) CNN Emotion sau tinh chỉnh

Hình 5.1: Normalized Confusion Matrix của ba cấu hình trên PrivateTest

Normalized Confusion Matrix tại Hình 5.1b và Hình 5.1c cho thấy sau tinh chỉnh, Recall của *Disgust* tăng từ 0,0909 lên 0,3636 và Recall của *Angry* tăng từ 0,3605 lên 0,4257. Đổi lại, Recall của *Happy* giảm từ 0,7565 xuống 0,7042 và Recall của *Neutral* giảm từ 0,4808 xuống 0,4137. Sự dịch chuyển này giải thích tại sao Balanced Accuracy và Macro-F1 tăng trong khi Accuracy giảm nhẹ.

Về hiệu năng, CNN Emotion sau tinh chỉnh có độ trễ phân vị 95 bằng 2,62 ms và thông lượng 422,51 ảnh mỗi giây, trong khi LBP kết hợp SVM lần lượt đạt 3,53 ms và 287,58 ảnh mỗi giây. Tệp trọng số của CNN Emotion có kích thước 5,70 MiB, còn mô hình SVM sau huấn luyện có kích thước 77,12 MiB. Việc tinh chỉnh gần như không làm thay đổi kích thước hoặc độ trễ của mạng, nhưng giúp thu hẹp khoảng cách Macro-F1 so với LBP kết hợp SVM từ 0,0475 xuống 0,0129.

5.2.5 Phạm vi diễn giải và giới hạn

Kết quả cho thấy tinh chỉnh CNN Emotion trên FER-2013 có hiệu quả đối với mục tiêu cải thiện sự cân bằng giữa các lớp: Macro-F1 và Balanced Accuracy đều tăng so với trước tinh chỉnh, trong khi Accuracy chỉ giảm 0,0025 điểm. Khi so với LBP kết hợp SVM, CNN Emotion sau tinh chỉnh có Accuracy và Balanced Accuracy cao hơn, đồng thời nhanh hơn và nhỏ hơn; LBP kết hợp SVM vẫn có Macro-F1 cao hơn 0,0129 điểm. Theo quy tắc lấy Macro-F1 làm tiêu chí chính và biên tương đương bằng 0,01, LBP kết hợp SVM vẫn được xếp cao hơn về tiêu chí chính, nhưng chênh lệch chỉ còn 0,0029 điểm ngoài biên tương đương. Nếu mục tiêu triển khai đồng thời ưu tiên tỷ lệ dự đoán đúng chung, độ trễ và kích thước mô hình, CNN Emotion sau tinh chỉnh là phương án phù hợp hơn trong ba cấu hình đã đo. Kết luận này chỉ áp dụng cho FER-2013 và môi trường thực nghiệm đã mô tả.

FER-2013 gồm các ảnh khuôn mặt đã được cắt sẵn, có độ phân giải thấp và không đại diện đầy đủ cho ảnh camera tại không gian mua sắm. Vì vậy, độ trễ tại mục này chỉ là thời gian của bộ phân loại và không thay thế phép đo độ trễ đầu cuối của hệ thống. Ngoài ra, bản kê khai dữ liệu phát hiện các ảnh trùng khớp hoàn toàn giữa các phần chia chính thức, gồm 278 cặp giữa *Training* và *PrivateTest*, cùng 43 cặp giữa *PublicTest* và *PrivateTest*. Thực nghiệm giữ nguyên cách chia chính thức để bảo đảm khả năng đối chiếu với FER-2013, nhưng hiện tượng này có thể làm kết quả của phương pháp được huấn luyện trên *Training* lạc quan hơn so với một phép chia đã loại trùng.

Mỗi cấu hình chỉ được đo bằng một lần chạy đầy đủ; vì vậy, kết quả chưa phản ánh độ biến thiên qua nhiều lần khởi tạo và huấn luyện. Mô hình sau tinh chỉnh mới được huấn luyện với một bộ siêu tham số và một giá trị khởi tạo ngẫu nhiên cố định. Ngoài ra, quyết định chọn cấu hình dựa trên nhiều tiêu chí phụ thuộc vào mục tiêu triển khai; Accuracy cao hơn không tự động đồng nghĩa chất lượng tốt hơn ở mọi lớp, còn Macro-F1 cao hơn cũng không tự động đồng nghĩa mô hình dự đoán đúng nhiều ảnh hơn. Các kết quả tại mục này được dùng để mô tả sự đánh đổi giữa ba cấu hình trong phạm vi FER-2013; trước khi thay đổi mô hình của hệ thống, cần kiểm tra tiếp trên dữ liệu camera phù hợp với môi trường mục tiêu.

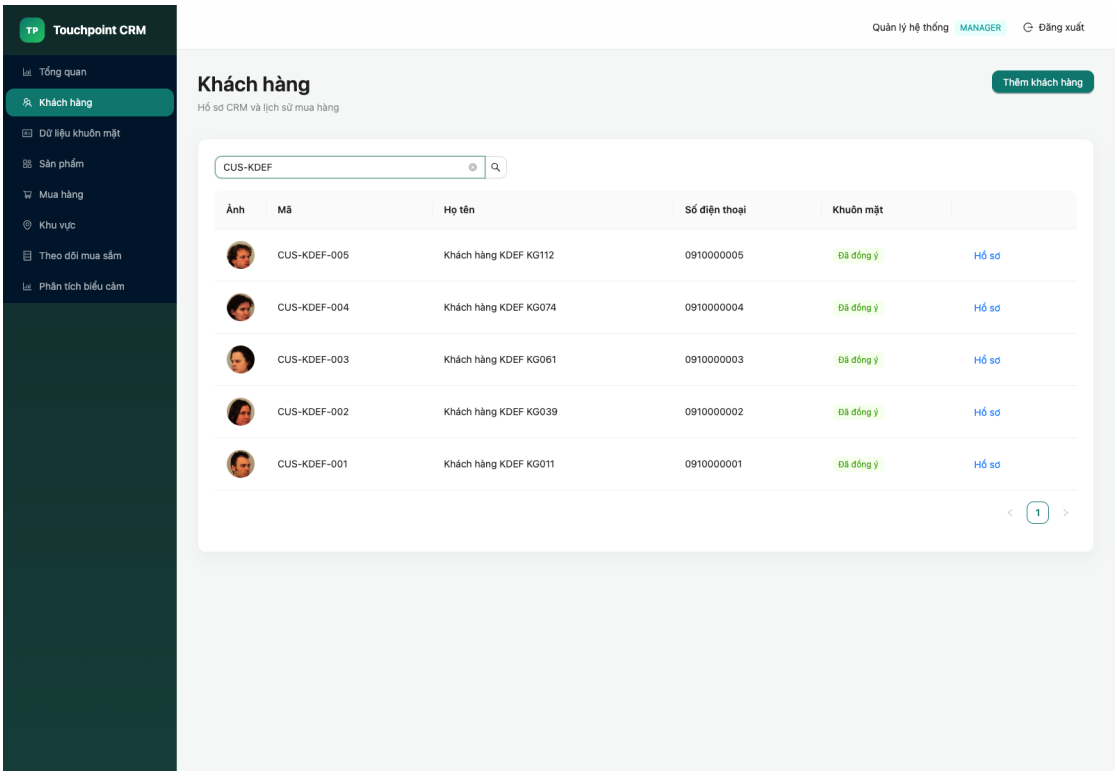
5.3 Thiết kế thực nghiệm đánh giá hệ thống đầu cuối

5.3.1 Dữ liệu và khởi tạo hồ sơ khách hàng

Dữ liệu ảnh để xây dựng hồ sơ khách hàng được lấy từ bản KDEF trên Kaggle [**?**], gồm 2.938 ảnh thuộc bảy nhãn biểu cảm: *Angry*, *Disgust*, *Fear*, *Happy*, *Neutral*, *Sad* và *Surprise*. Từ các nhóm ảnh có đủ bảy nhãn, luận văn lựa chọn ngẫu nhiên năm nhóm để xây dựng năm khách hàng thực nghiệm; mỗi nhóm được gắn với một hồ sơ riêng.

Mỗi hồ sơ gồm mã khách hàng duy nhất, tên, số điện thoại, địa chỉ thư điện tử và ảnh đại diện. Các thông tin dạng văn bản được tạo giả lập. Trong mỗi nhóm, ba ảnh của từng nhãn được xếp hạng theo mức độ gần chính diện bằng bộ phát hiện Haar. Ảnh *Neutral* xếp thứ hai được dùng để tạo mẫu khuôn mặt và đồng thời làm ảnh đại diện của hồ sơ; cách lựa chọn này dành ảnh gần chính diện nhất cho dữ liệu camera. Ảnh tạo mẫu được tách riêng khỏi ảnh hiệu chỉnh và ảnh quan sát.

Sau khi tạo hồ sơ, ảnh được đưa qua luồng tạo mẫu khuôn mặt của hệ thống. RetinaFace phát hiện khuôn mặt, ArcFace trích xuất véc-tơ đặc trưng và hệ thống lưu mẫu khuôn mặt gắn với mã khách hàng tương ứng. Kết quả khởi tạo gồm năm hồ sơ, mỗi hồ sơ có một mẫu khuôn mặt để đối sánh với ảnh camera ở các bước tiếp theo. Hình 5.2 thể hiện danh sách hồ sơ đã tạo trên giao diện, gồm ảnh đại diện, mã khách hàng, tên và số điện thoại.



Hình 5.2: Danh sách năm hồ sơ khách hàng sau khi khởi tạo từ ảnh KDEF

5.3.2 Nguyên tắc xây dựng dữ liệu camera thử nghiệm

Tách dữ liệu theo mục đích. Với mỗi khách hàng và mỗi nhãn biểu cảm, luận văn dành ảnh có mức độ gần chính diện cao nhất cho dữ liệu camera. Một ảnh *Neutral* khác được dùng để tạo mẫu khuôn mặt của hồ sơ. Trong phần ảnh còn lại, mỗi nhãn được lấy một ảnh để hiệu chỉnh ngưỡng ArcFace, tạo thành bảy ảnh hiệu chỉnh cho mỗi khách hàng. Ba nhóm ảnh dùng để tạo mẫu, hiệu chỉnh và làm đầu vào camera được tách riêng, không dùng chung ảnh.

Tạo hành trình mua sắm. Mỗi khách hàng được xây dựng năm hành trình. Một hành trình gồm bốn điểm chạm theo thứ tự Cửa vào–Khu trưng bày–Khu tư vấn–Quầy thanh toán. Với năm khách hàng, bộ dữ liệu dự kiến gồm 25 hành trình và 100 khung ảnh camera.

Lựa chọn ảnh ngẫu nhiên. Tại mỗi điểm chạm, luận văn lựa chọn ngẫu nhiên một trong bảy nhãn biểu cảm, sau đó lấy ảnh camera gần chính diện đã dành cho nhãn đó của khách hàng tương ứng. Ảnh đã chọn vẫn có thể được dùng lại ở điểm chạm khác. Bộ sinh số ngẫu nhiên sử dụng một giá trị khởi tạo cố định để có thể tái lập bộ dữ liệu. Vì vậy, chuỗi biểu cảm của hành trình, số cụm và chuỗi đại diện không được sắp xếp trước.

Giữ nguyên ảnh nguồn. Ảnh camera được gửi ở độ phân giải nguồn 562×762 pixel, không đặt vào khung nền, không thay đổi kích thước và không điều chỉnh độ sáng. Lựa chọn này loại bỏ ảnh hưởng của phép biến đổi hình học khi đánh giá khả năng xử lý ảnh của hệ thống.

Gán thời gian quan sát. Mỗi hành trình được gán một thời điểm bắt đầu. Khoảng thời gian từ một điểm chạm đến điểm chạm kế tiếp được lựa chọn ngẫu nhiên trong khoảng từ 5 đến 15 phút để biểu diễn thời gian di chuyển của khách hàng. Chẳng hạn, nếu camera tại Cửa vào ghi nhận khách hàng lúc 09:30 thì camera tại Khu trưng bày có thể ghi nhận trong khoảng từ 09:35 đến 09:45; thời điểm của các camera sau tiếp tục được xác định từ thời điểm quan sát liền trước. Năm hành trình của cùng một khách hàng được đặt ở năm ngày liên tiếp. Khoảng 5–15 phút nhỏ hơn ngưỡng gián đoạn tối đa 30 phút đã xác định ở Chương 3, do đó bốn quan sát liên tiếp vẫn được hệ thống liên kết vào cùng một hành trình. Các mốc này là thời gian quan sát được gán cho dữ liệu, không phải thời gian chương trình phải chờ giữa hai lần gửi ảnh.

Đưa ảnh vào hệ thống. Các ảnh được gửi theo thứ tự điểm chạm qua giao diện tiếp nhận mà nguồn camera sử dụng. Nhãn gốc của KDEF không được gửi vào hệ thống. Từ ảnh đầu vào, hệ thống thực hiện phát hiện khuôn mặt, ghép định danh, dự đoán biểu cảm, lưu quan sát và hình thành hành trình cùng chuỗi trạng thái.

Nhãn KDEF chỉ được giữ bên ngoài hệ thống để đối chiếu với kết quả sau khi quá trình xử lý kết thúc.

5.4 Triển khai và kết quả thực nghiệm đầu cuối

5.4.1 Môi trường và trình tự thực hiện

Hệ thống được dựng lại bằng Docker Compose trên máy MacBook Pro sử dụng bộ xử lý Apple M4 Pro với 12 lõi CPU và 24 GB bộ nhớ. Các thành phần thuộc phạm vi đánh giá gồm PostgreSQL/pgvector, dịch vụ xử lý ảnh, tiến trình cập nhật cấu trúc cơ sở dữ liệu (migration), máy chủ nghiệp vụ và giao diện web. Dịch vụ xử lý ảnh sử dụng RetinaFace để phát hiện khuôn mặt, ArcFace để ghép định danh và CNN Emotion để phân loại biểu cảm; các trọng số và tham số được cố định trước khi phát dữ liệu. Nguồn ảnh camera được biểu diễn bởi chương trình phát dữ liệu bên ngoài hệ thống; thành phần này gọi cùng giao diện tiếp nhận ảnh dành cho nguồn camera. Do ảnh được phát lại từ bộ dữ liệu thay vì thu đồng thời từ bốn camera vật lý, thực nghiệm tập trung vào luồng xử lý phần mềm từ tiếp nhận ảnh đến kết quả phân tích.

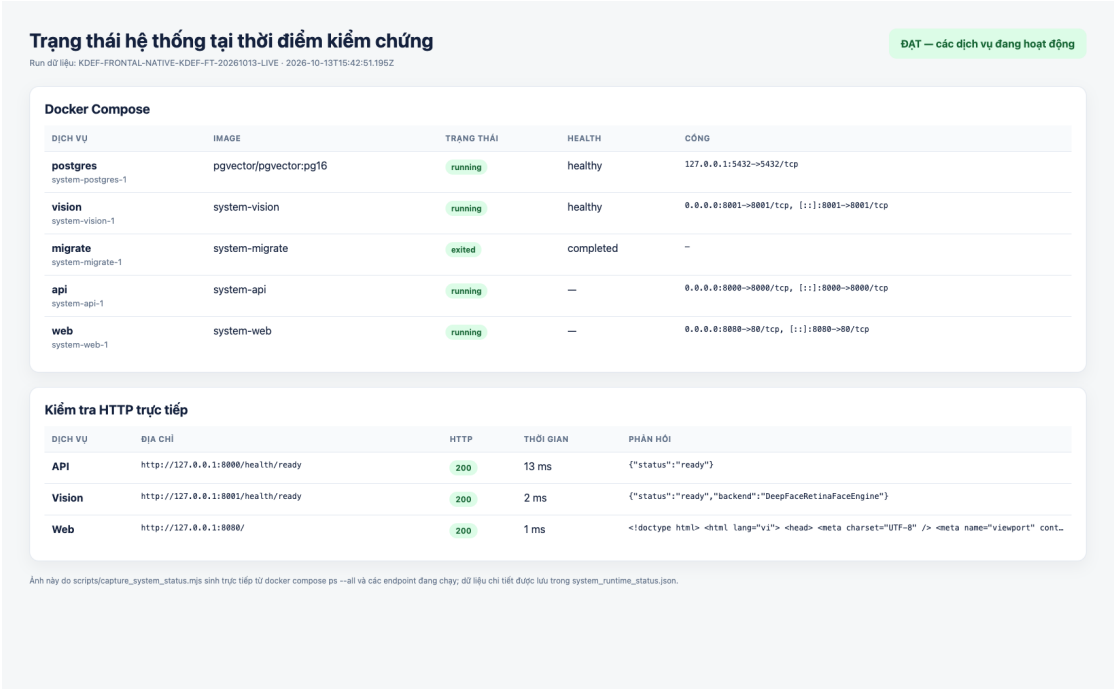
Bảng 5.6: Môi trường triển khai tại thời điểm thực nghiệm đầu cuối

Thành phần	Nền tảng	Cổng	Trạng thái
Cơ sở dữ liệu	PostgreSQL 16, pgvector	5432	Hoạt động, health check đạt
Dịch vụ xử lý ảnh	FastAPI, RetinaFace, ArcFace, DeepFace	8001	Hoạt động, health check đạt
Máy chủ nghiệp vụ	FastAPI, SQLAlchemy, Sequenzo	8000	Hoạt động, HTTP 200
Giao diện web	React, Nginx	8080	Hoạt động, HTTP 200

Trước khi phát dữ liệu, cơ sở dữ liệu cũ được sao lưu, các bản ghi mang cờ dữ liệu thử nghiệm được xóa và dữ liệu CRM được nạp lại. Ngoài năm hồ sơ khách hàng, hệ thống được khởi tạo với sáu nhóm sản phẩm, 24 sản phẩm và bốn điểm chạm gồm Cửa vào, Khu trưng bày sản phẩm, Khu tư vấn và Quầy thanh toán. Kịch bản không tạo đơn hàng. Năm ảnh được xử lý để tạo mẫu khuôn mặt. Tiếp theo, 35 ảnh tách riêng được dùng để hiệu chỉnh ngưỡng ArcFace; 100 ảnh quan sát được gửi theo lịch đã tạo; hệ thống liên kết quan sát thành lần mua sắm và tạo chuỗi dự đoán; cuối cùng, Optimal Matching–PAM được chạy trên các chuỗi đủ điều kiện. Trước khi chụp lại màn hình, kết quả được kiểm tra về số lượng bản ghi, thứ tự điểm chạm, liên kết khách hàng và sự thống nhất giữa hành trình với chuỗi phân tích. Các phản hồi API, khoảng cách hiệu chỉnh, kết quả phân tích và ảnh chụp được lưu cùng mã lần chạy để đối chiếu.

Hình 5.3 ghi lại trạng thái các thành phần được đánh giá và các điểm kiểm tra HTTP. Ngoài kiểm tra khi chạy, 15 kiểm thử máy chủ nghiệp vụ và 14 kiểm thử dịch vụ xử lý ảnh, trong đó có các kiểm thử bộ lấy mẫu và tách dữ liệu camera, đều

đạt; giao diện web biên dịch thành công bằng TypeScript và Vite. Toàn bộ 100 ảnh sau đó được phát qua các dịch vụ Docker để lấy kết quả thực nghiệm đầu cuối.



Hình 5.3: Trạng thái các thành phần của hệ thống tại thời điểm thực nghiệm

5.4.2 Kết quả tiếp nhận ảnh và liên kết hành trình

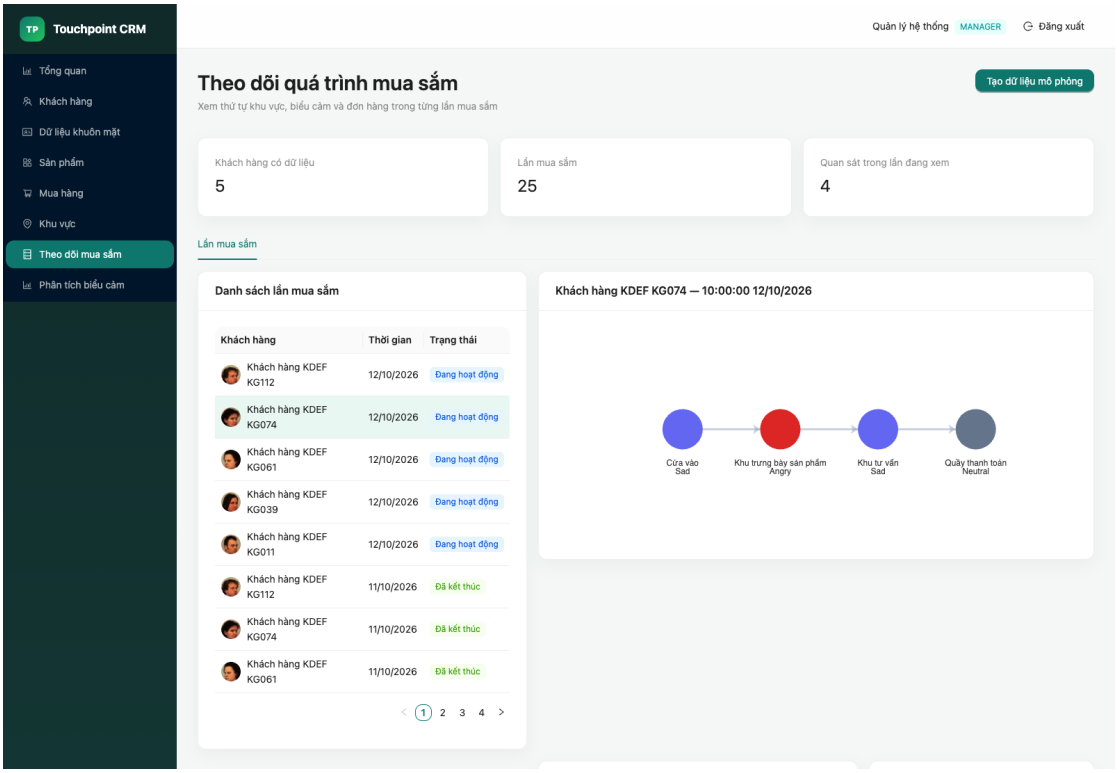
Ngưỡng khoảng cách ArcFace được xác định từ 35 ảnh hiệu chỉnh, tạo 105 cặp cùng nhóm và 490 cặp khác nhóm. Giữ nguyên quy tắc ROC ở Chương 3, hệ thống chọn ngưỡng có TPR lớn nhất trong các ứng viên thỏa FPR thực nghiệm bằng 0; nếu đồng hạng thì chọn ngưỡng lớn nhất. Ngưỡng thu được là 0,6303, chấp nhận 93/105 cặp cùng nhóm và không chấp nhận cặp nào trong 490 cặp khác nhóm.

Hệ thống tiếp nhận toàn bộ 100 ảnh, mỗi ảnh phát hiện được một khuôn mặt hợp lệ. ArcFace ghép đúng 97 ảnh với hồ sơ dự kiến; ba ảnh không đạt điều kiện ghép hồ sơ và không có ảnh bị ghép sang hồ sơ khác. Máy chủ vẫn lưu sự kiện tiếp nhận của ba ảnh không khớp nhưng không tạo quan sát gắn khách hàng cho chúng. Vì vậy, số khung xử lý hợp lệ là 100 nhưng số quan sát được lưu để tạo hành trình chỉ là 97.

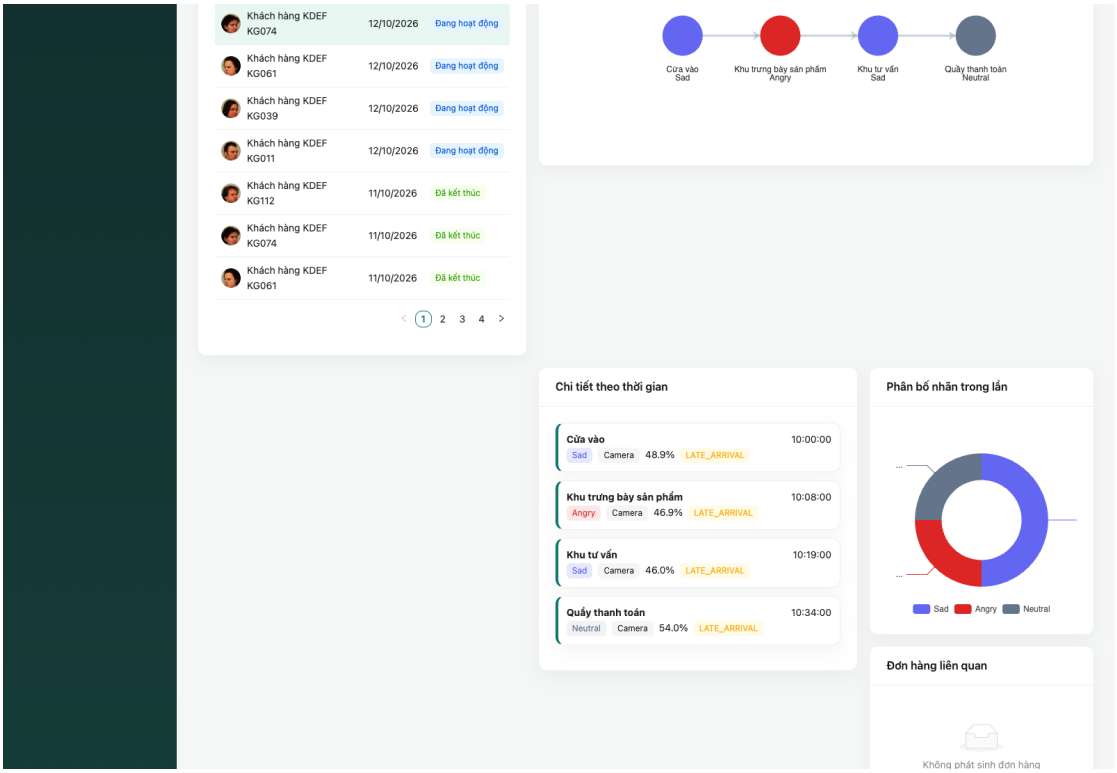
Bảng 5.7: Kết quả tiếp nhận và ghép định danh ảnh KDEF

Chỉ tiêu	Số ảnh	Tỷ lệ
Ảnh được xử lý hợp lệ	100	100,0%
Ghép đúng hồ sơ dự kiến	97	97,0%
Không tìm thấy hồ sơ phù hợp	3	3,0%
Ghép sang hồ sơ khác	0	0,0%

Từ 97 quan sát đã ghép định danh, hệ thống tạo 25 lần mua sắm: 23 lần đủ bốn điểm chạm, một lần chỉ có ba và một lần chỉ có hai quan sát. Các quan sát được lưu vẫn giữ đúng thứ tự điểm chạm. Hình 5.4 và Hình 5.5 minh họa một hành trình đầy đủ; hai hành trình thiếu được giữ trong dữ liệu và bị loại ở bước phân cụm theo điều kiện tối thiểu bốn trạng thái.



Hình 5.4: Một lần mua sắm có đủ bốn điểm chạm sau khi xử lý ảnh



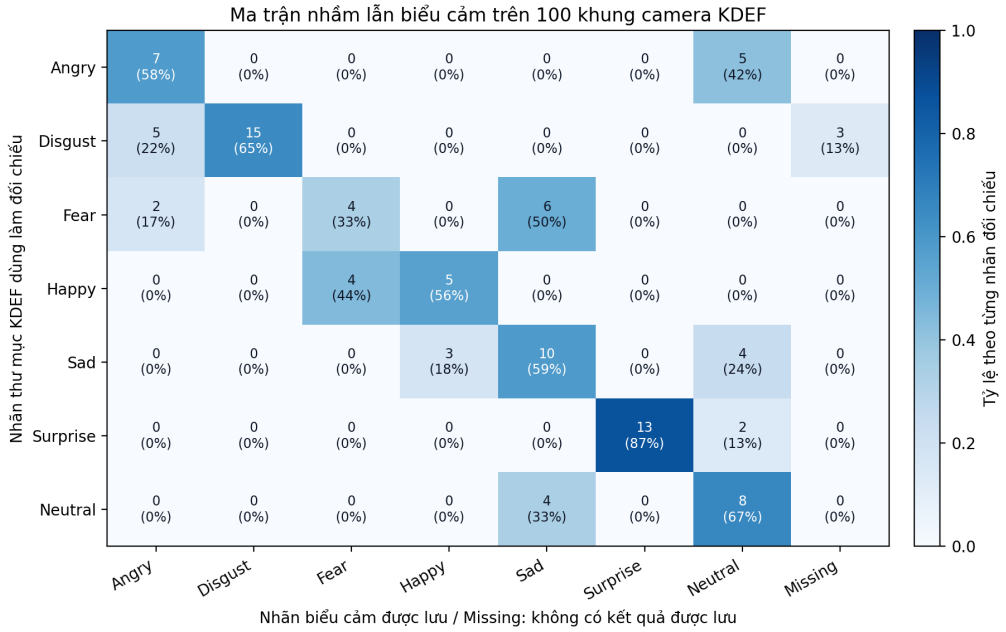
Hình 5.5: Các quan sát nguồn Camera được sắp theo thời gian trong một lần mua sắm

5.4.3 Đánh giá hiệu quả phân loại biểu cảm trong luồng đầu cuối

Nhãn do CNN Emotion dự đoán được đối chiếu với nhãn thư mục sau khi quá trình phát dữ liệu kết thúc. Trong 100 ảnh đầu vào, 97 ảnh có nhãn biểu cảm được lưu cùng quan sát và 62 ảnh có nhãn đúng. Tỷ lệ đầu vào tạo được nhãn đúng là $62/100 = 0{,}620$; Accuracy riêng trên các dự đoán được lưu là $62/97 = 0{,}639$. Ba ảnh không tạo được quan sát được tính vào cột *Missing*. Macro-F1 đầu cuối bằng 0,614 trên cả bảy lớp; khi tính Recall, các ảnh thiếu kết quả vẫn nằm trong tổng số đầu vào của lớp tương ứng.

Bảng 5.8: Kết quả biểu cảm của dữ liệu trong luồng đầu cuối

Lớp	Số mẫu	Precision	Recall	F1
Angry	12	0,500	0,583	0,538
Disgust	23	1,000	0,652	0,789
Fear	12	0,500	0,333	0,400
Happy	9	0,625	0,556	0,588
Sad	17	0,500	0,588	0,541
Surprise	15	1,000	0,867	0,929
Neutral	12	0,421	0,667	0,516



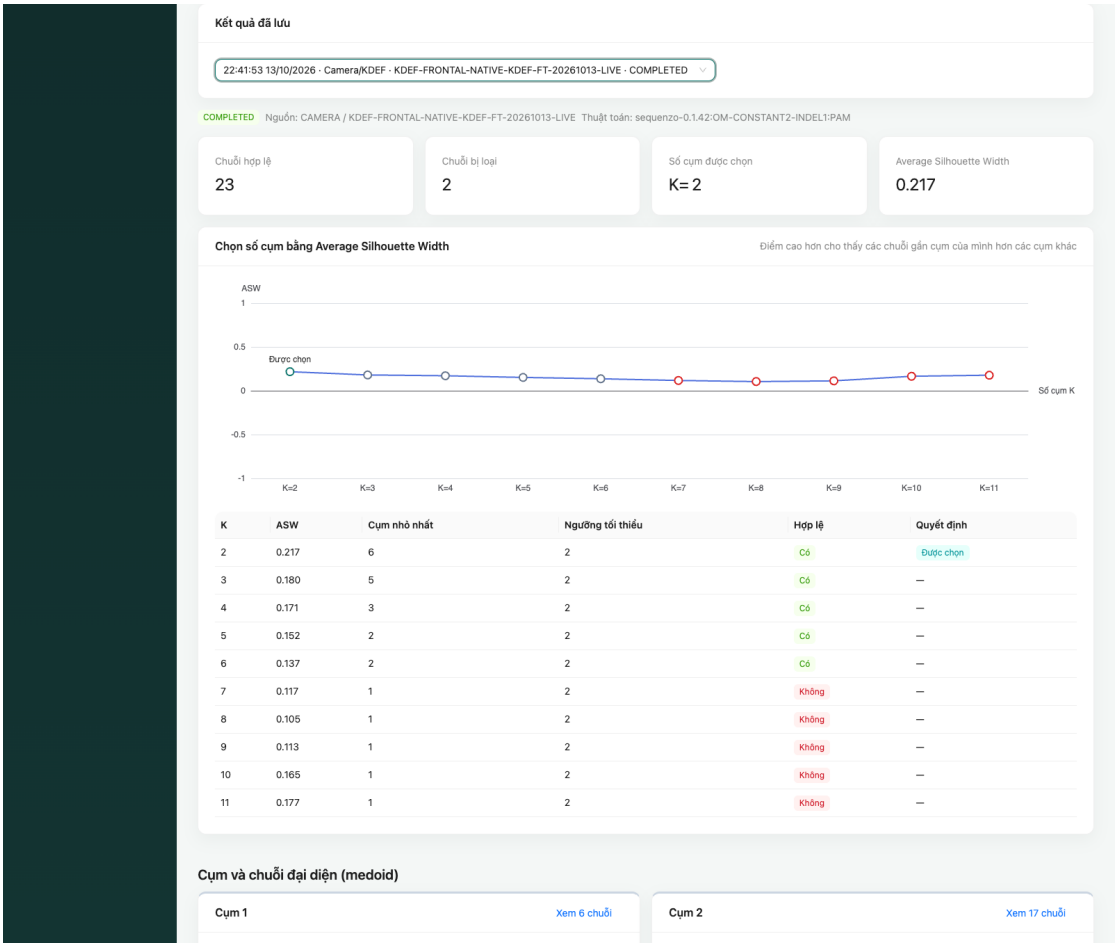
Hình 5.6: Ma trận nhầm lẫn biểu cảm trên 100 ảnh của lần chạy đầu cuối

Xét trên toàn bộ 100 ảnh đầu vào, hệ thống tạo được nhãn đúng cho 62 ảnh. *Surprise* có F1 cao nhất, bằng 0,929, tiếp theo là *Disgust* với 0,789. Các lớp *Happy*, *Sad*, *Angry* và *Neutral* đạt F1 trong khoảng từ 0,516 đến 0,588. *Fear* có kết quả thấp nhất với F1 bằng 0,400: bốn ảnh được dự đoán đúng, sáu ảnh bị gán thành *Sad* và hai ảnh bị gán thành *Angry*. Ma trận nhầm lẫn cũng cho thấy năm ảnh *Angry* bị gán thành *Neutral*, bốn ảnh *Happy* bị gán thành *Fear* và bốn ảnh *Neutral* bị gán thành *Sad*. Kết quả này cho thấy mô hình đã nhận diện đúng phần lớn đầu vào nhưng hiệu quả vẫn khác nhau giữa các lớp biểu cảm.

5.4.4 Kết quả tạo và phân cụm chuỗi trạng thái

Từ 25 lần mua sắm đã hình thành, hệ thống sắp xếp các nhãn biểu cảm dự đoán theo thứ tự bốn điểm chạm để tạo chuỗi trạng thái. Có 23 lần mua sắm tạo được chuỗi đủ bốn trạng thái; một lần chỉ có ba trạng thái và một lần chỉ có hai trạng thái do một số ảnh không ghép được định danh. Vì vậy, đầu vào của bước phân cụm gồm 23 chuỗi có cùng độ dài bốn. Các trạng thái trong chuỗi là kết quả dự đoán của hệ thống, không phải nhãn gốc của KDEF.

Quy trình phân cụm tại Chương 3 được áp dụng trực tiếp cho 23 chuỗi này. Các phương án từ $K = 2$ đến $K = 6$ đáp ứng điều kiện mỗi cụm có ít nhất hai chuỗi. Các phương án từ $K = 7$ đến $K = 11$ tạo ra cụm chỉ có một chuỗi nên bị loại. Trong các phương án hợp lệ, $K = 2$ có ASW lớn nhất, bằng 0,2171, và được chọn làm kết quả cuối cùng.

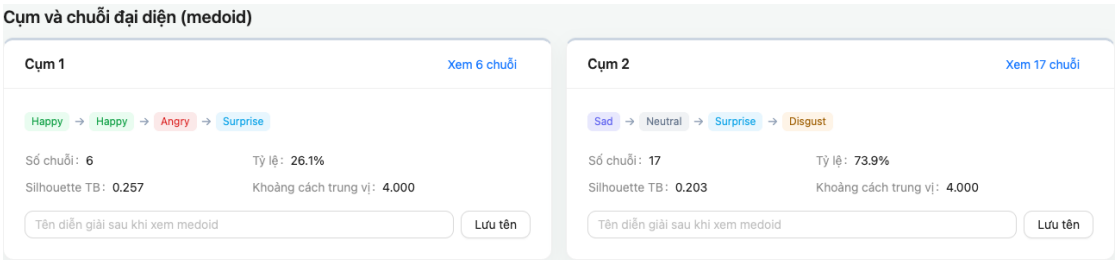


Hình 5.7: Kết quả lựa chọn số cụm từ 23 chuỗi trạng thái trên giao diện

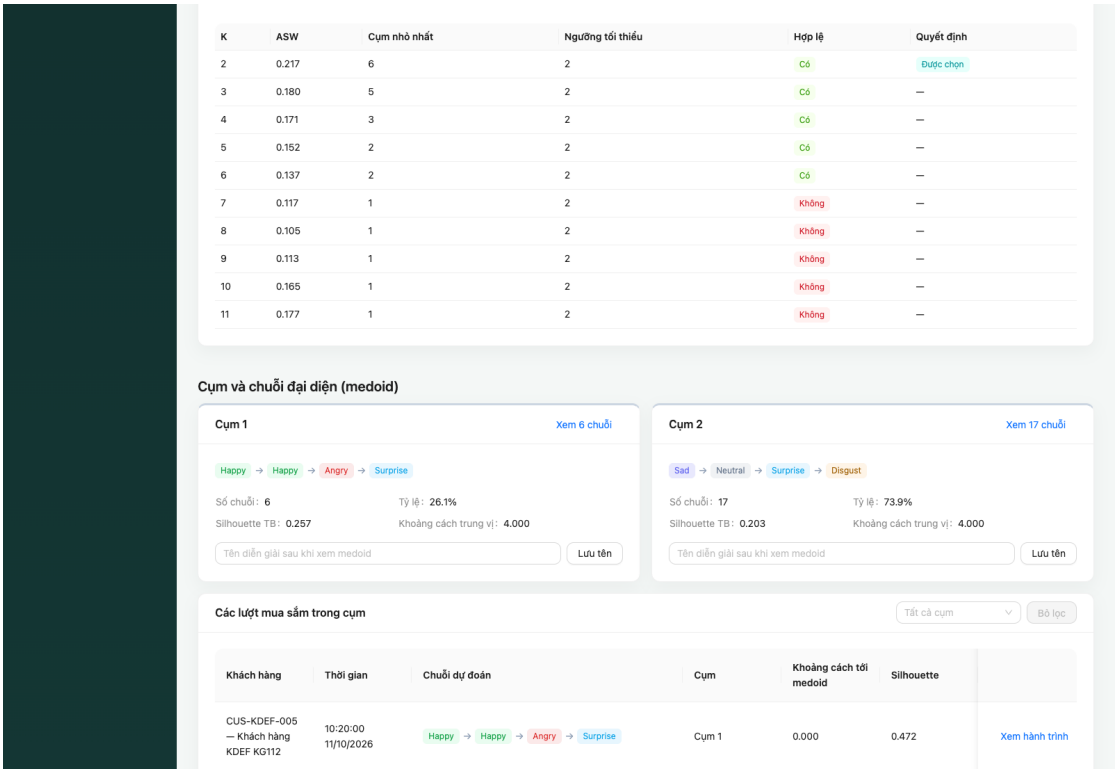
Bảng 5.9: Kết quả phân cụm 23 chuỗi trạng thái dự đoán đủ điều kiện

Cụm	Chuỗi medoid	Số chuỗi	Tỷ lệ	Silhouette TB
1	Happy → Happy → Angry → Surprise	6	26,1%	0,257
2	Sad → Neutral → Surprise → Disgust	17	73,9%	0,203

Cụm 2 có số lượng lớn nhất với 17 chuỗi, chiếm 73,9%; cụm 1 gồm sáu chuỗi, chiếm 26,1%. Silhouette trung bình của hai cụm lần lượt bằng 0,203 và 0,257; không có chuỗi nào mang silhouette âm. Các medoid trong Bảng 5.9 là hai chuỗi biểu cảm đại diện thu được từ dữ liệu thử nghiệm. Hình 5.8 và Hình 5.9 trình bày hai chuỗi medoid và danh sách các lần mua sắm thuộc từng cụm.

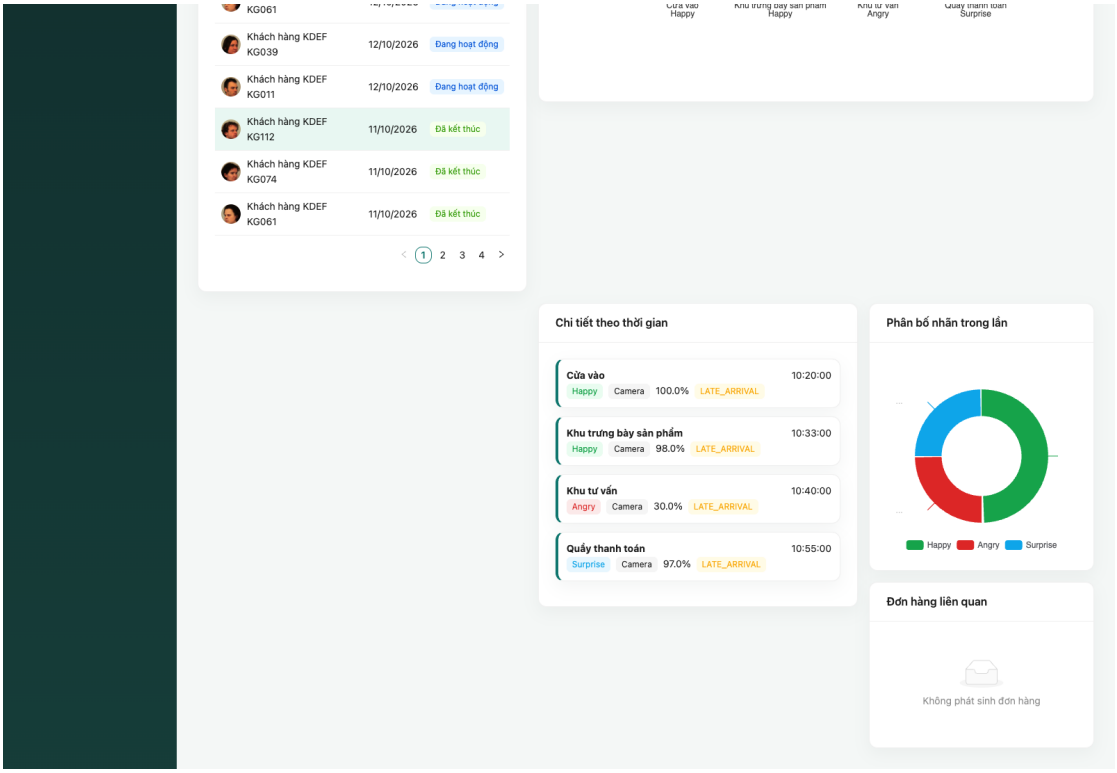


Hình 5.8: Medoid và thống kê của hai cụm trên giao diện hệ thống



Hình 5.9: Danh sách các lần mua sắm được gán cụm

Mỗi kết quả gán cụm được liên kết với lần mua sắm đã tạo ra chuỗi tương ứng. Từ danh sách gán cụm, có thể mở lại lần mua sắm và kiểm tra các quan sát theo từng điểm chạm, thời gian ghi nhận và biểu cảm dự đoán như Hình 5.10. Kết quả này xác nhận đầu ra phân cụm có thể được truy vết về các quan sát ban đầu của hành trình.



Hình 5.10: Truy vết một kết quả gán cụm về các quan sát ban đầu

5.5 Đánh giá hiệu quả hệ thống

Bảng 5.10 tổng hợp kết quả theo từng công đoạn. Trong 100 ảnh đầu vào, 97 ảnh tạo được quan sát gắn đúng hồ sơ; hệ thống hình thành 25 lần mua sắm và 23 lần đủ bốn điểm chạm để phân cụm. Kết quả kiểm tra sau thực nghiệm đạt 35/35 điều kiện về số lượng, thứ tự điểm chạm, kết quả ghép định danh và tính nhất quán giữa số hành trình đầy đủ với số chuỗi được phân tích.

Bảng 5.10: Đánh giá hiệu quả của luồng hệ thống đầu cuối

Công đoạn	Tiêu chí	Kết quả	Đánh giá
Tiếp nhận và xử lý ảnh	Ảnh tạo được kết quả hợp lệ	100/100	Hoàn thành toàn bộ đầu vào của kịch bản.
Ghép định danh	Đúng hồ sơ dự kiến	97/100	Ba ảnh không khớp; số trường hợp ghép sai là 0.
Tạo lần mua sắm	Đủ bốn điểm chạm, đúng thứ tự	23/25	Hai hành trình thiếu quan sát do không khớp định danh.
Kết quả biểu cảm đầu cuối	Tỷ lệ nhãn đúng trên đầu vào; Macro-F1	0,620; 0,614	Accuracy trên 97 kết quả được lưu là 0,639.
Phân cụm chuỗi	Chuỗi được sử dụng; ASW	23/25; 0,2171	Hai cụm; hai chuỗi bị loại vì thiếu trạng thái.
Kiểm tra và truy vết	Điều kiện kiểm tra đạt	35/35	Kết quả phân tích liên kết được về dữ liệu nguồn.

Đối với phân loại biểu cảm, 62 trong 100 ảnh đầu vào tạo được nhãn đúng; Accuracy trên 97 ảnh có kết quả là 0,639 và Macro-F1 đầu cuối là 0,614. Trong 38 ảnh còn lại, 35 ảnh có nhãn dự đoán khác nhãn đối chiếu và ba ảnh không tạo được quan sát do không ghép được định danh. Ba ảnh này làm hai hành trình bị thiếu trạng thái. Ở bước phân cụm, 23 chuỗi đủ điều kiện được chia thành hai cụm với ASW bằng 0,2171; không có chuỗi mang silhouette âm. Kết quả kiểm tra 35/35 điều kiện và liên kết truy vết từ cụm về từng quan sát cho thấy toàn bộ các công đoạn trong phạm vi kịch bản đã trao đổi và lưu trữ dữ liệu đúng cấu trúc.

Biểu cảm tại bốn điểm chạm được lựa chọn độc lập nên các chuỗi không được sắp đặt trước. Kết quả phân cụm xác định được hai chuỗi biểu cảm đại diện như trình bày trong Bảng 5.9. Mỗi chuỗi là medoid của một cụm, tức chuỗi có tổng khoảng cách nhỏ nhất đến các chuỗi còn lại trong cùng cụm. Hai medoid thu được là *Happy–Happy–Angry–Surprise* và *Sad–Neutral–Surprise–Disgust*.

TÀI LIỆU THAM KHẢO

[1] K. N. Lemon and P. C. Verhoef, "Understanding customer experience throughout the customer journey," *Journal of Marketing*, vol. 80, no. 6, pp. 69–96, 2016. [Online]. Available: https://doi.org/10.1509/jm.15.0420

[2] R. Halvorsrud, K. Kvale, and A. Folstad, "Improving service quality through customer journey analysis," *Journal of Service Theory and Practice*, vol. 26, no. 6, pp. 840–867, 2016. [Online]. Available: https://doi.org/10.1108/JSTP-05-2015-0111

[3] P. Ekman and W. V. Friesen, "Constants across cultures in the face and emotion," *Journal of Personality and Social Psychology*, vol. 17, no. 2, pp. 124–129, 1971. [Online]. Available: https://doi.org/10.1037/h0030377

[4] S. Li and W. Deng, "Deep facial expression recognition: A survey," *IEEE Transactions on Affective Computing*, vol. 13, no. 3, pp. 1195–1215, 2022. [Online]. Available: https://arxiv.org/abs/1804.08348

[5] I. J. Goodfellow, D. Erhan, P. L. Carrier, A. Courville, M. Mirza *et al.*, "Challenges in representation learning: A report on three machine learning contests," *Neural Networks*, vol. 64, pp. 59–63, 2015. [Online]. Available: https://doi.org/10.1016/j.neunet.2014.09.005

[6] P. Viola and M. Jones, "Rapid object detection using a boosted cascade of simple features," in *Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, vol. 1, 2001, pp. 511–518. [Online]. Available: https://doi.org/10.1109/CVPR.2001.990517

[7] K. Zhang, Z. Zhang, Z. Li, and Y. Qiao, "Joint face detection and alignment using multitask cascaded convolutional networks," *IEEE Signal Processing Letters*, vol. 23, no. 10, pp. 1499–1503, 2016. [Online]. Available: https://doi.org/10.1109/LSP.2016.2603342

[8] J. Deng, J. Guo, E. Ververas, I. Kotsia, and S. Zafeiriou, "Retinaface: Single-shot multi-level face localisation in the wild," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020, pp. 5203–5212. [Online]. Available: https://openaccess.thecvf.com/content_CVPR_2020/html/Deng_RetinaFace_Single-Shot_Multi-Level_Face_Localisation_in_the_Wild_CVPR_2020_paper.html

[9] T. Ojala, M. Pietikainen, and T. Maenpaa, "Multiresolution gray-scale and

rotation invariant texture classification with local binary patterns," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 24, no. 7, pp. 971–987, 2002. [Online]. Available: https://doi.org/10.1109/TPAMI.2002.1017623

[10] N. Dalal and B. Triggs, "Histograms of oriented gradients for human detection," in *Proceedings of the 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, vol. 1, 2005, pp. 886–893. [Online]. Available: https://doi.org/10.1109/CVPR.2005.177

[11] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, pp. 436–444, 2015. [Online]. Available: https://doi.org/10.1038/nature14539

[12] S. J. Pan and Q. Yang, "A survey on transfer learning," *IEEE Transactions on Knowledge and Data Engineering*, vol. 22, no. 10, pp. 1345–1359, 2010. [Online]. Available: https://doi.org/10.1109/TKDE.2009.191

[13] J. Deng, J. Guo, N. Xue, and S. Zafeiriou, "Arcface: Additive angular margin loss for deep face recognition," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019, pp. 4690–4699. [Online]. Available: https://openaccess.thecvf.com/content_CVPR_2019/html/Deng_ArcFace_Additive_Angular_Margin_Loss_for_Deep_Face_Recognition_CVPR_2019_paper.html

[14] S. Yang, P. Luo, C.-C. Loy, and X. Tang, "Wider face: A face detection benchmark," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 5525–5533. [Online]. Available: https://openaccess.thecvf.com/content_cvpr_2016/html/Yang_WIDER_FACE_A_CVPR_2016_paper.html

[15] OpenCV, "Haar cascade classifiers," 2026, truy cập ngày 22-09-2026. [Online]. Available: https://github.com/opencv/opencv/tree/4.x/data/haarcascades

[16] T. Esler, "facenet-pytorch: Pretrained pytorch face detection and recognition models," 2020, phiên bản 2.6.0, truy cập ngày 22-09-2026. [Online]. Available: https://github.com/timesler/facenet-pytorch

[17] J. Deng and Contributors, "Pytorch retinaface," 2020, commit b984b4b775b2c4dced95c1eadd195a5c7d32a60b, truy cập ngày 22-09-2026. [Online]. Available: https://github.com/biubug6/Pytorch_Retinaface

[18] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn, and A. Zisserman, "The pascal visual object classes (voc) challenge," *International Journal of*

Computer Vision, vol. 88, no. 2, pp. 303–338, 2010. [Online]. Available: https://doi.org/10.1007/s11263-009-0275-4

[19] K. Karkkainen and J. Joo, "Fairface: Face attribute dataset for balanced race, gender, and age for bias measurement and mitigation," in *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, 2021, pp. 1548–1558. [Online]. Available: https://openaccess.thecvf.com/content/WACV2021/html/Karkkainen_FairFace_Face_Attribute_Dataset_for_Balanced_Race_Gender_and_Age_WACV_2021_paper.html

[20] J. Joo and Contributors, "Fairface dataset repository," 2021, giấy phép CC BY 4.0, truy cập ngày 23-09-2026. [Online]. Available: https://github.com/joojs/fairface